

Wissensarbeit im Zeitalter generativer Künstlicher Intelligenz bei SAP

Eine systematische Analyse der Auswirkungen von Large Language Models auf Arbeitsprozesse und Kompetenzprofile

2. Projektarbeit

des Studienganges Wirtschaftsinformatik-Business Engineering
an der DHBW Ravensburg

von Anton Nguyen

Kurs:	WWIBE224
Matrikelnummer:	5282932
Dualer Partner:	SAP SE, 88677 Markdorf
Projektbetreuer:	Dagmar Schulte
Gutachter DHBW:	Kerem Ünal
Abgabedatum:	15.09.2026

Inhaltsverzeichnis

Abkürzungsverzeichnis.....	III
Abbildungsverzeichnis.....	IV
Tabellenverzeichnis.....	V
1 Einleitung.....	1
1.1 Problemstellung und Relevanz.....	1
1.2 Zielsetzung und Aufbau der Arbeit.....	2
2 Theoretische Grundlagen.....	4
2.1 Wissensarbeit im digitalen Wandel.....	4
2.2 Textgenerierung mittels Künstlicher Intelligenz: Large Language Models und Einsatzmöglichkeiten.....	6
3 Forschungsdesign und Vorgehensweise.....	8
3.1 Fallstudienanalyse nach Yin.....	8
3.2 Systematische Literaturanalyse.....	12
3.3 Experteninterviews.....	15
4 Auswirkungen von KI-Textgenerierung auf die Wissensarbeit (Ergebnisse der Literaturanalyse).....	18
4.1 Veränderungen von Arbeitsprozessen.....	18
4.2 Veränderungen der Kompetenzprofile.....	22
4.3 Chancen und Risiken.....	25
5 Experteninterviews, Diskussion und Handlungsempfehlungen.....	27
5.1 Durchführung und Auswertung der Interviews.....	27
5.2 Diskussion der Ergebnisse im Abgleich mit der Literatur.....	27
5.3 Limitationen der Untersuchung.....	27
5.4 Handlungsempfehlungen.....	27
6 Fazit und Ausblick.....	28
6.1 Zusammenfassung der Ergebnisse.....	28
6.2 Ausblick.....	28
Anhang.....	29
Literaturverzeichnis.....	35

Abkürzungsverzeichnis

AI	Artificial Intelligence
API	Application Programming Interface
BCG	Boston Consulting Group
GenAI	Generative Artificial Intelligence
KI	Künstliche Intelligenz
LLM	Large Language Model
LLMOps	Large Language Model Operations
ML	Machine Learning
PwC	PricewaterhouseCoopers
SAP	Systeme, Anwendungen und Produkte in der Datenverarbeitung
UX	User Experience

Abbildungsverzeichnis

Abbildung 1	Interviewleitfaden: KI Tools in der Wissensarbeit bei SAP.....	30
--------------------	--	----

Tabellenverzeichnis

Tabelle 1	Übersicht über die Nutzung von KI-basierten Werkzeugen.....	29
Tabelle 2	Gesprächsprotokoll: Interview mit Person A — KI Tools in der Wissensarbeit bei SAP.....	31
Tabelle 3	Gesprächsprotokoll: Interview mit Person B — KI Tools in der Wissensarbeit bei SAP.....	32
Tabelle 4	Gesprächsprotokoll: Interview mit Person C — KI Tools in der Wissensarbeit bei SAP.....	33
Tabelle 5	Gesprächsprotokoll: Interview mit Person D — KI Tools in der Wissensarbeit bei SAP.....	34

1 Einleitung

Die moderne Arbeitswelt steht am Beginn einer neuen technologischen Ära, die oft als fünfte industrielle Revolution begriffen wird und durch eine verstärkte Synergie zwischen menschlicher Kreativität und Künstlicher Intelligenz (KI) geprägt ist (vgl. McKinsey2026[S. 3]). Während vorangegangene Automatisierungswellen primär manuelle und routinemäßige Tätigkeiten betrafen, zielt Generative KI (GenAI) nun direkt auf die Domäne der Wissensarbeit ab (vgl. (Dell'Acqua u. a., 2026, S. 3); (Eloundou u. a., 2023, S. 1)).

Das enorme Aufsehen um Large Language Models (LLMs) wie ChatGPT begründet sich in der Fähigkeit dieser Systeme, komplexe Aufgaben zu übernehmen, die bisher menschliche Diskretion, tiefes Sprachverständnis und die Anwendung von implizitem Wissen erforderten (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 890); (Woodruff u. a., 2024, S. 1)). Aktuelle Analysen deuten darauf hin, dass GenAI in bestimmten Funktionsbereichen das Potenzial hat, in frühen Szenarien bis zu 70 % der heutigen Arbeitszeit technisch zu automatisieren (vgl. McKinsey2026[S. 5]; (Eloundou u. a., 2023, S. 1)). Für Unternehmen ergibt sich daraus die dringliche Notwendigkeit, sowohl allgemeine Sprachmodelle als auch spezialisierte relationale Modelle zur Analyse strukturierter Geschäftsdaten zu evaluieren und in bestehende Arbeitsprozesse zu integrieren (vgl. McKinsey2026[S. 20]; (Agrawal, Gans und Goldfarb, 2024, S. 327)).

1.1 Problemstellung und Relevanz

In der heutigen globalisierten Wirtschaft gilt Wissen als die **zentrale Ressource** und als der entscheidende Faktor für langfristige Wettbewerbsvorteile von Unternehmen (vgl. (Kusterer, 2008, S. 1)). Während die Informationstechnologie die Wissensarbeit seit Jahrzehnten unterstützt, markiert der Durchbruch generativer Künstlicher Intelligenz, insbesondere durch Large Language Models (LLMs), einen fundamentalen Wendepunkt (vgl. (Woodruff u. a., 2024, S. 2)). Diese Technologien dringen zunehmend in Domänen vor, die bisher als **ausschließlich menschliches Terrain** galten, wie etwa komplexes Sprachverständnis, kreative Textgenerierung und analytische Problemlösung (vgl. (Dell'Acqua u. a., 2026, S. 1); (Eloundou u. a., 2023, S. 1)).

Für ein Softwareunternehmen wie **SAP**, das im Zentrum der digitalen Transformation von Geschäftsprozessen steht, ist diese Entwicklung von doppelter Relevanz: Einerseits versprechen LLMs massive **Produktivitätspotenziale**. Studien belegen, dass der Einsatz von KI-Assistenten die Produktivität bei komplexen Schreib- und Programmieraufgaben signifikant steigern kann, wobei Zeiteinsparungen von etwa 0,75 Standardabweichungen beobachtet wurden (vgl. (Noy und Zhang, 2023, S. 187); (Brynjolfsson, Li und Raymond, 2025, S. 890)). Besonders bemerkenswert ist dabei die Fähigkeit der KI, als „**Equalizer**“, zu fungieren, indem

sie insbesondere weniger erfahrenen Mitarbeitern hilft, die Lernkurve schneller zu durchlaufen und Best-Practice-Muster erfolgreicher Experten zu adaptieren (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 917); (Dell'Acqua u. a., 2026, S. 8)).

Demgegenüber steht die Herausforderung einer „**gezackten technologischen Grenze**„ (Jagged Technological Frontier): LLMs zeigen eine beeindruckende Leistung bei bestimmten kreativen Aufgaben, scheitern jedoch unvorhersehbar an scheinbar einfachen logischen oder kontextspezifischen Problemen (vgl. (Dell'Acqua u. a., 2026, S. 1)). Die daraus resultierenden **Halluzinationen** — fachlich korrekt klingende, aber inhaltlich falsche Ausgaben — stellen in einem hochsensiblen Geschäftsumfeld ein erhebliches Risiko dar (vgl. (Woodruff u. a., 2024, S. 2); (Lee u. a., 2025, S. 2)). Hinzu kommen kritische Fragen der **Datensicherheit** und des Schutzes von geistigem Eigentum, da LLMs oft auf Basis sensibler Unternehmensdaten agieren (vgl. McKinsey2026[S. 20]).

Zudem löst der Einsatz von KI einen tiefgreifenden **Kompetenzwandel** aus. Wissensarbeitende verlagern ihre Tätigkeit zunehmend von der Erstellung von Inhalten hin zu deren **Überwachung und Integration** („Task Stewardship“), was eine verstärkte kognitive Anstrengung bei der Verifizierung von KI-Outputs erfordert (vgl. (Lee u. a., 2025, S. 2)). In Anbetracht dieser Spannungsfelder zwischen technologischem Fortschritt und operationalen Risiken widmet sich die vorliegende Arbeit der zentralen Fragestellung:

Wie verändern Large Language Models die Wissensarbeit bei SAP, und welche konkreten Handlungsempfehlungen lassen sich für Unternehmen und Mitarbeiter ableiten — angesichts erheblicher Produktivitätspotenziale, aber gleichzeitiger Risiken durch Halluzinationen, Datenschutz und Kompetenzwandel?

1.2 Zielsetzung und Aufbau der Arbeit

Das zentrale Ziel dieser Arbeit ist es, die Auswirkungen von Large Language Models auf die Wissensarbeit bei SAP systematisch zu analysieren und daraus konkrete Handlungsempfehlungen für Arbeitsprozesse, Kompetenzprofile und den zukünftigen KI-Einsatz abzuleiten. Um dieses Ziel zu erreichen, werden drei Erkenntnisdimensionen verfolgt. Zunächst soll der aktuelle Stand der Forschung zur Transformation der Wissensarbeit durch generative KI aufgearbeitet werden. Darauf aufbauend sollen die durch LLMs ausgelösten Veränderungen in Arbeitsabläufen und Kompetenzanforderungen bei SAP identifiziert werden. Schließlich sollen fundierte Handlungsempfehlungen entwickelt werden, die als Leitfaden für eine nachhaltige Integration von LLMs in den Arbeitsalltag dienen.

Entsprechend dieser Zielsetzung gliedert sich die Arbeit in sechs Kapitel. Zunächst legt Kapitel 2 die theoretischen Grundlagen, indem es den Begriff der Wissensarbeit im digitalen Wandel definiert und Large Language Models technisch einordnet. Anschließend beschreibt

Kapitel 3 das Forschungsdesign und erläutert die methodische Vorgehensweise, die auf einer Fallstudienanalyse nach Yin basiert und eine systematische Literaturanalyse mit qualitativen Experteninterviews verbindet. Darauf aufbauend stellt Kapitel 4 die Ergebnisse der Literaturanalyse dar, mit Fokus auf Veränderungen von Arbeitsprozessen und Kompetenzprofilen sowie den damit verbundenen Chancen und Risiken. Ergänzend dazu präsentiert Kapitel 5 die empirischen Ergebnisse der Experteninterviews und gleicht diese mit der Literatur ab, um spezifische Handlungsempfehlungen für SAP abzuleiten. Kapitel 6 schließt die Arbeit schließlich mit einer Zusammenfassung der zentralen Erkenntnisse und einem Ausblick auf die zukünftige Entwicklung der KI-gestützten Wissensarbeit ab.

2 Theoretische Grundlagen

Generative Künstliche Intelligenz verbreitet sich zunehmend und verändert dabei grundlegend, wie Wissensarbeit organisiert und ausgeführt wird (vgl. (Woodruff *u. a.*, 2024, S. 1-2); (Trenerry *u. a.*, 2021, S. 1–2)). Besonders Large Language Models markieren in diesem Zusammenhang einen bedeutenden Entwicklungsschritt, da sie zunehmend Aufgabenbereiche erschließen, die bislang überwiegend menschlicher Expertise vorbehalten waren, wie etwa komplexes Sprachverständnis, kreative Textgenerierung und analytische Problemlösung (vgl. (Dell'Acqua *u. a.*, 2026, S. 1); (Eloundou *u. a.*, 2023, S. 1-3)).

Um die Auswirkungen dieser Entwicklung auf die Wissensarbeit bei SAP im weiteren Verlauf der Arbeit systematisch analysieren zu können, werden in diesem Kapitel zunächst die theoretischen Grundlagen erarbeitet, auf denen die nachfolgende Untersuchung aufbaut. Abschnitt 2.1 definiert zunächst den Begriff der Wissensarbeit und beschreibt den durch LLMs ausgelösten Wandel. Abschnitt 2.2 erläutert anschließend die technische Funktionsweise von Large Language Models sowie deren Einsatzmöglichkeiten in der Wissensarbeit, wobei die Betrachtung bewusst auf die Textgenerierung beschränkt bleibt, da diese im unternehmerischen Kontext die dominierende Anwendungsform darstellt.

2.1 Wissensarbeit im digitalen Wandel

Der Begriff des Wissensarbeitenden wurde durch Peter Drucker geprägt (vgl. (Drucker, 1999)). Unter Wissensarbeit wird dabei eine Form spezialisierter Arbeit verstanden, deren zentrales Kapital Wissen darstellt (vgl. (Woodruff *u. a.*, 2024, S. 2)). Dementsprechend wird Wissen in Unternehmen häufig als eine der wichtigsten Ressourcen betrachtet und kann einen wesentlichen Wettbewerbsvorteil darstellen (vgl. (Kusterer, 2008, S. 1)). Wissensarbeit ist dadurch gekennzeichnet, dass sie ein hohes Maß an formaler Ausbildung sowie die Fähigkeit erfordert, theoretisches und analytisches Wissen anzuwenden. Hinzu kommt die Bereitschaft zum kontinuierlichen Lernen als wesentliches Merkmal (vgl. (Drucker, 1994)). Des Weiteren wird Wissen im ressourcenbasierten Ansatz als immaterielle Ressource verstanden, die aufgrund ihres Wertes, ihrer Seltenheit sowie ihrer eingeschränkten Imitier- und Substituierbarkeit zur Schaffung eines nachhaltigen Wettbewerbsvorteils beitragen kann (vgl. (Kusterer, 2008), S. 13). Die zunehmende Digitalisierung verändert die Rahmenbedingungen der Arbeit grundlegend und beeinflusst damit auch die Wissensarbeit (vgl. (Trenerry *u. a.*, 2021, S. 1–2)). Insbesondere digitale Technologien wie künstliche Intelligenz, Automatisierung, Cloud Computing und das Internet of Things verändern die Art und Weise, wie Arbeit organisiert und ausgeführt wird (vgl. (Trenerry *u. a.*, 2021, S. 1–2)). Als spezifische Gruppe von Arbeitnehmenden, deren zentrale Ressource Wissen ist (vgl. (Woodruff *u. a.*, 2024, S. 2)), sind Wissensarbeitende von diesen Veränderungen unmittelbar betroffen. Darüber hinaus ermöglichen digitale Technologien einen

erleichterten Zugang zu Informationen und unterstützen die Zusammenarbeit über räumliche Grenzen hinweg, beispielsweise durch digitale Kommunikations- und Kollaborationstechnologien (vgl. (Trenerry *u. a.*, 2021, S. 10)). Gleichzeitig verändern sich die Anforderungen an die Kompetenzen von Arbeitnehmenden, da digitale Fähigkeiten zunehmend notwendig werden, um Aufgaben in digitalen Arbeitsumgebungen ausführen zu können (vgl. (Trenerry *u. a.*, 2021, S. 7)). Dies betrifft insbesondere Wissensarbeitende, deren Tätigkeiten auf der Verarbeitung, Analyse und Nutzung von Informationen beruhen (vgl. (Woodruff *u. a.*, 2024, S. 2)).

Merkmale der Wissensarbeit

In der Literatur werden der Wissensarbeit häufig folgende Charakteristika zugeschrieben, die sie von manuellen oder rein administrativen Tätigkeiten abgrenzen:

- **Information als Rohstoff:** Wissensarbeit umfasst dabei Berufsfelder, die Informationen, Daten oder Ideen als „Rohmaterial“ nutzen, um Produkte und Dienstleistungen zu planen, zu analysieren, zu interpretieren, weiterzuentwickeln und zu erstellen ((Heerwagen *u. a.*, 2004, S. 511)).
- **Autonomie und Verantwortung:** Wissensarbeit versteht Arbeitnehmende als strategische Kapitalanlage des Unternehmens und verortet die Verantwortung für die Produktivität beim einzelnen Wissensarbeitende, der innerhalb definierter Grenzen autonom über die Herangehensweise an eine Aufgabe entscheidet (vgl. (Drucker, 1999, S. 87)).
- **Kognitive Intensität:** Wissensarbeit umfasst nicht-routinemäßige, kognitiv anspruchsvolle Aktivitäten, die auf der Erstellung, Anwendung oder Integration von spezialisierter intellektueller Expertise basieren (vgl. (Dell'Acqua *u. a.*, 2026, S. 4)).

Herausforderungen im digitalen Wandel

Durch den Einzug von Large Language Models (LLMs) steht die Wissensarbeit vor einer tiefgreifenden Transformation, die neue **Herausforderungen** mit sich bringt:

1. **Die diskontinuierliche technologische Grenze (Jagged Frontier):** KI-Systeme zeigen in kognitiven Domänen eine ungleichmäßige Leistung. Während sie bei kreativen Aufgaben oft menschliche Experten übertreffen, können sie bei logisch ähnlich komplexen Aufgaben unvorhersehbar scheitern (vgl. (Dell'Acqua *u. a.*, 2026, S. 1)).
2. **Wandel zur Stewardship-Rolle:** Die Tätigkeit von Wissensarbeitenden verlagert sich von der Erstellung hin zur Überwachung und Integration von KI-Outputs, was eine erhöhte kritische Reflexionsfähigkeit erfordert (vgl. (Lee *u. a.*, 2025, S. 15)).
3. **Cognitive Offloading:** Die zunehmende Delegation kognitiver Aufgaben an KI-Systeme birgt die Gefahr einer Schwächung des kritischen Denkens sowie einer kognitiven Abhängigkeit (vgl. (Gerlich, 2025, S. 2)).

4. **Validierungsaufwand:** Da LLMs zu Halluzinationen und inhaltlich falschen, aber plausibel klingenden Ausgaben neigen, steigt der Aufwand für Verifizierungsprozesse (vgl. (Lee *u. a.*, 2025, S. 15); (Brynjolfsson, Li und Raymond, 2025, S. 897); (Dell'Acqua *u. a.*, 2026, S. 3)).

Um diese Herausforderungen einordnen zu können, bedarf es zunächst eines Überblicks über die technische Grundlage von LLMs sowie deren konkrete Einsatzmöglichkeiten in der Wissensarbeit.

2.2 Textgenerierung mittels Künstlicher Intelligenz: Large Language Models und Einsatzmöglichkeiten

Large Language Models (LLMs) zählen zu den bedeutendsten Entwicklungen innerhalb der jüngeren KI-Forschung (vgl. (Bubeck *u. a.*, 2023, S.4)). Es handelt sich dabei um neuronale Netzwerkmodelle, die anhand riesiger Mengen an Textdaten aus dem Internet trainiert werden. Das Modell lernt dabei, auf Basis eines gegebenen Kontextes die Wahrscheinlichkeit nachfolgender Tokens vorherzusagen (vgl. (Bubeck *u. a.*, 2023, S.4)). Obwohl der Begriff menschliche Sprache impliziert, lassen sich diese Techniken auch auf andere Formen sequenzieller Daten anwenden, etwa Computercode, Proteinsequenzen oder Audiodaten (vgl. (Eloundou *u. a.*, 2023, S. 1)). Dabei bezeichnet der Begriff ein Modell, das auf extrem großen Datensätzen (oft im Tera- oder Petabyte-Bereich) trainiert wurde und über Milliarden von Parametern verfügt, um komplexe linguistische Strukturen abzubilden (vgl. (Woodruff *u. a.*, 2024, Fn. 1); (Bender *u. a.*, 2021, S. 610-623)).

Technische Funktionsweise der Textgenerierung

Der Kern der Textgenerierung basiert auf der **wahrscheinlichkeitsbasierten Vorhersage** des nächsten Wortes (bzw. Tokens) in einer Sequenz (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 895); (Chen *u. a.*, 2025, S. 14)).

- **Transformer-Architektur und Self-Attention:** Der entscheidende Fortschritt gelang durch die Einführung von Transformer-Modellen, die einen sogenannten „Attention-Mechanismus“ nutzen. Dieser erlaubt es dem System, Wörtern innerhalb eines Textes unterschiedliche Relevanzgewichte zuzuweisen, um semantische Abhängigkeiten über weite Distanzen hinweg zu erfassen (vgl. (Chen *u. a.*, 2025, S. 14); (Brynjolfsson, Li und Raymond, 2025, S. 896)).
- **Stochastische Mustererkennung:** Anstatt expliziten linguistischen Regeln zu folgen, lernen diese Modelle durch statistische Korrelationen („Pattern Recognition“), welche Begriffe in einem bestimmten Kontext üblicherweise zusammen auftreten (vgl. (Jiao *u. a.*, 2025, S. 1); (Brynjolfsson, Li und Raymond, 2025, S. 896)).
- **Software-2.0-Paradigma:** Im Gegensatz zur klassischen Programmierung (Software 1.0), bei der jede Anweisung explizit kodiert wird, folgt die Textgenerierung einem datengesteuerten Ansatz. Das Verhalten entsteht dabei aus Berechnungen auf großen Datensätzen, wobei

sich das neuronale Netzwerk für die erwünschte Antwort selbst optimiert (vgl. (Chen *u. a.*, 2025, S. 11)).

Abgrenzung und Einsatzgebiete in der Wissensarbeit

Ein wesentliches Merkmal textgenerierender KI ist die Abgrenzung zur **diskriminativen KI**. Diskriminative KI ist dabei primär auf die Klassifikation und Kategorisierung von Daten ausgerichtet, wohingegen generative KI eigenständig neue Inhalte erzeugt, die menschlichen Erzeugnissen in ihrer Qualität nahekommen (vgl. (Felten, Raj und Seamans, 2023, S. 1); (Jiao *u. a.*, 2025, S. 2)). Aufgrund dieser Eigenschaften finden LLMs in der Wissensarbeit breite Anwendung als Allzwecktechnologien (vgl. (Eloundou *u. a.*, 2023, S. 1 und 22)):

- **Textproduktion und -optimierung:** LLMs unterstützen die Erstellung von Erstentwürfen für Berichte, E-Mails oder Marketingmaterialien sowie die Umformulierung komplexer Sachverhalte an verschiedene Tonalitäten (vgl. (Noy und Zhang, 2023, S. 187-188); (Woodruff *u. a.*, 2024, S. 7,13 und 23)).
- **Codegenerierung:** LLMs ermöglichen die Übersetzung natürlicher Sprache in Programmiersprachen (z. B. Python), was die Produktivität in der Softwareentwicklung durch automatisierte Vorschläge erheblich steigert (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 897); (Eloundou *u. a.*, 2023, S. 4); (Chen *u. a.*, 2025, S. 6,11 und 15)).
- **Information Synthesis:** LLMs ermöglichen die Zusammenfassung umfangreicher Dokumente („Summarization“) und die Extraktion relevanter Fakten aus unstrukturierten Textmengen (vgl. (Chen *u. a.*, 2025, S. 14-15); (Lee *u. a.*, 2025, S. 4-6 und 12)).

Trotz dieser Potenziale bleibt die Herausforderung der **Halluzination** bestehen, da LLMs auf statistischen Wahrscheinlichkeiten für die Vorhersage des nächsten Tokens auf Basis des bisherigen Kontexts beruhen (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 895)) und dadurch inhaltlich falsche Aussagen mit hoher sprachlicher Überzeugungskraft generieren können (vgl. (Dell'Acqua *u. a.*, 2026, S. 3); (Woodruff *u. a.*, 2024, S. 7 und 23)). Eine kontinuierliche menschliche Validierung („Task Stewardship“) bleibt daher für die Qualitätssicherung in professionellen Kontexten unerlässlich (vgl. (Lee *u. a.*, 2025, S. 12–16)).

3 Forschungsdesign und Vorgehensweise

Eine Methode beschreibt eine systematische Vorgehensweise, mit der innerhalb eines festgelegten Ziels Erkenntnisse gewonnen werden können. Dabei zeichnen sich Methoden durch verschiedene charakteristische Merkmale aus. Zunächst ist entscheidend, dass eine Methode auch für Personen nachvollziehbar ist, die bisher keine Kenntnisse über deren Anwendung besitzen. Darüber hinaus sollte die Durchführung unabhängig von der jeweiligen Person immer zu vergleichbaren Ergebnissen führen.

Des Weiteren basieren Methoden auf einem klar strukturierten und durchdachten Prinzip, wodurch eine objektive Vorgehensweise ermöglicht wird. Folglich werden persönliche Annahmen oder subjektive Einschätzungen, die bereits im Vorfeld entstanden sind, nicht in die Bewertung einbezogen. Abschließend ist es wichtig, dass Methoden nach einheitlichen Grundsätzen aufgebaut sind, sodass sie vermittelbar, erlernbar und wiederholbar bleiben (vgl. (Balzert, 2009, S. 53)).

3.1 Fallstudienanalyse nach Yin

Yin definiert die Fallstudie entlang zweier zentraler Dimensionen, nämlich dem Untersuchungsgegenstand einerseits und den methodischen Merkmalen andererseits. Hinsichtlich des Untersuchungsgegenstands handelt es sich bei einer Fallstudie um eine empirische Untersuchung, die ein Phänomen oder einen Fall eingehend und in seinem realen Kontext analysiert. In methodischer Hinsicht zeichnet sich die Fallstudie dadurch aus, dass sie die technisch besondere Situation berücksichtigt, in der mehr relevante Variablen als verfügbare Datenpunkte vorliegen. Um dieser Komplexität gerecht zu werden, stützt sie sich auf mehrere Evidenzquellen, deren Daten durch Triangulation zusammengeführt werden. Insgesamt erweist sich die Fallstudie damit als eine ganzheitliche Forschungsmethode, die Designlogik, Datenerhebung und Datenanalyse gleichermaßen umfasst und folglich nicht auf ein bloßes Erhebungsinstrument reduziert werden kann (vgl. (Yin, 2014, S. 33)).

Arten von Fallstudien

Fallstudien können drei verschiedenen Forschungszwecken dienen. Explorative Fallstudien zielen darauf ab, erste Hypothesen für eine weiterführende Untersuchung zu entwickeln. Deskriptive Fallstudien beschreiben ein Phänomen innerhalb seines Kontextes vollständig. Explanatorische Fallstudien hingegen erklären kausale Zusammenhänge (vgl. (Yin, 2014, S. 23)).

Ein weiteres Unterscheidungsmerkmal betrifft die Anzahl der untersuchten Fälle. Bei der Einzelfallstudie konzentriert sich die Analyse auf einen einzigen Fall, was sich dann anbietet, wenn dieser besonders erkenntnisreich ist, einen Extremfall darstellt oder einen seltenen Zugang

zum Untersuchungsgegenstand ermöglicht. Auf diese Weise lässt sich die Existenz eines Phänomens unter außergewöhnlichen Bedingungen gezielt und tiefgehend untersuchen (vgl. (Eisenhardt und Graebner, 2007, S. 25-27)). Die Mehrfachfallstudie erweitert diesen Ansatz, indem sie mehrere Fälle einbezieht und auf dieser Grundlage fallübergreifende Aussagen ableitet (vgl. (Yin, 2014, S. 45)). Der Vergleich verschiedener Fälle erlaubt es zu beurteilen, ob ein Ergebnis fallspezifisch ist oder sich auf andere Kontexte übertragen lässt. Die Fallauswahl erfolgt dabei bewusst, um theoretische Annahmen zu stützen, weiterzuentwickeln, zu kontrastieren oder konkurrierende Erklärungen zu entkräften (vgl. (Eisenhardt und Graebner, 2007, S. 25-27)).

Der Forschungsprozess nach Yin gliedert sich in sechs aufeinander aufbauende Phasen, nämlich Plan, Design, Prepare, Collect, Analyze und Share, die den gesamten Ablauf von der ersten Konzeption bis zur abschließenden Kommunikation der Ergebnisse strukturieren.

Plan

In der Plan-Phase wird grundlegend geklärt, ob die Fallstudie als Forschungsmethode für das jeweilige Erkenntnisinteresse geeignet ist. Nach Yin spricht für ihren Einsatz, wenn die Forschungsfragen auf ein Wie oder Warum abzielen, der Forscher keinen Einfluss auf das untersuchte Geschehen nehmen kann und ein gegenwärtiges Phänomen im Mittelpunkt steht (vgl. (Yin, 2014, S. 3)). Der Formulierung der Forschungsfrage kommt in diesem Zusammenhang eine besondere Bedeutung zu, denn sie ist nicht nur inhaltlicher Ausgangspunkt, sondern entscheidet durch ihre Form als Wie- oder Warum-Frage maßgeblich darüber, ob die Fallstudie als Methode überhaupt in Betracht kommt (vgl. (Yin, 2014, S. 11)).

Design

Die Designphase verfolgt das Ziel, logische Inkonsistenzen im Forschungsaufbau zu vermeiden und sicherzustellen, dass die erhobenen Daten tatsächlich zur Beantwortung der Forschungsfrage beitragen. Yin zufolge umfasst ein vollständiges Fallstudiendesign fünf zentrale Komponenten, nämlich die Forschungsfragen, theoretische Annahmen, die zu untersuchende Einheit, die Logik der Verknüpfung von Daten und Annahmen sowie Kriterien zur Interpretation der Befunde (vgl. (Yin, 2014, S. 61)).

Prepare

Die Prepare-Phase dient der systematischen Vorbereitung der Datenerhebung und gliedert sich nach Yin in fünf Bereiche. Diese umfassen die persönlichen Fähigkeiten des Forschers, ein fallspezifisches Training, die Erstellung eines Studienprotokolls, die Auswahl geeigneter Fälle sowie eine vorgelagerte Pilotstudie. Anders als bei Experimenten oder standardisierten Befragungen gibt es bei der Fallstudienforschung kein festgelegtes Erhebungsverfahren, weshalb der Forscher während der gesamten Datenerhebung fortlaufend eigene Urteile treffen muss. Yin benennt dabei konkrete Anforderungen an den Forscher, der gezielt und präzise

fragen, aktiv zuhören, flexibel auf unerwartete Entwicklungen reagieren, die theoretischen Vorannahmen kontinuierlich im Blick behalten und mögliche Verzerrungen bewusst reflektieren sollte (vgl. (Yin, 2014, S. 71f)). Zur Absicherung der Reliabilität empfiehlt Yin die Erstellung eines Fallstudienprotokolls, das vier Bestandteile umfasst, nämlich eine Übersicht über das Forschungsprojekt, eine Beschreibung des Datenerhebungsprozesses, einen Katalog analytischer Fragen als Orientierungshilfe für den Forscher während der Feldarbeit sowie einen Leitfaden für die abschließende Berichterstattung (vgl. (Yin, 2014, S. 84f)).

Ergänzend weist Yin darauf hin, dass die analytischen Fragen des Protokolls nicht mit den Interviewfragen verwechselt werden dürfen, da sie ausschließlich als Reflexionshilfe für den Forscher selbst konzipiert sind und nicht an die Befragten gerichtet werden (vgl. (Yin, 2014, S. 89f)). Im Anschluss daran folgt das Screening, das der finalen Fallauswahl unmittelbar vor Beginn der Datenerhebung dient (vgl. (Yin, 2014, S. 95)). Da als Untersuchungseinheit Wissensarbeitende bei SAP, die aktiv Large Language Models einsetzen, von Beginn an feststanden, war ein aufwändiges Auswahlverfahren nicht erforderlich. Darüber hinaus empfiehlt Yin die Durchführung einer Pilotstudie, die sich von einem klassischen Pretest insofern unterscheidet, als sie nicht nur das Erhebungsinstrument erprobt, sondern auch konzeptionelle Klärungen für das Gesamtdesign ermöglicht (vgl. (Yin, 2014, S. 96)). In der vorliegenden Arbeit wurde auf eine Pilotstudie verzichtet, da der Forscher als internes Mitglied der SAP-Organisation über einen kontinuierlichen Feldzugang verfügte, der diese konzeptionelle Funktion bereits erfüllte.

Collect

In der Collect-Phase erfolgt die eigentliche Datenerhebung, wobei Fallstudien grundsätzlich auf eine Vielzahl unterschiedlicher Datenquellen zurückgreifen können. Keine dieser Quellen ist den anderen dabei von vornherein überlegen. Stattdessen zeichnet eine qualitativ hochwertige Fallstudie gerade dadurch aus, dass sie möglichst viele verschiedene Quellen miteinander kombiniert und so eine breitere und belastbarere Evidenzbasis schafft. Zu den gängigsten Datenquellen zählen nach Yin Dokumentation, Archivdaten, Interviews, direkte Beobachtung, teilnehmende Beobachtung sowie physische Artefakte (vgl. (Yin, 2014, S. 106f)). In der vorliegenden Arbeit werden zwei dieser Quelltypen kombiniert, nämlich Experteninterviews als primäre Erhebungsmethode sowie wissenschaftliche und praxisorientierte Literatur als sekundäre Evidenzbasis. Weitere bei Yin genannte Quellen wie interne Dokumente, direkte Beobachtung oder Archivdaten konnten aus forschungspraktischen Gründen nicht einbezogen werden, da der Feldzugang auf die Durchführung von Interviews begrenzt war.

Analyze

Gegenstand der Analysephase ist die systematische Auswertung der erhobenen Belege, die kategorisiert, tabellarisch aufbereitet und zueinander in Beziehung gesetzt werden, um daraus

fundierte Erkenntnisse abzuleiten (vgl. (Yin, 2014, S. 133)). Anders als bei quantitativen Methoden stehen dem Forscher dabei weder standardisierte Verfahren noch feste Formeln zur Verfügung, weshalb er frühzeitig eine eigene Analysestrategie entwickeln sollte, idealerweise bereits in der Designphase. Als Orientierungsrahmen benennt Yin vier allgemeine Strategien, wobei der Forscher wahlweise an theoretischen Propositionen anknüpfen, induktiv von den Daten ausgehen, eine deskriptive Fallbeschreibung erarbeiten oder plausible Alternativerklärungen systematisch prüfen kann (vgl. (Yin, 2014, S. 136f)). Aufbauend auf diesen Strategien stehen zudem fünf spezifische Analysetechniken zur Verfügung, nämlich Pattern Matching, Explanation Building, Time-Series Analysis, Logic Models sowie Cross-Case Synthesis (vgl. (Yin, 2014, S. 142)).

Im Kontext der vorliegenden Arbeit kommen zwei Analysetechniken zum Einsatz. Zum einen wird Pattern Matching als primäre Technik genutzt, da die in der Literaturanalyse erarbeiteten theoretischen Muster zu Veränderungen in Arbeitsprozessen und Kompetenzprofilen mit den empirischen Befunden der Experteninterviews abgeglichen werden. Stimmen die beobachteten Muster mit den theoretisch erwarteten überein, stärkt dies die interne Validität der Ergebnisse (vgl. (Yin, 2014, S. 143)). Ergänzend dazu wird Explanation Building eingesetzt, um auf Basis dieses Abgleichs schrittweise eine konsistente Erklärung dafür zu entwickeln, wie und unter welchen Bedingungen LLMs die Wissensarbeit bei SAP verändern. Die Erklärung entsteht dabei iterativ, indem eine theoretische Ausgangsthese mit den erhobenen Interviewdaten konfrontiert und in mehreren Schritten so lange verfeinert wird, bis ein stimmiges Gesamtbild vorliegt (vgl. (Yin, 2014, S. 147f)). Unabhängig von der gewählten Technik hebt Yin schließlich vier Qualitätsmerkmale einer guten Analyse hervor, nämlich die lückenlose Berücksichtigung aller erhobenen Belege, die aktive Auseinandersetzung mit konkurrierenden Erklärungsansätzen, die konsequente Fokussierung auf den zentralen Forschungsgegenstand sowie die reflektierte Nutzung des eigenen Expertenwissens (vgl. (Yin, 2014, S. 168f)).

Share

Als abschließender Schritt des Fallstudienforschungsprozesses umfasst die Share-Phase die Aufbereitung und Kommunikation der gewonnenen Erkenntnisse. Da die Fallstudie dabei keiner standardisierten Vorlage folgt, stellt Yin zufolge gerade diese Phase besonders hohe Anforderungen an die schriftlichen und kommunikativen Kompetenzen des Forschers. Hinsichtlich der Form ist zu betonen, dass ein Fallstudienbericht nicht auf reine Texte beschränkt ist, sondern ebenso nicht-textuelle Elemente wie Tabellen, Abbildungen, Grafiken oder Präsentationen einschließen kann. Vor der eigentlichen Gestaltung sollte jedoch zunächst die Zielgruppe des Berichts geklärt werden, da Yin zwischen wissenschaftlichen Fachkollegen, Praktikern und politischen Entscheidungsträgern, Prüfungskommissionen sowie Forschungsförderern unterscheidet und jede dieser Gruppen spezifische Erwartungen an den Bericht mitbringt (vgl. (Yin, 2014, S. 177f)). Gerade für wissenschaftliche Abschlussarbeiten bietet

sich die linear-analytische Struktur an, bei der die Darstellung von der Forschungsfrage über Methodik und Daten bis hin zu Befunden und Schlussfolgerungen logisch aufgebaut wird (vgl. (Yin, 2014, S. 188)). Zudem empfiehlt Yin, den Schreibprozess nicht auf die Abschlussphase zu verschieben, sondern bereits während der Datenerhebung zu beginnen, um die Qualität des Endberichts nachhaltig zu sichern (vgl. (Yin, 2014, S. 195)). Als übergeordnetes Gütemerkmal gilt schließlich, dass der Bericht so viele Belege enthält, dass sich der Leser auf dieser Basis ein eigenes, unabhängiges Urteil über die präsentierten Befunde bilden kann (vgl. (Yin, 2014, S. 205)).

Grundsätzlich wären für diese Arbeit auch alternative Forschungsdesigns denkbar gewesen, etwa eine Mehrfachfallstudie mit vergleichend untersuchten Unternehmen, ein quantitatives Umfrage-Design mit standardisierten Fragebögen oder eine Grounded-Theory-Studie. Dennoch erweist sich die Einzelfallstudie nach Yin als am besten geeignet, weil die Rollen-transformation ein zeitgenössisches Phänomen darstellt, das nicht losgelöst von seinem organisationalen Kontext betrachtet werden kann. Eine quantitative Erhebung schied dabei aus, da sie voraussetzen würde, dass die relevanten Variablen bereits bekannt sind, was hier gerade die eigentliche Forschungslücke darstellt. Ebenso wenig war eine Mehrfachfallstudie realisierbar, da der Zugang zu vergleichbaren Transformationsprojekten anderer Unternehmen nicht in ausreichendem Maß gegeben war. SAP hingegen bietet als Einzelfall einen Kontext mit bereits fortgeschrittener LLM-Adoption und erfüllt damit Yins Kriterium eines Critical Case: Die in Kapitel 4 aus der Literatur abgeleiteten theoretischen Propositionen zu Veränderungen in Arbeitsprozessen und Kompetenzprofilen werden in Kapitel 5 anhand der empirischen Interviewdaten geprüft, bestätigt oder herausgefordert. Als Analyseeinheit werden dabei Wissensarbeitende bei SAP definiert, die im Rahmen ihrer beruflichen Tätigkeit aktiv Large Language Models einsetzen. Die Untersuchung richtet sich damit nicht auf die Organisation als Ganzes, sondern auf die konkreten Veränderungen in Arbeitsprozessen und Kompetenzprofilen dieser Personengruppe.

3.2 Systematische Literaturanalyse

Methodisches Vorgehen der Literaturanalyse nach Snyder

Um für die Untersuchung der Wissensarbeit bei SAP eine valide und reproduzierbare Grundlage zu schaffen, folgt diese Arbeit dem methodischen Rahmen von (Snyder, 2019). Da im Rahmen dieser Arbeit festgestellt wurde, dass das Forschungsfeld der generativen Künstlichen Intelligenz durch eine hohe Entwicklungsgeschwindigkeit und ein breites fachübergreifendes Spektrum geprägt ist, eignet sich dieser Ansatz besonders, da er nicht auf rein quantitative Methoden beschränkt ist, sondern auch die gemeinsame Auswertung von Quellen aus unterschiedlichen Forschungsrichtungen ermöglicht (vgl. (Snyder, 2019, S. 334)). Das Vorgehen

gliedert sich dabei in den vierphasigen Prozess aus Design, Durchführung, Analyse und Verschriftlichung (vgl. (Snyder, 2019, S. 336-337)).

In der ersten Phase, dem Review-Design, wird die methodische Ausrichtung festgelegt. Aufgrund der beschriebenen Aktualitätsproblematik und der Notwendigkeit, verschiedene Perspektiven zu vereinen, wird ein integrativer Review-Ansatz gewählt. Dieser eignet sich nach Snyder besonders für neue Themenbereiche, bei denen noch kein etabliertes theoretisches Modell existiert und das Ziel darin besteht, erste Zusammenhänge und Muster zu erkennen, anstatt bestehende Ansätze lediglich zu bestätigen (vgl. (Snyder, 2019, S. 336)). Entsprechend den Vorgaben von Snyder wurden in dieser Phase zunächst die Forschungsfragen festgelegt, die als Grundlage für die gesamte Suche und Analyse dienen (vgl. (Snyder, 2019, S. 336)). Sie adressieren dabei sowohl theoretische Potenziale als auch praktische Realitäten des KI-Einsatzes bei SAP. Darüber hinaus wurde die Suchstrategie definiert: Die wissenschaftliche Suche erfolgte in den Datenbanken Google Scholar, arXiv, ResearchGate sowie dem Bibliothekskatalog der DHBW Ravensburg mit den Suchbegriffen „how AI shapes and evolves knowledge work,,, „generative AI productivity“ sowie „LLM in knowledge work,,, Praxisorientierte Quellen wie Beratungsstudien wurden über gezielte KI-gestützte Recherche identifiziert und verifiziert. Da eine Literatursuche in der Regel eine große Anzahl an Treffern liefert, wurden auf Basis der Forschungsfrage zudem konkrete Ein- und Ausschlusskriterien festgelegt, anhand derer die tatsächlich relevanten Quellen identifiziert werden sollten (vgl. (Snyder, 2019, S. 337)). Snyder betont dabei, dass alle Ein- und Ausschlussentscheidungen explizit begründet sein müssen, um die Transparenz und die Qualität des Reviews sicherzustellen (vgl. (Snyder, 2019, S. 337–338)). Dies wird in dieser Arbeit durch die kritische Würdigung der grauen Literatur realisiert.

In der zweiten Phase der Durchführung wurde die eigentliche Literatursuche anhand der in Phase 1 festgelegten Strategie umgesetzt. Snyder empfiehlt, die Suchbegriffe und Auswahlkriterien zunächst an einer kleineren Auswahl zu testen und den Prozess bei Bedarf anzupassen, bevor die vollständige Suche durchgeführt wird (vgl. (Snyder, 2019, S. 337)). Entsprechend diesem Vorgehen wurden die Suchbegriffe in einem ersten Schritt erprobt und verfeinert. Die Quellenauswahl erfolgte anschließend in zwei Stufen: Zunächst wurden die Treffer anhand von Titel und Abstract auf ihre Relevanz geprüft, bevor die verbliebenen Quellen im Volltext gelesen und abschließend bewertet wurden. Snyder empfiehlt zudem den Einsatz von zwei Reviewern, um die Qualität und Reliabilität der Quellenauswahl zu sichern (vgl. (Snyder, 2019, S. 337)). Da die vorliegende Arbeit von einem einzelnen Autor verfasst wird, konnte diesem Vorgehen nicht entsprochen werden; diesem Umstand wird durch die explizite Dokumentation der Ein- und Ausschlusskriterien begegnet. Alle Entscheidungen wurden dabei auf Basis der in Phase 1 definierten Kriterien getroffen und sind durch die kritische Würdigung der Quellenkategorien nachvollziehbar dokumentiert (vgl. (Snyder, 2019, S. 337)).

Nach der Identifikation der relevanten Quellen erfolgt in der dritten Phase die Analyse. Snyder betont, dass nach der Festlegung der endgültigen Quellen ein einheitliches Vorgehen zur Informationsentnahme angewendet werden sollte, um Qualität und Verlässlichkeit der Auswertung sicherzustellen (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit wurden aus den ausgewählten Quellen relevante Informationen in Form von Befunden, Einschätzungen und thematischen Schwerpunkten entnommen. Die Analyse erfolgt dabei nicht rein autorenenorientiert, sondern konzeptzentriert: Themen wie „Veränderung von Arbeitsprozessen“, „Kompetenzwandel durch KI“ oder „Chancen und Risiken des KI-Einsatzes“, wurden über die verschiedenen Quellenkategorien hinweg extrahiert und miteinander verglichen. Da das Ziel dieser Arbeit nicht die statistische Auswertung von Effektgrößen, sondern die Entwicklung eines inhaltlichen Überblicks ist, wurde eine für integrative Reviews geeignete Analysetechnik gewählt (vgl. (Snyder, 2019, S. 337)).

In der abschließenden Phase der Verschriftlichung werden die Ergebnisse so aufbereitet, dass Motivation, Vorgehen und Erkenntnisse des Reviews klar und nachvollziehbar kommuniziert werden (vgl. (Snyder, 2019, S. 337)). Snyder verweist dabei auf anerkannte Richtlinien zur Berichterstattung von Literaturreviews, darunter die Leitlinien für integrative Reviews nach Torracco (Torraco, 2005, zitiert nach (Snyder, 2019, S. 337)). Unabhängig vom gewählten Ansatz wird erwartet, dass der gesamte Prozess von der Planung über die Suche bis hin zur Analyse transparent beschrieben wird, damit der Leser die Qualität und Verlässlichkeit der Ergebnisse einschätzen kann (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit wird diesem Anspruch durch die detaillierte Beschreibung der vier Phasen in diesem Kapitel entsprochen. Snyder beschreibt, dass der Beitrag eines Reviews verschiedene Formen annehmen kann, etwa eine konzeptionelle Aufarbeitung eines Forschungsfelds (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit besteht der Beitrag darin, einen strukturierten Überblick über den aktuellen Wissensstand zur Veränderung der Wissensarbeit durch generative KI zu schaffen.

Zielsetzung und Vorgehen

Die vorliegende Arbeit untersucht, wie generative Künstliche Intelligenz Arbeitsprozesse und Kompetenzprofile in der Wissensarbeit bei SAP verändert sowie welche Chancen und Risiken sich daraus ergeben. Da es sich um ein Forschungsfeld handelt, in dem im Rahmen dieser Arbeit festgestellt wurde, dass die akademische Literatur der technologischen Entwicklung teils mit zeitlichem Verzug folgt, wurde die Literaturanalyse bewusst mehrstufig angelegt: Sie kombiniert drei Quellenkategorien, die zwei unterschiedliche Funktionen erfüllen, nämlich die theoretisch-methodische Fundierung durch wissenschaftliche Studien einerseits sowie die Abbildung empirischer Aktualität und Praxisrelevanz durch Berater- und Fachpressequellen andererseits.

Die einbezogene Literatur lässt sich dabei in drei Kategorien unterteilen. Wissenschaftliche Literatur in Form von peer-reviewten Studien und Working Papern bildet die theoretische

Basis der Arbeit und liefert methodisch abgesicherte Erkenntnisse zu Automatisierungspotenzialen und Produktivitätseffekten. Beratungsstudien (graue Literatur) großer Institute liefern ergänzend aktuelle, breit angelegte empirische Daten zu Skill-Wandel oder Adoptionsraten, die wissenschaftlich oft noch nicht verfügbar sind. Fachpresse und Praxisbeiträge runden das Bild punktuell ab, indem sie die praktische Rezeption der Entwicklungen in Unternehmen abbilden. Da geeignete Fachpressebeiträge im Zuge der Recherche nur vereinzelt identifiziert werden konnten, stützt sich die Analyse in diesem Bereich überwiegend auf Beratungsstudien, die eine vergleichbare Funktion erfüllen.

Zur Sicherung der Quellenqualität werden spezifische Auswahlkriterien angelegt. Neben einer strikten Aktualität (Fokus auf 2023–2026) wird bei Beratungsstudien die Transparenz der Methodik (Stichprobengröße, Erhebungszeitraum) geprüft. Um eine einseitige Darstellung zu vermeiden, wird auf Ausgewogenheit geachtet, indem auch kritische Gegenpositionen zum KI-Einsatz in Unternehmen einbezogen werden. Reine Meinungsbeiträge ohne empirische Grundlage werden ausgeschlossen.

Diese einbezogenen Beratungsquellen stellen keine peer-reviewte Literatur im engeren Sinne dar und sind entsprechend kritisch zu würdigen. Insbesondere bei Studien von Unternehmensberatungen ist ein potenzieller Interessenkonflikt zu berücksichtigen, da diese Institute selbst kommerzielle KI-Transformationsleistungen anbieten. Dieser methodischen Einschränkung wird dadurch begegnet, dass Beratungsquellen stets in Verbindung mit wissenschaftlichen Quellen herangezogen werden und ihre empirischen Befunde nur dort als eigenständige Belege gelten, wo vergleichbare wissenschaftliche Daten aufgrund der Aktualität des Forschungsfelds noch nicht verfügbar sind.

3.3 Experteninterviews

Als eine der zentralen Methoden qualitativer Forschung findet das Experteninterview in unterschiedlichen Forschungsfeldern Anwendung und kann dabei sowohl als eigenständiges Instrument als auch in Kombination mit weiteren Forschungsmethoden eingesetzt werden (vgl. (Burger, 2011, S. 127)). Im Mittelpunkt steht die gezielte Erschließung des Fachwissens ausgewählter Experten, um auf dieser Basis wissenschaftlich fundierte Erkenntnisse zu gewinnen (vgl. (Bogner, Littig und Menz, 2014, S. 17)).

Das Interview stellt in seiner grundlegenden Form eine mündliche Befragung dar (vgl. (Renner und Jacob, 2020, S. 1)). Befragungen lassen sich dabei generell in quantitative und qualitative Verfahren unterteilen (vgl. (Fantapié Altobelli, 2017, S. 55, 357)). Leitfadengestützte Experteninterviews zählen zu den qualitativen Methoden der Datenerhebung. Da die gewonnenen Daten im Anschluss unmittelbar weiterverarbeitet werden, ist bei der Durchführung besondere Sorgfalt geboten (vgl. (Baur und Blasius, 2022, S. 875)).

Qualitative Befragungen unterscheiden sich von quantitativen Verfahren insbesondere durch ihren kleineren Umfang. Anstelle standardisierter Fragen stehen individualisierte Fragen im Vordergrund, die auf Informationen abzielen, die für Außenstehende nicht ohne Weiteres zugänglich sind (vgl. (Fantapié Altobelli, 2017, S. 357)). Ein Leitfadeninterview eignet sich insbesondere dann, wenn der Interviewer mit dem Thema vertraut ist oder es gezielt eingrenzen kann. In beiden Fällen ermöglichen vorab formulierte Fragen eine strukturierte Gesprächsführung (vgl. (Porst, 2015, S. 95)). Das Experteninterview stellt eine besondere Form des Leitfadeninterviews dar, bei der der Fokus auf dem Fachwissen und der Praxiserfahrung der befragten Person liegt. Dies erlaubt es, zielgerichtete und komplexere Fragestellungen zu adressieren, die ausschließlich durch den Sachverstand eines Experten beantwortet werden können (vgl. (Baur und Blasius, 2022, S. 888–889)).

Nach Renner und Jacob lassen sich Interviews grundsätzlich in drei Formen unterteilen: hoch standardisierte, unstandardisierte sowie teilstandardisierte bzw. halbstrukturierte Interviews (vgl. (Renner und Jacob, 2020, S. 13–17)). Hoch standardisierte Interviews folgen einem strikten Ablaufplan, der weder in der Reihenfolge der Fragen noch in den vorgegebenen Antwortmöglichkeiten Abweichungen erlaubt, wodurch sie schnell und einfach durchführbar sind. Im Gegensatz dazu sind beim unstandardisierten Interview weder Fragen noch Antworten festgelegt, sondern lediglich Themen, die im Gesprächsverlauf frei vertieft werden können. Das teilstandardisierte bzw. halbstrukturierte Interview versucht schließlich, die Vorteile beider Formen zu vereinen: Es orientiert sich an einem Leitfaden mit vorab formulierten Fragen, lässt jedoch gleichzeitig Raum für ergänzende Fragen, die sich im Gesprächsverlauf ergeben. Damit schließt diese Form unmittelbar an das zuvor beschriebene Konzept des Leitfadeninterviews nach Porst an.

Der Leitfaden strukturiert den Ablauf aller Gespräche und ermöglicht so eine einheitliche Gesprächsführung. Er kann Erzählaufforderungen, vorformulierte Fragen sowie Stichpunkte enthalten und bei Bedarf auch Stimuli wie Bilder oder Geschichten einbeziehen. Dabei wird stets eine Balance zwischen Offenheit und Strukturiertheit angestrebt. Bei der Erstellung empfiehlt sich ein dreistufiges Vorgehen: Zunächst werden möglichst offene Fragen gestellt, die dem Befragten freie Antworten ermöglichen und so alle relevanten Informationen erschließen. Anschließend können gezielte Nachfragen zu Themen gestellt werden, die bisher unbeantwortet oder unzureichend behandelt wurden. Abschließend werden vorformulierte Fragen in einer logischen Reihenfolge an den Interviewten gerichtet (vgl. (Baur und Blasius, 2022, S. 881–883)).

Als Experten können Personen herangezogen werden, die über ein überdurchschnittliches, umfangreiches Wissen oder eine besondere fachliche Tiefe in einem bestimmten Bereich verfügen. Dies umfasst sowohl Insiderwissen, das für Außenstehende nur schwer zugänglich ist, als auch einen allgemein vertieften Wissensstand im jeweiligen Fachgebiet. Expertenwissen

beschränkt sich dabei nicht auf die Berufswelt: Auch Personen, die sich ein spezifisches Thema eigenständig erschlossen oder darin besondere Fähigkeiten entwickelt haben, können in diesen Bereichen als Experten gelten. Im Mittelpunkt der Interviews steht die fachliche Expertise der Befragten und nicht ihre persönliche Lebenssituation. Den Interviewpartnern wird dabei verdeutlicht, welche bedeutsame Rolle ihr Wissen für die Beantwortung der Forschungsfrage einnimmt (vgl. (Baur und Blasius, 2022, S. 887–888)).

4 Auswirkungen von KI-Textgenerierung auf die Wissensarbeit (Ergebnisse der Literaturanalyse)

Das folgende Kapitel stellt die Ergebnisse der durchgeführten Literaturanalyse dar und untersucht, wie KI-Textgenerierung die Wissensarbeit verändert. Dabei gliedert sich die Analyse in die drei Themenbereiche, die im Rahmen der Literaturanalyse in Kapitel 3 identifiziert wurden. Abschnitt 4.1 beleuchtet zunächst, inwiefern sich bestehende Arbeitsprozesse durch den Einsatz von KI verschieben. Darauf aufbauend analysiert Abschnitt 4.2, welche veränderten Anforderungen sich daraus für die Kompetenzprofile von Wissensarbeitenden ergeben. Abschließend zeigt Abschnitt 4.3, welche Chancen und Risiken sich aus diesen Veränderungen ergeben. Die drei Abschnitte bauen dabei aufeinander auf und ermöglichen so einen umfassenden Blick auf die Auswirkungen von KI-Textgenerierung auf die Wissensarbeit.

4.1 Veränderungen von Arbeitsprozessen

Die Literaturanalyse zeigt, dass KI-Textgenerierung die Arbeitsprozesse von Wissensarbeitenden auf mehreren Ebenen verändert. Im Folgenden werden vier zentrale Verschiebungen beschrieben, nämlich die Verlagerung von ausführenden hin zu assistierenden Tätigkeiten, die wachsende Bedeutung der Steuerung und Überwachung von KI-Prozessen, die funktionale Arbeitsteilung zwischen Mensch und Maschine sowie die veränderte Bewertungsgrundlage von Arbeit.

Verschiebung von Ausführung zu Assistenz

Die Literaturanalyse legt nahe, dass KI-Textgenerierung die Arbeitsprozesse von Wissensarbeitenden weniger durch eine vollständige Ablösung von Arbeitsplätzen verändert, sondern vielmehr bestehende Tätigkeiten und Aufgaben innerhalb von Rollen verschiebt. Dieses Bild zeigt sich sowohl in wissenschaftlichen Studien als auch in Praxis- und Beratungsberichten (vgl. (Carbonero, Ernst und Weber, 2023, S. 707-708); vgl. (Agrawal, Gans und Goldfarb, 2024, 327); vgl. (Brynjolfsson, Li und Raymond, 2025, 891, 901, 934-935); vgl. (Emerson *u. a.*, 2026, S. 1-2, 9-13); vgl. (Deloitte, 2026, S. 3-5, 8, 11-12, 32); vgl. (PwC Deutschland, 2026, S. 3-19)). Insbesondere routineorientierte Tätigkeiten wie Informationsrecherche, Texterstellung und Dokumentation werden den Quellen zufolge zunehmend durch KI unterstützt, woraus sich interpretieren lässt, dass sich der Arbeitsschwerpunkt stärker auf die Überprüfung, Bewertung und Integration von Ergebnissen verlagert (vgl. (Noy und Zhang, 2023, Abstract, S. 1, 3, 7); vgl. (Brynjolfsson, Li und Raymond, 2025, S. 890, 891); vgl. (Lee *u. a.*, 2025, S. 1-2); vgl. (Dell'Acqua *u. a.*, 2026, S. 403, 406, 419-420)). Bereits vor dem Aufkommen generativer KI zeigte sich, dass Wissensarbeitende einen erheblichen Teil ihrer Arbeitszeit für Routineaufgaben aufwenden, wodurch weniger Kapazität für Innovationen und Problemlösungen verbleibt

(vgl. (Haufe Online Redaktion, 2017)). Darüber hinaus deutet die Literatur darauf hin, dass KI überwiegend nicht als Ersatz, sondern als Assistenzsystem verstanden wird, das menschliche Arbeit ergänzt und erweitert. Daraus lässt sich schließen, dass zunehmend hybride Arbeitsformen entstehen, in denen menschliche und technologische Fähigkeiten gemeinsam eingesetzt werden (vgl. (Brynjolfsson, Li und Raymond, 2025, 891, 901, 934-935); vgl. (Dell'Acqua u. a., 2026, S. 403-404); vgl. (Lei und Kim, 2024, S. 252, 259); vgl. (Emerson u. a., 2026, S. 1-2, 9-13); vgl. (Deloitte, 2026, S. 3-5, 8, 11-12, 32); vgl. (PwC Deutschland, 2026, S. 3-19)).

Steuerung und Überwachung von KI-Prozessen

Diese Verlagerung hin zur Assistenzfunktion von KI geht mit einer grundlegenden Veränderung der Rolle von Wissensarbeitenden einher. Fast die Hälfte der Befragten gab an, dass sich ihre Rolle zunehmend dahin verschoben habe, KI zu steuern und anzuleiten, anstatt die eigentliche Arbeit selbst auszuführen (vgl. (Beauchene u. a., 2026, S.3)). Laut McKinsey werden in diesem Zuge neue Rollen erforderlich sein, unter anderem für LLM Selection and Management sowie für das Training und Management von GenAI-Agenten (vgl. (Hussin u. a., 2024, S.5)).

Diese Entwicklung zeigt sich auch in spezifischen Berufsfeldern. So verschiebt generative KI nach BCG die Tätigkeit von Softwareentwicklern weg von repetitiven Codieraufgaben hin zu System-Level Thinking, Orchestrierung sowie Produkt- und Designaufgaben, wobei menschliches Urteilsvermögen und Verantwortung weiterhin erforderlich bleiben (vgl. (Emerson u. a., 2026, S.8)). Auf organisationaler Ebene verweist Deloitte auf die Work-Orchestration-Plattform Gloat Mosaic als Beispiel für eine Lösung, die Fähigkeiten, Arbeitsaufgaben und Technologien integriert und Manager sowie Mitarbeitende dabei unterstützt, dynamisch zu entscheiden, ob Aufgaben von Menschen oder Maschinen übernommen werden sollten (vgl. (Cantrell u. a., 2025)).

Neben der Steuerung gewinnt dabei auch die Überwachung von KI-Prozessen an Bedeutung. McKinsey argumentiert, dass die Automatisierung einfacher Tätigkeiten Beschäftigten ermöglicht, sich komplexeren Aufgaben zuzuwenden, die menschliches Urteilsvermögen, Aufsicht und den Umgang mit Mehrdeutigkeit erfordern. Zugleich verweist McKinsey auf eine Studie mit 1.488 US-Beschäftigten, nach der eine intensive Überwachung von KI-Systemen zu kognitiver Ermüdung beitragen kann (vgl. (Metakis u. a., 2026)). BCG erwartet in diesem Zusammenhang, dass durch KI neugestaltete Rollen höhere Anforderungen an Fachwissen, Aufsicht und Verantwortlichkeit stellen werden, wobei insbesondere Aufgaben bestehen bleiben, die kontextbezogenes Urteilsvermögen, Koordination und Oversight-Fähigkeiten erfordern (vgl. (Emerson u. a., 2026, S. 11-12, 15)). McKinsey betont ergänzend, dass mit der Einführung generativer KI neue Rollen und Verantwortlichkeiten entstehen, darunter LLMOps-Fähigkeiten zur langfristigen Überwachung der Modelleleistung sowie eine stärkere Führungsaufsicht darüber, wie sich Rollen und Arbeitsweisen anpassen müssen (vgl. (Hussin u. a., 2024, S. 5)). PwC hebt schließlich hervor, dass Organisationen nicht nur KI-Kompetenzen innerhalb

der Belegschaft aufbauen, sondern auch ihre Integrations-, Governance- und Vendor-Management-Fähigkeiten stärken müssen, um KI-Lösungen gezielt steuern zu können (vgl. (PwC Deutschland, 2026, S. 17, 19)).

Routine für KI, Ausnahmen für Menschen

Mit der Verlagerung hin zu steuernden Tätigkeiten verändert sich auch das konkrete Verhältnis zwischen menschlicher und maschineller Aufgabenbearbeitung. Dabei zeigt sich, dass LLMs häufig strikt an vorgegebene Richtlinien gebunden bleiben, selbst wenn deren Anwendung im konkreten Kontext unpraktisch oder kontraproduktiv ist. Diese Inflexibilität wird auf eine mechanistische Interpretation von Regeln zurückgeführt, während menschliche Entscheidungen häufiger kontextabhängige Anpassungen berücksichtigen. Der Umgang mit Ausnahmen stellt daher eine Form adaptiver Entscheidungsfindung dar, die nuanciertes Urteilsvermögen erfordert (vgl. (DiSorbo, Ju und Aral, 2025, S. 1,3,14)).

Daraus ergibt sich eine funktionale Arbeitsteilung zwischen Mensch und Maschine. Rollen mit offenen Problemlösungen und häufigen Ausnahmen werden laut der Analyse eher durch KI ergänzt als ersetzt, da sie weiterhin menschliches Urteilsvermögen erfordern. Am Beispiel von Call-Centern zeigt sich eine mögliche Aufgabenteilung, bei der KI standardisierte Erstinteraktionen übernimmt, während Menschen Eskalationen und Ausnahmefälle bearbeiten. Gleichzeitig könnten Einstiegsrollen neu gestaltet werden und früher als bisher Aufgaben wie die Überwachung von KI-Systemen, das Management von Ausnahmen und komplexere Problemlösungen umfassen (vgl. (Emerson *u. a.*, 2026, S. 3-7, 15)). In der Praxis bedeutet dies, dass durch den Einsatz von KI Mitarbeitende zwar von einfachen, wiederkehrenden Anfragen entlastet werden, ihre Tätigkeit sich jedoch stärker hin zu komplexen und eskalierten Fällen verschiebt. Während KI das Grundrauschen einfacher Aufgaben übernimmt, verbleiben bei Menschen die anspruchsvolleren Fälle, wodurch die kognitive Intensität der Arbeit steigen kann (vgl. (Brassey *u. a.*, 2026)).

Qualität statt Geschwindigkeit

Die veränderte Aufgabenteilung zwischen Mensch und KI hat nicht nur Auswirkungen auf die Art der Tätigkeiten, sondern auch auf den Maßstab, nach dem Arbeit bewertet wird. Während in klassischen Arbeitsprozessen Effizienz oft als zentrales Kriterium galt, rückt mit dem Einsatz von KI zunehmend die Ergebnisqualität in den Vordergrund. Hintergrund hierfür ist, dass Machine-Learning-Code im Gegensatz zu klassischem Softwarecode nicht auf deterministischen Wenn-Dann-Regeln basiert, sondern auf statistischen Verfahren. Aufgrund seines nicht-deterministischen Charakters kann dieselbe Eingabe zu unterschiedlichen Ausgaben führen, was ML-Systeme grundlegend von deterministischen Programmen unterscheidet (vgl. (Hu *u. a.*, 2022, S.2-3,7-8)). Ergänzend dazu werden KI-Halluzinationen als ein inhärentes technisches

Merkmal der probabilistischen Generierungsmechanismen großer Sprachmodelle eingeordnet (vgl. (Cheng *u. a.*, 2026, S.1)).

Dieser nicht-deterministische Charakter schlägt sich in einem Spannungsverhältnis zwischen Effizienz und Verantwortlichkeit nieder. Nutzer bevorzugen in praktischen Anwendungssituationen häufig direkte und schnell umsetzbare Antworten gegenüber einem tieferen Verständnis der zugrunde liegenden Entscheidungsprozesse. Eine starke Effizienzorientierung kann jedoch das Risiko einer übermäßigen Abhängigkeit von KI-Systemen erhöhen, wodurch die kritische Bewertung von KI-generierten Ergebnissen beeinträchtigt werden kann (vgl. (Spatola, 2024, S.1-2,5)). Ebenso zeigt sich, dass eine Steigerung der Bearbeitungsgeschwindigkeit nicht zwangsläufig zu einer Verbesserung der Qualität der Ergebnisse führt (vgl. (Spivack *u. a.*, 2024, S.5)).

Folgerichtig verändert der Einsatz von KI die Rolle von Wissensarbeitenden in Richtung einer stärkeren Qualitätssicherung. Im Bereich der Softwareentwicklung beispielsweise müssen Entwickler zunehmend als Reviewer agieren und KI-generierten Code hinsichtlich Fehlern, Kompatibilität und Wartbarkeit bewerten, was erweiterte Fähigkeiten zur Analyse und Qualitätssicherung erfordert (vgl. (Hussin *u. a.*, 2024, S.3-4)). Dabei steigen auch die allgemeinen Erwartungen an Arbeitsergebnisse. Befragte geben an, dass die Anforderungen an das, was als ausreichend gilt, gestiegen sind, und 52 % berichten, dass sie mehr Zeit für die Überprüfung und Korrektur von KI-generierten Ergebnissen aufwenden (vgl. (Beauchene *u. a.*, 2026, S.17)). In sicherheitskritischen Bereichen können KI-Halluzinationen darüber hinaus erhebliche Auswirkungen haben, etwa wenn fehlerhafte diagnostische Vorschläge im Gesundheitswesen klinische Risiken erhöhen oder in anderen Bereichen durch notwendige Überprüfungen zusätzliche Aufwände entstehen (vgl. (Cheng *u. a.*, 2026, S. 4)). Schließlich zeigt sich, dass für die Ausrichtung von LLMs an menschlichem Urteilsvermögen nicht nur entscheidend ist, welche Entscheidungen getroffen werden, sondern auch, wie diese zustande kommen, wobei insbesondere das Training mit menschlichen Erklärungen eine wichtige Rolle spielt (vgl. (DiSorbo, Ju und Aral, 2025, S.1-2)).

Zusammenfassend lässt sich aus den gesichteten Quellen ableiten, dass KI-Textgenerierung die Wissensarbeit nicht durch Stellenabbau verändert, sondern durch eine mehrstufige Verschiebung von Tätigkeitsschwerpunkten. Routineaufgaben werden zunehmend durch KI übernommen, während Wissensarbeitende stärker in steuernde, überwachende und bewertende Rollen wechseln. Dabei entsteht eine funktionale Arbeitsteilung, in der KI standardisierbare Prozesse abwickelt und der Mensch Ausnahmen, Qualitätssicherung und kontextabhängige Entscheidungen verantwortet. Da KI-Systeme nicht deterministisch arbeiten und zu Halluzinationen neigen, verschiebt sich der Bewertungsmaßstab von Effizienz hin zur Ergebnisqualität. Die Verantwortung für die Richtigkeit und Verwendbarkeit von Arbeitsergebnissen verbleibt damit beim Menschen.

4.2 Veränderungen der Kompetenzprofile

Die in Abschnitt 4.1 beschriebenen Verschiebungen in den Arbeitsprozessen ziehen veränderte Anforderungen an die Kompetenzprofile von Wissensarbeitenden nach sich. Die Literaturanalyse identifiziert dabei vier zentrale Themenbereiche, nämlich die steigende Bedeutung von KI-Kompetenz und kritischem Denken, den wachsenden Wert impliziten Erfahrungswissens, die Relevanz von Fachkompetenz und kontextuellem Urteilsvermögen sowie die Notwendigkeit kontinuierlichen Lernens und der Requalifizierung.

KI-Kompetenz und kritisches Denken

Die Analyse der Literatur zeigt, dass sich durch KI-Textgenerierung nicht nur Arbeitsprozesse verändern, sondern auch die Anforderungen an die Kompetenzprofile von Wissensarbeitenden. Über nahezu alle Quellen hinweg lässt sich erkennen, dass technologische Kompetenzen zunehmend durch menschliche Fähigkeiten ergänzt werden müssen und künftig nicht mehr allein fachliches Wissen über den beruflichen Erfolg entscheidet (vgl. (Lee u. a., 2025, S.1); vgl. (Gerlich, 2025, 1-2, 14)). Besonders häufig zeigt sich dabei die steigende Bedeutung von KI-Kompetenz. Den Quellen zufolge müssen Wissensarbeitende lernen, KI-Systeme effektiv einzusetzen, ihre Ergebnisse zu interpretieren sowie deren Grenzen und Risiken zu verstehen (vgl. (Rafi u. a., 2024, S. 1-2, 7); vgl. (Emerson u. a., 2026, S. 15, 18-19); vgl. (Deloitte, 2026, S. 3-5, 8, 11-12, 32)). Da KI-generierte Inhalte Fehler, Verzerrungen oder Halluzinationen enthalten können, lässt sich daraus schließen, dass kritisches Denken und menschliche Urteilskraft nicht an Bedeutung verlieren, sondern im Gegenteil unverzichtbar bleiben (vgl. (Lee u. a., 2025, S. 12, 15-16); (Brynolfsson, Li und Raymond, 2025, S. 897); vgl. (Dell'Acqua u. a., 2026, S. 3); vgl. (Woodruff u. a., 2024, S. 7 und 23)).

Erfahrungswissen als Wettbewerbsvorteil

Neben explizit vermittelbaren Kompetenzen wie KI-Literacy rückt mit dem Aufkommen von KI auch eine weniger greifbare Wissensform in den Fokus, nämlich das implizite Erfahrungswissen. Explizites Wissen bezeichnet Wissen, das leicht dokumentiert, formalisiert und kommuniziert werden kann, beispielsweise in Form von Anleitungen oder Rezepten. Implizites Wissen basiert dagegen auf persönlicher Erfahrung, Intuition und situativem Verständnis und lässt sich nur schwer verbalisieren oder vollständig kodifizieren, wie etwa die Fähigkeit, beim Fahrradfahren das Gleichgewicht zu halten (vgl. (Atakishiyev u. a., 2025, S. 14); (Lu, 2025, S. 9)). Dabei handelt es sich häufig um Wissen, dessen Besitz oder Erwerb den Handelnden nicht vollständig bewusst ist (vgl. (Atakishiyev u. a., 2025, S. 14); (Lu, 2025, S. 1, 7)). Implizites Wissen umfasst dabei drei Formen. Erstens gibt es Wissen, das zwar theoretisch kodifizierbar wäre, dessen Überführung in explizite Information jedoch zu kostspielig ist. Zweitens zählt dazu Wissen über sprachliche Nuancen und Subtexte. Drittens gehört verkörpertes Wissen dazu, das durch sensorische Erfahrungen erworben wird (vgl. (Lu, 2025, S. 1-2)).

Genau an diesem Punkt stoßen LLMs an ihre Grenzen. Sie basieren auf Repräsentationsmodellen, die Muster aus großen Mengen textueller Daten lernen und diese für Sprachgenerierung und Verständnis nutzen. Da ein Teil des impliziten Wissens subjektiv, erfahrungsbasiert und kaum textualisiert ist, stellt dessen Erfassung durch LLMs eine besondere Herausforderung dar (vgl. (Atakishiyev *u. a.*, 2025, S. 14); (Lu, 2025, S. 2)). Besonders deutlich wird dieser Unterschied im Bereich des verkörperten Wissens, denn während LLMs sprachliche Muster und Zusammenhänge aus Trainingsdaten lernen können, verfügen sie nicht über physische Erfahrungen oder sensorische Interaktionen mit der Welt und können daher beispielsweise Kälte beschreiben, ohne jemals körperlich zu frieren (vgl. (Lu, 2025, S. 2, 10, 17)). Kritiker argumentieren darüber hinaus, dass LLMs lediglich statistische Zusammenhänge in Textdaten erfassen und keine menschliche Form von semantischem Verständnis besitzen (vgl. (Lu, 2025, S. 6-7)).

Daraus ergibt sich, dass implizites Erfahrungswissen durch die Verbreitung von KI nicht an Wert verliert, sondern im Gegenteil an Bedeutung gewinnt. KI kann bestehendes Wissen erweitern und Aufgaben beschleunigen, ersetzt jedoch nicht vollständig menschliches Urteilsvermögen, Mustererkennung und implizites Wissen, die durch wiederholte praktische Erfahrung in realen Situationen entstehen (vgl. (Brassey *u. a.*, 2026)). Menschen können zudem bei bestimmten Aufgaben weiterhin einen komparativen Vorteil besitzen, insbesondere wenn für das Training von KI-Modellen nicht ausreichend aufgezeichnete Daten verfügbar sind oder deren Erhebung wirtschaftlich nicht sinnvoll wäre (vgl. (Lu, 2025, S. 16)).

Fachkompetenz und kontextuelles Urteilsvermögen

Eng verbunden mit dem Wert impliziten Wissens ist die Frage, welche Fachkompetenzen künftig besonders gefragt sind. Während stark strukturierte und wiederholbare Tätigkeiten eher für eine Automatisierung geeignet sind, bleiben Rollen mit offenen Problemlösungen und häufigen Ausnahmen stärker auf menschliches Urteilsvermögen angewiesen und werden daher eher durch KI augmentiert als ersetzt. Mitarbeitende können dabei als Eskalationsschicht fungieren, wenn KI-Agenten komplexe Fälle oder Ausnahmesituationen nicht bewältigen können (vgl. (Emerson *u. a.*, 2026, S.4, 16)). McKinsey zeigt in diesem Zusammenhang, dass stark KI-exponierte Rollen Aufgaben mit menschlich geprägten Fähigkeiten wie Empathie, Urteilsvermögen und Kreativität 2,5-mal schneller aufnehmen als weniger KI-exponierte Rollen (vgl. (Brassey *u. a.*, 2026)).

Besondere Bedeutung kommt dabei dem kontextuellen Urteilsvermögen zu. KI kann zwar strukturierte Aufgaben übernehmen und Prozesse beschleunigen, ersetzt jedoch nicht vollständig das menschliche Urteilsvermögen, das für die Interpretation emotionaler und sozialer Hinweise sowie für kontextabhängige Entscheidungen notwendig ist. Besonders Rollen mit hohen Anforderungen an Interaktion, Vertrauen und kontextuelles Urteil werden daher eher durch KI ergänzt als ersetzt (vgl. (Emerson *u. a.*, 2026, S. 7-8, 11-12)). Da bestimmte Fähig-

keiten wie Problemlösung, Urteilsvermögen und der Umgang mit organisationsspezifischem Wissen schwer formal zu vermitteln sind, gewinnen zudem Lehrlingsmodelle und Mentoring an Bedeutung, bei denen erfahrene Experten durch praktische Zusammenarbeit und Vorbildfunktion institutionelles Wissen sowie schwer vermittelbare Kompetenzen an jüngere Mitarbeitende weitergeben (vgl. (Hussin u. a., 2024, S. 8)).

Kontinuierliches Lernen und Requalifizierung

Angesichts der beschriebenen Verschiebungen in Arbeitsprozessen und Kompetenzprofilen stellt sich schließlich die Frage, wie Wissensarbeitende und Organisationen auf diese Veränderungen reagieren können. Der zunehmende Einsatz von KI wird erhebliche Veränderungen der Arbeitswelt bewirken. Schätzungen zufolge werden in den nächsten zwei bis drei Jahren etwa 50 % bis 55 % der Arbeitsplätze in den USA durch KI verändert. Für viele Beschäftigte bedeutet dies keine vollständige Ersetzung ihrer bisherigen Tätigkeit, sondern eine Veränderung der Arbeitsanforderungen und Aufgabenprofile. Unternehmen stehen daher vor der Herausforderung, strategische Maßnahmen zur Weiterbildung und Umschulung ihrer Mitarbeitenden zu entwickeln (vgl. (Emerson u. a., 2026, S.1,13)).

Der Bedarf an Weiterbildung wird von vielen Beschäftigten als zunehmend relevant wahrgenommen. So geben 88 % der Befragten an, dass sie in den nächsten fünf Jahren eine umfassende Weiterqualifizierung benötigen, während sich lediglich 36 % als ausreichend geschult einschätzen (vgl. (Beauchene u. a., 2026, S.11-13)). Aufgrund der kontinuierlichen Weiterentwicklung von KI-Technologien wird Weiterbildung dabei nicht als einmalige Maßnahme ausreichen, sondern Beschäftigte werden voraussichtlich häufiger Weiterqualifizierungen benötigen, um ihre Fähigkeiten an veränderte Anforderungen anzupassen (vgl. (Emerson u. a., 2026, S.18)). Die Einführung von KI-Systemen erfordert darüber hinaus nicht nur die Weiterentwicklung technischer Kompetenzen, sondern auch den Erhalt der kognitiven Leistungsfähigkeit der Beschäftigten. Das Konzept des Brain Capital betrachtet Gehirngesundheit und geistige Fähigkeiten als strategische Ressource. Ohne entsprechende Maßnahmen besteht das Risiko kognitiver Überlastung, insbesondere wenn Weiterbildungs- und Transformationsprozesse zusätzliche Anforderungen schaffen, ohne ausreichende Kapazitäten und Erholungsphasen zu berücksichtigen (vgl. (Brassey u. a., 2026)).

Zusammenfassend verdeutlicht die Literaturanalyse, dass sich die Kompetenzanforderungen an Wissensarbeitende in mehrere Richtungen gleichzeitig verschieben. KI-Kompetenz und kritisches Denken werden zur Grundvoraussetzung, da KI-generierte Inhalte stets bewertet und hinterfragt werden müssen. Gleichzeitig gewinnt implizites Erfahrungswissen an Wert, weil LLMs auf explizitem Textwissen basieren und situatives Urteilen, verkörpertes Wissen und kontextabhängige Entscheidungen nicht replizieren können. Tiefe Fachkompetenz bleibt erforderlich, um Ausnahmen zu erkennen und KI-Ausgaben gegen Erfahrungswissen zu prüfen. Da sich diese Anforderungen kontinuierlich weiterentwickeln, wird nicht mehr allein fachliches

Wissen, sondern die Fähigkeit zur dauerhaften Requalifizierung zum entscheidenden Merkmal zukunftsfähiger Wissensarbeit.

4.3 Chancen und Risiken

Aus den in Abschnitt 4.1 und 4.2 beschriebenen Veränderungen ergeben sich sowohl Chancen als auch Risiken für Wissensarbeitende.

Chancen

Eine zentrale Chance ergibt sich aus der in Abschnitt 4.1 beschriebenen Entlastung von Routinetätigkeiten. Da KI standardisierbare Aufgaben zunehmend übernimmt, gewinnen Wissensarbeitende zeitliche Kapazitäten für komplexere und wertschöpfende Tätigkeiten, sodass mehr Raum für strategisches Denken, Ideenentwicklung und kreative Problemlösung entsteht.

Eine weitere Chance liegt in der Stärkung menschlicher Kernkompetenzen. Wie in Abschnitt 4.2 gezeigt, können LLMs implizites Erfahrungswissen, kontextuelles Urteilsvermögen und situatives Entscheiden nicht replizieren. Der Mensch bleibt in komplexen Ausnahmesituationen daher unverzichtbar, und genau diese Kompetenzen gewinnen durch den KI-Einsatz an Sichtbarkeit und Wert.

Darüber hinaus eröffnet die in Abschnitt 4.1 beschriebene Mensch-KI-Kollaboration neue Möglichkeiten der Aufgabenverteilung. Organisationen können Prozesse flexibler gestalten, indem KI standardisierte Erstinteraktionen übernimmt und Menschen sich auf Eskalationen, Ausnahmen und Entscheidungen mit hohem Kontextbedarf konzentrieren.

Risiken

Den Chancen stehen jedoch erhebliche Risiken gegenüber. Ein zentrales Risiko besteht in Fehlentscheidungen durch unkritische KI-Nutzung. Wie in Abschnitt 4.1 dargelegt, arbeiten KI-Systeme nicht deterministisch und neigen zu Halluzinationen. Wer KI-generierte Ergebnisse ungeprüft übernimmt, riskiert inhaltlich falsche Ausgaben als Grundlage für Entscheidungen zu verwenden. Da die Verantwortung für Ergebnisqualität beim Menschen verbleibt, stellt die fehlende kritische Prüfung ein strukturelles Risiko dar, das mit zunehmendem KI-Einsatz an Gewicht gewinnt.

Ein weiteres Risiko betrifft den Kompetenzaufbau bei Berufsanfängern. KI bietet weniger erfahrenen Beschäftigten kurzfristig die Möglichkeit, Aufgaben schneller und mit besseren Ergebnissen zu bearbeiten, sodass Leistungsunterschiede zu erfahrenen Mitarbeitenden zunächst sinken. Gleichzeitig sind es genau diese Einstiegsaufgaben, über die Berufsanfänger traditionell praktische Erfahrung und implizites Wissen aufbauen. Wie in Abschnitt 4.2 beschrieben, lässt sich implizites Erfahrungswissen nur durch wiederholte Praxis in realen Situationen

entwickeln. Werden diese Aufgaben durch KI automatisiert, entfällt dieser Lernpfad, sodass der kurzfristige Leistungsgewinn langfristig auf Kosten des Kompetenzaufbaus gehen kann.

Schließlich besteht das Risiko einer wachsenden Qualifikationslücke. Der in Abschnitt 4.2 beschriebene Bedarf an kontinuierlicher Requalifizierung trifft nicht alle Beschäftigten gleichermaßen. Wer KI-Kompetenz, kritisches Denken und die Bereitschaft zur dauerhaften Weiterentwicklung nicht aufbaut, läuft Gefahr, mit den veränderten Anforderungen nicht Schritt halten zu können. Zugleich besteht das Risiko kognitiver Überlastung, wenn Weiterbildungs- und Transformationsprozesse zusätzliche Anforderungen schaffen, ohne ausreichende Kapazitäten zu berücksichtigen.

Zusammenfassend zeigt sich, dass die durch KI ausgelösten Veränderungen in Arbeitsprozessen und Kompetenzprofilen weder ausschließlich positiv noch ausschließlich negativ zu bewerten sind. Die Chancen liegen vor allem in der Entlastung von Routinetätigkeiten, der Aufwertung menschlicher Kernkompetenzen und flexibleren Formen der Zusammenarbeit. Dem gegenüber stehen Risiken durch unkritische KI-Nutzung, den Wegfall klassischer Lernpfade für Berufsanfänger und eine wachsende Qualifikationslücke. Entscheidend wird sein, ob Wissensarbeitende und Organisationen die notwendigen Kompetenzen und Strukturen aufbauen, um KI verantwortungsvoll einzusetzen und die menschliche Urteilskraft dauerhaft zu erhalten.

5 Experteninterviews, Diskussion und Handlungsempfehlungen

[Text]

5.1 Durchführung und Auswertung der Interviews

Zur Beantwortung der Forschungsfrage wurden ergänzend zur Literaturanalyse leitfadengestützte Experteninterviews durchgeführt. Als Grundlage für die Gespräche diente ein Interviewleitfaden, der im Rahmen der Vorbereitung entwickelt wurde und im Anhang in Abbildung 1 eingesehen werden kann. Parallel dazu wurden geeignete Interviewpartner aus dem Unternehmensumfeld von SAP identifiziert, kontaktiert und die Gesprächstermine koordiniert.

Durchführung der Experteninterviews

Im Vorfeld jedes Interviews wurden die Teilnehmenden über die Zielsetzung und den Kontext der Arbeit informiert, um einen gemeinsamen Ausgangspunkt zu schaffen. Die Interviews fanden jeweils unabhängig voneinander in Form von Videokonferenzen statt und dauerten durchschnittlich ca. 30 Minuten. Um einen natürlichen Gesprächsfluss zu ermöglichen, wurde die Reihenfolge der Fragen flexibel gehandhabt. Mit ausdrücklicher Zustimmung der Teilnehmenden wurden die Gespräche aufgezeichnet, sodass eine sorgfältige Auswertung im Nachgang möglich war. Darüber hinaus wurden die Teilnehmenden zu Beginn des Gesprächs darauf hingewiesen, dass ihre Aussagen sowie ihre Person vollständig anonymisiert behandelt werden.

Auswertung der Experteninterviews

5.2 Diskussion der Ergebnisse im Abgleich mit der Literatur

[Text]

5.3 Limitationen der Untersuchung

[Text]

5.4 Handlungsempfehlungen

[Text]

6 Fazit und Ausblick

[Text]

6.1 Zusammenfassung der Ergebnisse

[Text]

6.2 Ausblick

[Text]

Anhang

A1: Übersicht eingesetzter KI-Werkzeuge

Werkzeug	Beschreibung der Nutzung
ChatGPT	• Sprachliche Überarbeitung und Umformulierung von Textpassagen zur Verbesserung der Ausdrucksweise (gesamt) • Erstellung von BibTeX-Einträgen für das Literaturverzeichnis auf Basis bibliografischer Angaben (gesamt)
Claude (Anthropic)	• Vorschläge zu wissenschaftlicher Fachliteratur und relevanten Quellen im Themenfeld KI und Wissensarbeit (gesamt) • Übersetzung von Textpassagen und Fachbegriffen vom Deutschen ins Englische (gesamt) • Inhaltliche Rückfragen zu Konzepten und Begriffsdefinitionen zur eigenen Einschätzung (gesamt)
NotebookLM (Google)	• Erstellung einer strukturierten Übersicht über die verwendeten Quellen und deren Kerninhalte (gesamt) • Abgleich von Textaussagen mit den zugehörigen Quellenbelegen zur Konsistenz- und Zitatprüfung (gesamt) • Zusammenfassung und Erschließung längerer wissenschaftlicher Dokumente (gesamt)
Elicit	• Systematische Literaturrecherche zu wissenschaftlichen Studien und Forschungsergebnissen im Themenfeld KI-gestützte Textgenerierung und Wissensarbeit (Kapitel 2 und 3) • Identifikation thematisch relevanter Publikationen anhand von Forschungsfragen (Kapitel 2 und 3)

Tabelle 1: Übersicht über die Nutzung von KI-basierten Werkzeugen

Interviewleitfaden: LLMs in der Wissensarbeit bei SAP

Interviewleitfaden: KI Tools in der Wissensarbeit bei SAP

Datum und Uhrzeit: xx.xx.xxxx um xx:xx Uhr	Ort: Microsoft Teams Besprechung
Befragter: xxx	Interviewer: Anton Nguyen

Alle Daten werden anonymisiert behandelt und nicht weitergegeben. Die Arbeit ist nur meinem wissenschaftlichen Betreuer an der DHBW Ravensburg sowie ausgewählten Kollegen intern bei SAP zugänglich.

	Inhaltliche Aspekte	Nachfragen mit obligatorischer Formulierung
Erzählauf-forderung	Würdest du dich zu Beginn kurz vorstellen und etwas über deinen beruflichen Hintergrund und deine aktuellen Aufgaben erzählen?	
Erzählauf-forderung	Wie häufig nutzt du interne KI Tools wie den MS Copilot Unternehmenschat, GenAI XL, Claude oder EKX in deinem Arbeitsalltag, regelmäßig, gelegentlich oder eher selten oder gar nicht?	<i>Falls regelmäßig: Wofür genau setzt du sie ein, und gibt es Aufgaben, bei denen du sie besonders häufig nutzt? Falls selten oder gar nicht: Was sind die Gründe dafür?</i>
Erzählauf-forderung	Was hält dich, oder Kolleg:innen in deinem Bereich, davon ab, diese Tools stärker zu nutzen?	<i>Liegt das eher an fehlendem Vertrauen, fehlender Schulung, ungeeigneten Aufgaben, technischen Hürden oder anderen Gründen?</i>
Erzählauf-forderung	Was hat sich bei deiner Arbeit konkret verändert, seit du diese Tools nutzt, beziehungsweise was müsste sich ändern, damit du sie stärker einsetzt?	<i>Was hat sich dadurch für dein Team oder deine Abteilung verändert?</i>
Erzählauf-forderung	Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist oder ob du sie lieber selbst übernimmst?	<i>Fällt dir ein konkretes Beispiel aus deinem Bereich dazu ein?</i>
Erzählauf-forderung	KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	<i>Hattest du selbst schon einmal so eine Situation? Was ist passiert, und wie bist du damit umgegangen?</i>
Erzählauf-forderung	Worauf achtest du beim Thema Datenschutz und Vertraulichkeit, wenn du diese Tools bei SAP nutzt?	<i>Gibt es dazu klare Vorgaben oder Regeln in deinem Bereich?</i>
Erzählauf-forderung	Prüfst und überarbeitest du inzwischen mehr KI generierte Inhalte, statt Dinge komplett selbst von null zu erstellen?	<i>Was musstest du dafür neu lernen, oder welche Fähigkeiten sind dadurch wichtiger geworden?</i>
Erzählauf-forderung	Hast du manchmal das Gefühl, dass du dich zu sehr auf die Tools verlässt und dadurch etwas verlernst?	
Erzählauf-forderung	Wo bringt dir KI am meisten Zeitvorteile oder Qualitätsvorteile, und wo stößt sie an ihre Grenzen?	<i>Fallen dir weitere Vorteile oder Nachteile ein, die wir noch nicht angesprochen haben?</i>
Erzählauf-forderung	Was sollte SAP als Unternehmen tun, damit die Vorteile genutzt werden, ohne dass die Risiken überhandnehmen?	<i>Was würdest du speziell für deinen eigenen Bereich empfehlen?</i>
Ab-schluss-frage:	Gibt es sonst noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist und das wir noch nicht besprochen haben?	

Abbildung 1: Interviewleitfaden: KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person A

Gesprächsprotokoll	Interview Person A 30.07.2026, 11:00-11:30 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	• 4-5 Jahre bei PCG; Hintergrund in Recruiting (Daimler/Mercedes-Benz, Amazon, Deutsche Bahn) und PM bei SAP (HANA Data & Analytics) • Aktuell PM im CISE-Projekt - Transformation von zwei Support-Einheiten • Bringt PCG-Konzepte zu Rollen-Snapshots, Zusammenführungen und Retrospektiven ein
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	• Regelmäßig, täglich • EKX -> hauptsächlich für PowerPoint-Präsentationen • MS Copilot -> E-Mail-Formulierungen, Texte polieren • Teams Premium -> automatische Meeting-Summaries -> Weitergabe an Copilot zur Analyse (z.B. unbekannte Fachbegriffe wie „Omnichannel Routing“ erklären lassen)
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	• Person A selbst hält nichts davon ab • Kolleg:innen: Wissenslücken über Tool-Funktionsweise; fehlende Einsicht in den Nutzen • Zeitargument: Nachkontrolle kostet Zeit; Unsicherheit bzgl. Datenschutz • Fehlende Prompting-Kompetenz -> schlechte Ergebnisse
Was hat sich konkret verändert, bzw. was müsste sich ändern?	• Delegiert administrative PM-Aufgaben an KI -> mehr Zeit für strategisch-inhaltliche Themen • Wunsch: PII-Daten auch in EKX erlaubt; bessere Tool-Integration (Teams Summary -> Copilot -> Auto-Action-Items + E-Mail) • Einschränkung: Halluzinationsgefahr macht umfangreiche Aufgaben weiterhin zeitaufwendig
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	• Geeignet: E-Mails, Texte, Präsentationen • Nicht geeignet: langer E-Mail-Vorkontext, Prioritätenabhängigkeiten, Empathie/Teamdynamik, finanzielle/zeitliche Impacts • Bsp.: Workshop-Agenden mit individuellen Teilnehmenden-Hintergründen - dafür ist KI nicht gemacht
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	• Irischer Kollege mit starkem Akzent falsch transkribiert -> Copilot erfand wiederholt „Paris-Projekt“ • Person A musste 90-Min.-Meeting vollständig abhören, um Fehlerquelle zu finden • Umgang: Suchfunktion, Video zurückspringen, kritisch gegenlesen - „Du kannst dem Tool nicht blind vertrauen“
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	• Grünes SAP-internes Symbol bei Copilot beachten; kein PII in EKX eingeben • Richtlinien nicht auf einer zentralen Seite konsolidiert; Wissenstand ggf. veraltet • Wunsch: zentrale Übersichtsseite oder KI-Tool, das Datenschutzfragen beantwortet
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	• Wichtigste neue Fähigkeit: Prompting - Scope definieren, Ergebnis challengen • Kritisches Prüfen des Outputs; gezielte Tool-Auswahl • Nutzt Claude bewusst nicht - Oberfläche zu technisch; bevorzugt Copilot • „Es gibt nicht das eine richtige Tool - jeder muss seinen Weg finden“
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	• Bei Person A nicht - lernt bei unbekannten Themen (z.B. Go-Live-Testing) durch KI dazu • Kolleginnen aus Assistenzbereichen berichten jedoch, E-Mails nach intensiver KI-Nutzung nicht mehr alleine schreiben zu können
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	• Vorteile: Administrative Aufgaben beschleunigt, strategisch relevanter arbeiten, weniger Routinearbeit • Grenzen: Halluzinationen, fehlende Tool-übergreifende Kommunikation, kein Kontextverständnis, keine Empathie
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	• Zentrale Übersichtsseite: welches Tool wofür, was darf eingegeben werden • Automatischer PII-Guard; regelmäßige interne Kommunikation über neue Möglichkeiten • PCG-spezifisch: KI-Best-Practice-Katalog team- und bereichsübergreifend teilen
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	• KI-Nutzung stark isoliert je Team - Wunsch: PCG-weiter Überblick, welche Teams welche Tools wie einsetzen • Kontrast: Bei SAP KI fast erwartet; in anderen Unternehmen wurden ChatGPT-Übersetzungen als Abmahnungsgrund behandelt

Tabelle 2: Gesprächsprotokoll: Interview mit Person A — KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person B

Gesprächsprotokoll	Interview Person B 30.07.2026, 13:15-13:45 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	• Projekte im Bereich Support und Support Operations bei PCG; ca. 15 Jahre in der Gruppe • Hintergrund: externer Consultant in 4 Firmen (Bankbereich, technische Seite), dann SAP Systems Integration, Global Process Office, CEO Area Internal Consulting • Aktuell: Entitlement Checks für Partnerprodukte, Customer Support Profiles (Nachbarprojekt zu Support Rewired) sowie interne Projekte zu KI-Tools
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	• Sehr regelmäßig • PM-Aufgaben: Projekte aufsetzen, Work-Breakdown-Structures entwickeln, Planung starten • Brainstormen und kritische Durchsicht von Präsentationsfolien - KI als Sparring-Partner • Gelegentlich als Lern-Tutor bei neuen Themen; Prozessmodellierung mit KI-Tools in Signavio
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	• Person B selbst kaum durch Schulung gehemmt; in Expertenbereichen (Datenmodellierung, Datenanalyse) sind aber bessere KI-Kenntnisse nötig • Stärkere Nutzung kommt mit stärkeren Tool-Fähigkeiten und der Möglichkeit, Agenten aufzubauen • Für Agentic AI fehlen noch Kurse (z.B. Joule Studio)
Was hat sich konkret verändert, bzw. was müsste sich ändern?	• Zeit wird frei -> mehrere Projekte gleichzeitig einfacher zu betreuen; Qualität steigt • Gegenpol: KI-Ergebnisse müssen immer geprüft werden, was Zeit kostet (teilweise Kompensation) • Im Team: große Unterschiede in KI-Affinität; Person B wird häufig von Kollegen um Rat gefragt
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	• Formulierungsaufgaben: sehr geeignet, spart schnell Zeit • Komplexe Zusammenhänge: Einzelaspekte eingeben, KI verknüpft und reichert mit Wissen an • Projektplanung: Infos von Stakeholdern zusammenfassen lassen - funktioniert sehr gut • Recherche und Einarbeitung in neue Themen als Tutor - hilft, „5 Minuten Vorsprung vor dem Kunden“ zu erreichen
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	• Früher: KI rechnete falsch oder schrieb Zahlen ohne Berechnung hin; Bildgenerierung mit vielen Fehlern • Heute deutlich besser; Person B hat einen Kontext-Prompt auf die eigene Rolle zugeschnitten • Prompt enthält Anweisung zu Rückfragen und Interaktion, sodass KI Halluzinationen selbst erkennt • Auch Compliance-, Branding- und Sprachvorgaben im Prompt verpackt -> kaum noch Probleme
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	• Klare Vorgaben vorhanden; empfiehlt Disclaimer der Tools zu lesen • Datenschutz ist Topthema für SAP - konsequente Einhaltung wichtig, auch wenn umständlich • Kontext-Prompt enthält Anweisung: keine persönlichen Daten verwenden • Richtet sich nach SAP-Empfehlungen; beachtet Vertraulichkeitsstufen: Public, Confidential, Strictly Confidential
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	• Ja - KI-Inhalte überarbeiten statt selbst von Grund auf erstellen überwiegt absolut • Fähigkeit zur strukturierten Evaluation von KI-Ergebnissen noch nicht ausgebildet - braucht Kurse • Hält das für eine zentrale Aufgabe, die das Team noch lernen muss
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	• Ja, Gefahr besteht - je mehr man sich stützt, desto schneller verlernt man Dinge • Durch aktive Evaluation von KI-Ergebnissen kann man den Effekt teilweise kompensieren • Man empfindet das Ergebnis dann wieder als eigenes -> Ausgleich zwischen Nutzung und Verlernrisiko
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	• Vorteile: Projekt-Setup, Kommunikationsaufgaben, Produktivität und Qualität eindeutig • Kostenvorteil aus Firmensicht: KI kann Personal ersetzen, wenn günstiger als Personalkosten • Nachteil: Großer Spread zwischen KI-affinen und nicht-affinen Kollegen -> mögliche Konflikte in Teamstrukturen • Überforderung als Risiko: hohe Erwartungshaltung von Arbeitgeber und Gesellschaft kann psychische Probleme verursachen
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	• Mitarbeiter befähigen, KI-Ergebnisse strukturiert zu evaluieren - auch aktiv einfordern • Kapazität für Evaluation einplanen, nicht nur Netto-Produktivitätsvorteile messen • Automatisierte Überprüfung bei automatisierten KI-Antworten einbauen • Überforderungsthematik im Auge behalten; Verlernrisiko adressieren
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	• Token-Kosten und faire Verteilung von KI-Nutzungsbudgets - einige Rollen können grenzenlos nutzen, andere sehr begrenzt -> Chancenungleichheit • Rollenveränderungen durch KI werden in 2-3 Jahren enorm stark sein; Risiko für Einzelne, Chance für KI-affine Kollegen und den Arbeitgeber

Tabelle 3: Gesprächsprotokoll: Interview mit Person B — KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person C

Gesprächsprotokoll	Interview Person C 06.08.2026, 11:00-11:30 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	- Wirtschaftsinformatik studiert; 2003 Berufseinstieg bei kleiner Hardwarefirma in Hamburg 2006 SAP-Einstieg (Technologieberatung, Traineeprogramm); 2026 20-jähriges Jubiläum bei SAP - Ca. 7 Jahre Consulting, ca. 7 Jahre MaxAttention-Kundenbetreuung, Mitentwicklung des Readiness-Checks (ERP -> S/4HANA-Migration) - Seit ca. 6 Jahren bei PCG; aktuelles Projekt: „Reimagine Customer Communication“, - Kundenkommunikation auf Kanal-, Technologie- und Geschäftsprozessebene neu denken
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	- Regelmäßig - Teams Premium: Meeting-Transcript-Summaries - Claude und EKX: größere Datenmengen aus Excels/Dokumenten zusammenfassen, Inhalte gezielt finden - Bsp.: 500-seitige Compliance- und Rechtsdokumente (z.B. sap.com) analysieren, ohne PII einzugeben - statt manuelles Durchlesen
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	- Person C selbst hält nichts davon ab - PCG ist keine Entwicklungseinheit -> geringerer Anreiz für Code-Generierung; nicht alle Projekte arbeiten mit Massendaten - Bei Strategie-Projekten (Meetings, Dokumente, konzeptionelles Arbeiten) keine weiteren Anwendungsfälle als aktuell genutzt - Bei Kolleg:innen: Unterschied zwischen KI-Affinen (nutzen privat ChatGPT, Gemini, Claude Code, DeepSeek) und KI-Ablehnenden -> Letztere weniger intrinsisch motiviert
Was hat sich konkret verändert, bzw. was müsste sich ändern?	- Persönlich schneller geworden; im aktuellen Strategie-Projekt ca. 10 % Speed-Steigerung (kein Massendaten-Projekt) - Vergleich mit Entwickler-Freund: 90 % Zeitersparnis bei Prototypen-Erstellung - Bei PCG-Projekten mit Massendaten (z.B. Ticketanalysen): höhere Ersparnis möglich, aber nicht bezifferbar - Im Team: Kolleg:innen beschäftigen sich mehr mit dem Thema, Lernaufwand kostet zunächst Zeit; noch in Anfangsphase (manche Tools erst seit wenigen Monaten freigegeben)
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	- Primärfilter: Datenschutz- und Vertraulichkeitsprüfung vor inhaltlicher Eignung - Primäre Hürde: personenbezogene Daten und Confidentiality; aufpassen, was man eingibt - Need-to-Know-Prinzip: auch Kundendaten ohne PII sind vertraulich; KI kann Daten aggregieren, die nur einem engeren Kreis zugänglich sein sollten - Viele Kolleg:innen nicht ausreichend für diesen Sachverhalt sensibilisiert
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	- Bei Zusammenfassungen: Plausibilitätschecks durchführen; bei eigenem Meeting direkt erkennbar - Bei Datenauswertungen: Ergebnis hinterfragen lassen („Rechne bitte nochmal nach,“) -> fast in der Hälfte der Fälle leichte Abweichungen in zweiter Antwort - Umgang: Bei Trendaussagen mit leichten Abweichungen wird das Ergebnis trotzdem genutzt; bei genauen Zahlen ist manuelle Prüfung notwendig
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	- Need-to-Know-Prinzip beachten; kein PII und keine vertraulichen Daten eingeben - Klare Vorgaben fehlen oft: im offiziellen Playground lange keine deutlichen Hinweise (kein Popup, keine rote Schrift) - Regeln nur in Wiki-Artikeln/Dokumenten hinterlegt - Großer Nachholbedarf: Datenschutzhinweise müssen direkt am Prompt-Eingabefeld erscheinen, nicht nur auf Übersichtsseiten
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	Nein - erstellt Inhalte überwiegend selbst
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	Bis jetzt noch nicht
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	- Vorteile im aktuellen Projekt: Meeting Summaries, Dokument Summaries, PowerPoint-Gerüst als Ausgangsbasis (dann manuell nacharbeiten) - Für Entwickler massiver Vorteil (bis 90 % Zeitersparnis bei Prototypen); für Operations ebenfalls (Daten aus ERP/Ariba ohne vordefinierten Report abrufen, Stichwort Autonomous Enterprise) - Risiko: KI-Outputs nicht immer reproduzierbar -> erschwert Support für KI-generierte Ergebnisse; fraglich, ob SAP genug Zeit/Geld in diesen Aspekt investiert
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	- Klares Bewusstsein schaffen, welche Datenquellen an Assistenten angebunden werden und was die jeweilige Zielgruppe sehen darf (Need-to-Know) - Mitarbeitende verinnerlichen lassen, ob genutzte Tools intern (hinter SAP-Firewall) oder extern (OpenAI, Google) betrieben werden - Offenheit für KI-Nutzung fördern, wenn Datenbewusstsein vorhanden -> hohes Potenzial; andernfalls persönliches Compliance-Risiko
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	Nein, alle relevanten Aspekte wurden besprochen

Tabelle 4: Gesprächsprotokoll: Interview mit Person C — KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person D

Gesprächsprotokoll	Interview Person D xx.xx.xxxx, xx:xx-xx:xx Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	
Was hat sich konkret verändert, bzw. was müsste sich ändern?	
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	

Tabelle 5: Gesprächsprotokoll: Interview mit Person D — KI Tools in der Wissensarbeit bei SAP

Literaturverzeichnis

Agrawal, A., Gans, J.S. und Goldfarb, A. (2024) „Artificial intelligence adoption and system-wide change“, *Journal of Economics & Management Strategy*, 33(2), S. 327–337. Verfügbar unter: <https://doi.org/10.1111/jems.12521>.

Atakishiyev, R. u. a. (2025) „Explainability of Large Language Models: Opportunities and Challenges Toward Generating Trustworthy Explanations“, *arXiv preprint arXiv:2510.17256* [Preprint]. Verfügbar unter: <https://arxiv.org/pdf/2510.17256>.

Balzert, H. (2009) *Lehrbuch der Softwaretechnik: Basiskonzepte und Requirements Engineering*. 3. Aufl. Heidelberg: Spektrum Akademischer Verlag. Verfügbar unter: <https://doi.org/10.1007/978-3-8274-2247-7>.

Baur, N. und Blasius, J. (Hrsg.) (2022) *Handbuch Methoden der empirischen Sozialforschung*. 3. Aufl. Wiesbaden: Springer VS. Verfügbar unter: <https://doi.org/10.1007/978-3-658-37985-8>.

Beauchene, V. u. a. (2026) *AI at Work: Strategy Matters More Than Tools*. Verfügbar unter: <https://web-assets.bcg.com/eb/92/4b39b729403fb6fcae4ff974b234/ai-at-work-slideshow-jun-2026-1.pdf>.

Bender, E.M. u. a. (2021) „On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?“, in *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. New York, NY, USA: Association for Computing Machinery, S. 610–623. Verfügbar unter: <https://doi.org/10.1145/3442188.3445922>.

Bogner, A., Littig, B. und Menz, W. (2014) *Interviews mit Experten: Eine praxisorientierte Einführung*. Wiesbaden: Springer VS (Qualitative Sozialforschung). Verfügbar unter: <https://doi.org/10.1007/978-3-531-19416-5>.

Brassey, J. u. a. (2026) „Five Principles for Designing Brain-Powered Organizations“, *McKinsey People & Organizational Performance Blog* [Preprint]. Verfügbar unter: <https://www.mckinsey.com/capabilities/people-and-organizational-performance/our-insights/the-organization-blog/five-principles-for-designing-brain-powered-organizations>.

Brynjolfsson, E., Li, D. und Raymond, L.R. (2025) „Generative AI at Work“, *The Quarterly Journal of Economics*, 140(2), S. 889–942. Verfügbar unter: <https://doi.org/10.1093/qje/qjae044>.

Bubeck, S. u. a. (2023) *Sparks of Artificial General Intelligence: Early Experiments with GPT-4*. arXiv. Verfügbar unter: <https://doi.org/10.48550/arXiv.2303.12712>.

Burger, D. (2011) *Computergestützter organisationaler Wissenstransfer und Wissensgenerierung: Ein Experteninterview basierter Forschungsansatz*. Wiesbaden: VS Verlag für Sozialwis-

senschaften (SpringerLink Bücher). Verfügbar unter: <https://doi.org/10.1007/978-3-531-93047-3>.

Cantrell, S. u. a. (2025) „From Jobs to Skills to Outcomes: Rethinking How Work Gets Done“, *Deloitte Insights* [Preprint]. Verfügbar unter: <https://www.deloitte.com/us/en/insights/topics/talent/future-of-workforce-planning/planning-work-outcomes.html>.

Carbonero, F., Ernst, E. und Weber, E. (2023) „The Impact of Artificial Intelligence on Labor Markets in Developing Countries: A New Method with an Illustration for Lao PDR and Urban Viet Nam“, *Journal of Evolutionary Economics*, 33, S. 707–736. Verfügbar unter: <https://doi.org/10.1007/s00191-023-00809-7>.

Chen, Q. u. a. (2025) „Large language models at work in China's labor market“, *China Economic Review*, 92, S. 102413. Verfügbar unter: <https://doi.org/10.1016/j.chieco.2025.102413>.

Cheng, Q. u. a. (2026) „The trust crisis in artificial intelligence: AI hallucinations and human-AI collaboration“, *Technology in Society*, 86, S. 103286. Verfügbar unter: <https://doi.org/10.1016/j.techsoc.2026.103286>.

Dell'Acqua, F. u. a. (2026) „Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality“, *Organization Science*, S. 1–21. Verfügbar unter: <https://doi.org/10.1287/orsc.2025.21838>.

Deloitte (2026) *2026 Global Human Capital Trends: From Tensions to Tipping Points – Choosing the Human Advantage*. technical report.

DiSorbo, M.D., Ju, H. und Aral, S. (2025) „Teaching AI to Handle Exceptions: Supervised Fine-Tuning with Human-Aligned Judgment“, *arXiv preprint arXiv:2503.02976* [Preprint]. Verfügbar unter: <https://doi.org/10.48550/arXiv.2503.02976>.

Drucker, P.F. (1994) „The Age of Social Transformation“, *The Atlantic Monthly*, 274(5), S. 53–80. Verfügbar unter: <https://www.theatlantic.com/past/politics/ecbig/soctrans.htm> (Zugegriffen: 22 Juli 2026).

Drucker, P.F. (1999) „Knowledge-Worker Productivity: The Biggest Challenge“, *California Management Review*, 41(2), S. 79–94.

Eisenhardt, K.M. und Graebner, M.E. (2007) „Theory Building from Cases: Opportunities and Challenges“, *Academy of Management Journal*, 50(1), S. 25–32. Verfügbar unter: <https://doi.org/10.5465/AMJ.2007.24160888>.

Eloundou, T. u. a. (2023) *GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models*. arXiv. Verfügbar unter: <https://doi.org/10.48550/arXiv.2303.10130>.

- Emerson, G. u. a. (2026) „AI Will Reshape More Jobs Than It Replaces“, *Boston Consulting Group* [Preprint]. Verfügbar unter: <https://www.bcg.com/publications/2026/ai-will-reshape-more-jobs-than-it-replaces> (Zugegriffen: 28 Juli 2026).
- Fantapié Altobelli, C. (2017) *Marktforschung: Methoden, Anwendungen, Praxisbeispiele*. 3. Aufl. Konstanz und München: UVK Verlagsgesellschaft mbH. Verfügbar unter: <https://doi.org/10.36198/9783838587219>.
- Felten, E., Raj, M. und Seamans, R. (2023) „Occupational Heterogeneity in Exposure to Generative AI“, *SSRN Electronic Journal* [Preprint], (4414065). Verfügbar unter: <https://doi.org/10.2139/ssrn.4414065>.
- Gerlich, M. (2025) „AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking“, *Societies*, 15(1), S. 6. Verfügbar unter: <https://doi.org/10.3390/soc15010006>.
- Haufe Online Redaktion (2017) *Status quo Wissensarbeit: Viel Routine, wenig Innovation*. Verfügbar unter: https://www.haufe.de/personal/hr-management/status-quo-wissensarbeit-viel-routine-wenig-innovation_80_428408.html (Zugegriffen: 27 Juli 2026).
- Heerwagen, J.H. u. a. (2004) „Collaborative Knowledge Work Environments“, *Building Research & Information*, 32(6), S. 510–528. Verfügbar unter: <https://doi.org/10.1080/09613210412331313025>.
- Hu, E.J. u. a. (2022) „LoRA: Low-Rank Adaptation of Large Language Models“, *arXiv preprint arXiv:2206.11834* [Preprint]. Verfügbar unter: <https://arxiv.org/abs/2206.11834>.
- Hussin, A. u. a. (2024) „The Gen AI Skills Revolution: Rethinking Your Talent Strategy“, *McKinsey Insights* [Preprint]. Verfügbar unter: <https://www.mckinsey.com/~media/mckinsey/business%20functions/mckinsey%20digital/our%20insights/the%20gen%20ai%20skills%20revolution%20rethinking%20your%20talent%20strategy/the-gen-ai-skills-revolution-rethinking-your-talent-strategy-v3.pdf?shouldIndex=false>.
- Jiao, J. u. a. (2025) *Generative AI and LLMs in Industry: A Text-Mining Analysis and Critical Evaluation of Guidelines and Policy Statements Across Fourteen Industrial Sectors*. Verfügbar unter: <https://arxiv.org/abs/2501.00957>.
- Kusterer, S. (2008) *Qualitätssicherung im Wissensmanagement: Eine Fallstudienanalyse*. Wiesbaden: Gabler Edition Wissenschaft.
- Lee, H.-P. u. a. (2025) „The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Stewardship“, in *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '25)*. ACM. Verfügbar unter: <https://doi.org/10.1145/3706598.3713778>.

- Lei, Y.-W. und Kim, R. (2024) „Automation and Augmentation: Artificial Intelligence, Robots, and Work“, *Annual Review of Sociology*, 50, S. 251–272. Verfügbar unter: <https://doi.org/10.1146/annurev-soc-090523-050708>.
- Lu, J. (2025) „Tacit Knowledge in Large Language Models“, *The Review of Austrian Economics* [Preprint]. Verfügbar unter: <https://doi.org/10.1007/s11138-025-00710-5>.
- Metakis, M. u. a. (2026) „You Can't Lead AI from the Sidelines“, *McKinsey People & Organizational Performance Blog* [Preprint]. Verfügbar unter: <https://www.mckinsey.com/capabilities/people-and-organizational-performance/our-insights/the-organization-blog/you-cant-lead-ai-from-the-sidelines>.
- Noy, S. und Zhang, W. (2023) „Experimental Evidence on the Productivity Effects of Generative Artificial Intelligence“, *SSRN Electronic Journal* [Preprint]. Verfügbar unter: <https://doi.org/10.2139/ssrn.4375283>.
- Porst, R. (2015) „Arten von Befragungen und Befragungstechniken“, *Gesellschaft, Wirtschaft, Politik (GWP)*, 64(1), S. 93–103. Verfügbar unter: <https://www.budrich-journals.de/>.
- PwC Deutschland (2026) *2026 AI Jobs Barometer: KI kommt an, doch Skills folgen kaum*. Studie. Verfügbar unter: <https://www.pwc.de/de/workforce-transformation/ai-jobs-barometer.html> (Zugegriffen: 28 Juli 2026).
- Rafi, M. u. a. (2024) „Analyzing The Impact of Generative AI on IT Employee Performance“, in *2024 3rd International Conference on Creative Communication and Innovative Technology (ICCIT)*. IEEE. Verfügbar unter: <https://doi.org/10.1109/ICCIT62134.2024.10701171>.
- Renner, K.-H. und Jacob, N.-C. (2020) *Das Interview: Grundlagen und Anwendung in Psychologie und Sozialwissenschaften*. Berlin and Heidelberg: Springer (Basiswissen Psychologie). Verfügbar unter: <https://doi.org/10.1007/978-3-662-60441-0>.
- Snyder, H. (2019) „Literature review as a research methodology: An overview and guidelines“, *Journal of Business Research*, 104, S. 333–339. Verfügbar unter: <https://doi.org/10.1016/j.jbusres.2019.07.039>.
- Spatola, N. (2024) „The efficiency-accountability tradeoff in AI integration: Effects on human performance and over-reliance“, *Computers in Human Behavior: Artificial Humans*, 2(2), S. 100059. Verfügbar unter: <https://doi.org/10.1016/j.chbah.2024.100059>.
- Spivack, N. u. a. (2024) „Cognition is All You Need—The Next Layer of AI Above Large Language Models“, *arXiv preprint arXiv:2403.02164* [Preprint]. Verfügbar unter: <https://doi.org/10.48550/arXiv.2403.02164>.
- Trenerry, B. u. a. (2021) „Preparing Workplaces for Digital Transformation: An Integrative Review and Framework of Multi-Level Factors“, *Frontiers in Psychology*, 12, S. 620766. Verfügbar unter: <https://doi.org/10.3389/fpsyg.2021.620766>.

Woodruff, A. u. a. (2024) „How Knowledge Workers Think Generative AI Will (Not) Transform Their Industries“, in *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '24)*. ACM. Verfügbar unter: <https://doi.org/10.1145/3613904.3642700>.

Yin, R.K. (2014) *Case Study Research: Design and Methods*. Thousand Oaks, California: SAGE Publications.

Selbständigkeitserklärung

Ich versichere hiermit, dass ich die vorliegende Projektarbeit mit dem Thema

Wissensarbeit im Zeitalter generativer Künstlicher Intelligenz bei SAP

Eine systematische Analyse der Auswirkungen von Large Language Models auf Arbeitsprozesse und Kompetenzprofile

selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe und diese Arbeit bei keiner anderen Prüfung mit gleichem oder vergleichbarem Inhalt vorgelegt habe und diese bislang nicht veröffentlicht wurde. Des Weiteren versichere ich, dass die eingereichte elektronische Fassung mit der gedruckten Ausfertigung übereinstimmt.

Ort, Datum

Unterschrift

Erklärung und Nutzungsdokumentation zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten als Prüfungsleistungen

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts „Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten als Prüfungsleistungen im prüfungsrechtlichen Kontext“ Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Arbeit habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlicher oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Verfasser:in der Arbeit die volle Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, sind diese zu den Produktnamen, den formulierten Eingaben (Prompts), den Einsatzzwecken und der entsprechenden Seiten-/Bereichsreferenzierung auf die Arbeit im KI-Verzeichnis am Ende der Arbeit vollständig ausgewiesen und im Text belegt (z.B. als Fußnote).

Ort, Datum

Unterschrift