

Wissensarbeit im Zeitalter generativer Künstlicher Intelligenz bei SAP

Eine systematische Analyse der Auswirkungen von Large Language Models auf Arbeitsprozesse und Kompetenzprofile

2. Projektarbeit

des Studienganges [Studiengang]
an der DHBW Ravensburg

von Anton Nguyen

Kurs: [Kurs]
Matrikelnummer: [Matrikelnummer]
Dualer Partner: SAP SE, 88677 Markdorf
Projektbetreuer: [Projektbetreuer]
Gutachter DHBW: Kerem Ünal
Abgabedatum: [Abgabedatum]

Inhaltsverzeichnis

Abkürzungsverzeichnis.....	III
Tabellenverzeichnis.....	IV
1 Einleitung.....	1
1.1 Problemstellung und Relevanz.....	1
1.2 Zielsetzung und Aufbau der Arbeit.....	2
2 Theoretische Grundlagen.....	4
2.1 Wissensarbeit im digitalen Wandel.....	4
2.2 Textgenerierung mittels Künstlicher Intelligenz: Large Language Models und Einsatzmöglichkeiten.....	6
3 Forschungsdesign und Vorgehensweise.....	8
3.1 Fallstudienanalyse nach Yin.....	8
3.2 Systematische Literaturanalyse.....	12
3.3 Experteninterviews.....	15
4 Auswirkungen von KI-Textgenerierung auf die Wissensarbeit (Ergebnisse der Literaturanalyse).....	17
4.1 Veränderungen von Arbeitsprozessen.....	17
4.2 Veränderungen der Kompetenzprofile.....	17
4.3 Chancen und Risiken.....	18
5 Ergebnisse der Experteninterviews, Diskussion und Handlungsempfehlungen.....	20
5.1 Durchführung und Auswertung der Interviews.....	20
5.2 Diskussion der Ergebnisse im Abgleich mit der Literatur.....	20
5.3 Limitationen der Untersuchung.....	20
5.4 Handlungsempfehlungen.....	20
6 Fazit und Ausblick.....	21
6.1 Zusammenfassung der Ergebnisse.....	21
6.2 Ausblick.....	21
Anhang.....	22
Literaturverzeichnis.....	24

Abkürzungsverzeichnis

API	Application Programming Interface
KI	Künstliche Intelligenz
UX	User Experience

Tabellenverzeichnis

Tabelle 1	Übersicht über die Nutzung von KI-basierten Werkzeugen.....	22
------------------	---	----

1 Einleitung

Die moderne Arbeitswelt steht am Beginn einer neuen technologischen Ära, die oft als fünfte industrielle Revolution begriffen wird und durch eine verstärkte Synergie zwischen menschlicher Kreativität und Künstlicher Intelligenz (KI) geprägt ist (vgl. (Johansson *u. a.*, 2026a, S. 3)). Während vorangegangene Automatisierungswellen primär manuelle und routinemäßige Tätigkeiten betrafen, zielt Generative KI (GenAI) nun direkt auf die Domäne der Wissensarbeit ab (vgl. (Dell'Acqua *u. a.*, 2026, S. 3); (Eloundou *u. a.*, 2023, S. 1)).

Das enorme Aufsehen um Large Language Models (LLMs) wie ChatGPT begründet sich in der Fähigkeit dieser Systeme, komplexe Aufgaben zu übernehmen, die bisher menschliche Diskretion, tiefes Sprachverständnis und die Anwendung von implizitem Wissen erforderten (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 890); (Woodruff *u. a.*, 2024, S. 1)). Aktuelle Analysen deuten darauf hin, dass GenAI in bestimmten Funktionsbereichen das Potenzial hat, in frühen Szenarien bis zu 70 % der heutigen Arbeitszeit technisch zu automatisieren (vgl. (Johansson *u. a.*, 2026a, S. 5); (Eloundou *u. a.*, 2023, S. 1)). Für Unternehmen ergibt sich daraus die dringliche Notwendigkeit, sowohl allgemeine Sprachmodelle als auch spezialisierte relationale Modelle zur Analyse strukturierter Geschäftsdaten zu evaluieren und in bestehende Arbeitsprozesse zu integrieren (vgl. (Johansson *u. a.*, 2026a, S. 20); (Agrawal, Gans und Goldfarb, 2024, S. 327)).

1.1 Problemstellung und Relevanz

In der heutigen globalisierten Wirtschaft gilt Wissen als die **zentrale Ressource** und als der entscheidende Faktor für langfristige Wettbewerbsvorteile von Unternehmen (vgl. (Kusterer, 2008, S. 1)). Während die Informationstechnologie die Wissensarbeit seit Jahrzehnten unterstützt, markiert der Durchbruch generativer Künstlicher Intelligenz, insbesondere durch Large Language Models (LLMs), einen fundamentalen Wendepunkt (vgl. (Woodruff *u. a.*, 2024, S. 2)). Diese Technologien dringen zunehmend in Domänen vor, die bisher als **ausschließlich menschliches Terrain** galten, wie etwa komplexes Sprachverständnis, kreative Textgenerierung und analytische Problemlösung (vgl. (Dell'Acqua *u. a.*, 2026, S. 1); (Eloundou *u. a.*, 2023, S. 1)).

Für ein Softwareunternehmen wie **SAP**, das im Zentrum der digitalen Transformation von Geschäftsprozessen steht, ist diese Entwicklung von doppelter Relevanz: Einerseits versprechen LLMs massive **Produktivitätspotenziale**. Studien belegen, dass der Einsatz von KI-Assistenten die Produktivität bei komplexen Schreib- und Programmieraufgaben signifikant steigern kann, wobei Zeiteinsparungen von etwa 0,75 Standardabweichungen beobachtet wurden (vgl. (Noy und Zhang, 2023, S. 187); (Brynjolfsson, Li und Raymond, 2025, S. 890)). Besonders bemerkenswert ist dabei die Fähigkeit der KI, als „**Equalizer**“, zu fungieren, indem

sie insbesondere weniger erfahrenen Mitarbeitern hilft, die Lernkurve schneller zu durchlaufen und Best-Practice-Muster erfolgreicher Experten zu adaptieren (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 917); (Dell'Acqua u. a., 2026, S. 8)).

Demgegenüber steht die Herausforderung einer „**gezackten technologischen Grenze**„ (Jagged Technological Frontier): LLMs zeigen eine beeindruckende Leistung bei bestimmten kreativen Aufgaben, scheitern jedoch unvorhersehbar an scheinbar einfachen logischen oder kontextspezifischen Problemen (vgl. (Dell'Acqua u. a., 2026, S. 1)). Die daraus resultierenden **Halluzinationen** — fachlich korrekt klingende, aber inhaltlich falsche Ausgaben — stellen in einem hochsensiblen Geschäftsumfeld ein erhebliches Risiko dar (vgl. (Woodruff u. a., 2024, S. 2); (Lee u. a., 2025, S. 2)). Hinzu kommen kritische Fragen der **Datensicherheit** und des Schutzes von geistigem Eigentum, da LLMs oft auf Basis sensibler Unternehmensdaten agieren (vgl. (Johansson u. a., 2026a, S. 20)).

Zudem löst der Einsatz von KI einen tiefgreifenden **Kompetenzwandel** aus. Wissensarbeiter verlagern ihre Tätigkeit zunehmend von der Erstellung von Inhalten hin zu deren **Überwachung und Integration** („Task Stewardship“), was eine verstärkte kognitive Anstrengung bei der Verifizierung von KI-Outputs erfordert (vgl. (Lee u. a., 2025, S. 2)). In Anbetracht dieser Spannungsfelder zwischen technologischem Fortschritt und operationalen Risiken widmet sich die vorliegende Arbeit der zentralen Fragestellung:

Wie verändern Large Language Models die Wissensarbeit bei SAP, und welche konkreten Handlungsempfehlungen lassen sich für Unternehmen und Mitarbeiter ableiten — angesichts erheblicher Produktivitätspotenziale, aber gleichzeitiger Risiken durch Halluzinationen, Datenschutz und Kompetenzwandel?

1.2 Zielsetzung und Aufbau der Arbeit

Das zentrale Ziel dieser Arbeit ist es, die Auswirkungen von Large Language Models auf die Wissensarbeit bei SAP systematisch zu analysieren und daraus konkrete Handlungsempfehlungen für Arbeitsprozesse, Kompetenzprofile und den zukünftigen KI-Einsatz abzuleiten. Um dieses Ziel zu erreichen, werden drei Erkenntnisdimensionen verfolgt. Zunächst soll der aktuelle Stand der Forschung zur Transformation der Wissensarbeit durch generative KI aufgearbeitet werden. Darauf aufbauend sollen die durch LLMs ausgelösten Veränderungen in Arbeitsabläufen und Kompetenzanforderungen bei SAP identifiziert werden. Schließlich sollen fundierte Handlungsempfehlungen entwickelt werden, die als Leitfaden für eine nachhaltige Integration von LLMs in den Arbeitsalltag dienen.

Entsprechend dieser Zielsetzung gliedert sich die Arbeit in sechs Kapitel. Zunächst legt Kapitel 2 die theoretischen Grundlagen, indem es den Begriff der Wissensarbeit im digitalen Wandel definiert und Large Language Models technisch einordnet. Anschließend beschreibt

Kapitel 3 das Forschungsdesign und erläutert die methodische Vorgehensweise, die auf einer Fallstudienanalyse nach Yin basiert und eine systematische Literaturanalyse mit qualitativen Experteninterviews verbindet. Darauf aufbauend stellt Kapitel 4 die Ergebnisse der Literaturanalyse dar, mit Fokus auf Veränderungen von Arbeitsprozessen und Kompetenzprofilen sowie den damit verbundenen Chancen und Risiken. Ergänzend dazu präsentiert Kapitel 5 die empirischen Ergebnisse der Experteninterviews und gleicht diese mit der Literatur ab, um spezifische Handlungsempfehlungen für SAP abzuleiten. Kapitel 6 schließt die Arbeit schließlich mit einer Zusammenfassung der zentralen Erkenntnisse und einem Ausblick auf die zukünftige Entwicklung der KI-gestützten Wissensarbeit ab.

2 Theoretische Grundlagen

Generative Künstliche Intelligenz verbreitet sich zunehmend und verändert dabei grundlegend, wie Wissensarbeit organisiert und ausgeführt wird (vgl. (Woodruff *u. a.*, 2024, S. 1-2); (Trenerry *u. a.*, 2021, S. 1–2)). Besonders Large Language Models markieren in diesem Zusammenhang einen bedeutenden Entwicklungsschritt, da sie zunehmend Aufgabenbereiche erschließen, die bislang überwiegend menschlicher Expertise vorbehalten waren, wie etwa komplexes Sprachverständnis, kreative Textgenerierung und analytische Problemlösung (vgl. (Dell'Acqua *u. a.*, 2026, S. 1); (Eloundou *u. a.*, 2023, S. 1-3)).

Um die Auswirkungen dieser Entwicklung auf die Wissensarbeit bei SAP systematisch analysieren zu können, legt dieses Kapitel das theoretische Fundament der Arbeit. Abschnitt 2.1 definiert zunächst den Begriff der Wissensarbeit und beschreibt den durch LLMs ausgelösten Wandel. Abschnitt 2.2 erläutert anschließend die technische Funktionsweise von Large Language Models sowie deren Einsatzmöglichkeiten in der Wissensarbeit, wobei die Betrachtung bewusst auf die Textgenerierung beschränkt bleibt, da diese die größte praktische Relevanz für die Wissensarbeit besitzt.

2.1 Wissensarbeit im digitalen Wandel

Der Begriff des Wissensarbeiters wurde durch Peter Drucker geprägt (vgl. (Drucker, 1999)). Unter Wissensarbeit wird dabei eine Form spezialisierter Arbeit verstanden, deren zentrales Kapital Wissen darstellt (vgl. (Woodruff *u. a.*, 2024, S. 2)). Dementsprechend wird Wissen in Unternehmen häufig als eine der wichtigsten Ressourcen betrachtet und kann einen wesentlichen Wettbewerbsvorteil darstellen (vgl. (Kusterer, 2008), S. 1). Wissensarbeit ist dadurch gekennzeichnet, dass nicht-routinemäßige Probleme mithilfe theoretischer und analytischer Kenntnisse bearbeitet und gelöst werden. Dabei wird dieses Wissen insbesondere durch spezialisierte Trainings erworben ((Janz, Colquitt und Noe, 1997), S. 878). Des Weiteren wird Wissen im ressourcenbasierten Ansatz als immaterielle Ressource verstanden, die aufgrund ihres Wertes, ihrer Seltenheit sowie ihrer eingeschränkten Imitier- und Substituierbarkeit zur Schaffung eines nachhaltigen Wettbewerbsvorteils beitragen kann (vgl. (Kusterer, 2008), S. 13). Die zunehmende Digitalisierung verändert die Rahmenbedingungen der Arbeit grundlegend und beeinflusst damit auch die Wissensarbeit (vgl. (Trenerry *u. a.*, 2021, S. 1–2)). Insbesondere digitale Technologien wie künstliche Intelligenz, Automatisierung, Cloud Computing und das Internet of Things verändern die Art und Weise, wie Arbeit organisiert und ausgeführt wird (vgl. (Trenerry *u. a.*, 2021, S. 1–2)). Als spezifische Gruppe von Arbeitnehmenden, deren zentrale Ressource Wissen ist (Galbraith, 2007, S. 2, zitiert nach (Woodruff *u. a.*, 2024, S. 2)), sind Wissensarbeiter von diesen Veränderungen unmittelbar betroffen. Darüber hinaus ermöglichen digitale Technologien einen erleichterten Zugang zu Informationen und unterstützen die

Zusammenarbeit über räumliche Grenzen hinweg, beispielsweise durch digitale Kommunikations- und Kollaborationstechnologien (vgl. (Trenerry u. a., 2021, S. 10)). Gleichzeitig verändern sich die Anforderungen an die Kompetenzen von Arbeitnehmenden, da digitale Fähigkeiten zunehmend notwendig werden, um Aufgaben in digitalen Arbeitsumgebungen ausführen zu können (vgl. (Trenerry u. a., 2021, S. 7)). Dies betrifft insbesondere Wissensarbeiter, deren Tätigkeiten auf der Verarbeitung, Analyse und Nutzung von Informationen beruhen (vgl. Briggs und Kodnani, 2023, zitiert nach (Woodruff u. a., 2024, S. 2)).

Merkmale der Wissensarbeit

In der Literatur werden der Wissensarbeit häufig folgende Charakteristika zugeschrieben, die sie von manuellen oder rein administrativen Tätigkeiten abgrenzen:

- **Information als Rohstoff:** Wissensarbeit umfasst dabei Berufsfelder, die Informationen, Daten oder Ideen als „Rohmaterial„ nutzen, um Produkte und Dienstleistungen zu planen, zu analysieren, zu interpretieren, weiterzuentwickeln und zu erstellen ((Heerwagen u. a., 2004), S. 511).
- **Autonomie und Verantwortung:** Wissensarbeit versteht Arbeitnehmende als strategische Kapitalanlage des Unternehmens und verortet die Verantwortung für die Produktivität beim einzelnen Wissensarbeiter, der innerhalb definierter Grenzen autonom über die Herangehensweise an eine Aufgabe entscheidet (vgl. (Drucker, 1999), S. 87).
- **Kognitive Intensität:** Wissensarbeit umfasst nicht-routinemäßige, kognitiv anspruchsvolle Aktivitäten, die auf der Erstellung, Anwendung oder Integration von spezialisierter intellektueller Expertise basieren (vgl. (Dell'Acqua u. a., 2026, S. 4)).

Herausforderungen im digitalen Wandel

Durch den Einzug von Large Language Models (LLMs) steht die Wissensarbeit vor einer tiefgreifenden Transformation, die neue **Herausforderungen** mit sich bringt:

1. **Die diskontinuierliche technologische Grenze (Jagged Frontier):** KI-Systeme zeigen in kognitiven Domänen eine ungleichmäßige Leistung. Während sie bei kreativen Aufgaben oft menschliche Experten übertreffen, können sie bei logisch ähnlich komplexen Aufgaben unvorhersehbar scheitern (vgl. (Dell'Acqua u. a., 2026, S. 1)).
2. **Wandel zur Stewardship-Rolle:** Die Tätigkeit von Wissensarbeitern verlagert sich von der Erstellung hin zur Überwachung und Integration von KI-Outputs, was eine erhöhte kritische Reflexionsfähigkeit erfordert (vgl. (Lee u. a., 2025, S. 15)).
3. **Cognitive Offloading:** Die zunehmende Delegation kognitiver Aufgaben an KI-Systeme birgt die Gefahr einer Schwächung des kritischen Denkens sowie einer kognitiven Abhängigkeit (vgl. (Gerlich, 2025, S. 2)).

4. **Validierungsaufwand:** Da LLMs zu Halluzinationen und inhaltlich falschen, aber plausibel klingenden Ausgaben neigen, steigt der Aufwand für Verifizierungsprozesse (vgl. (Lee *u. a.*, 2025, S. 15); (Brynjolfsson, Li und Raymond, 2025, S. 897); (Dell'Acqua *u. a.*, 2026, S. 3)).

2.2 Textgenerierung mittels Künstlicher Intelligenz: Large Language Models und Einsatzmöglichkeiten

Large Language Models (LLMs) zählen zu den bedeutendsten Entwicklungen innerhalb der jüngeren KI-Forschung (vgl. (Bubeck *u. a.*, 2023, S.4)). Es handelt sich dabei um neuronale Netzwerkmodelle, die anhand riesiger Mengen an Textdaten aus dem Internet trainiert werden. Das Modell lernt dabei, auf Basis eines gegebenen Kontextes die Wahrscheinlichkeit nachfolgender Tokens vorherzusagen (vgl. (Bubeck *u. a.*, 2023, S.4)). Obwohl der Begriff menschliche Sprache impliziert, lassen sich diese Techniken auch auf andere Formen sequenzieller Daten anwenden, etwa Computercode, Proteinsequenzen oder Audiodaten (vgl. (Eloundou *u. a.*, 2023, S. 1)). Dabei bezeichnet der Begriff ein Modell, das auf extrem großen Datensätzen (oft im Tera- oder Petabyte-Bereich) trainiert wurde und über Milliarden von Parametern verfügt, um komplexe linguistische Strukturen abzubilden (vgl. (Woodruff *u. a.*, 2024, Fn. 1); (Bender *u. a.*, 2021, S. 610-623)).

Technische Funktionsweise der Textgenerierung

Der Kern der Textgenerierung basiert auf der **wahrscheinlichkeitsbasierten Vorhersage** des nächsten Wortes (bzw. Tokens) in einer Sequenz (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 895); (Chen *u. a.*, 2025, S. 14)).

- **Transformer-Architektur und Self-Attention:** Der entscheidende Fortschritt gelang durch die Einführung von Transformer-Modellen, die einen sogenannten „Attention-Mechanismus“ nutzen. Dieser erlaubt es dem System, Wörtern innerhalb eines Textes unterschiedliche Relevanzgewichte zuzuweisen, um semantische Abhängigkeiten über weite Distanzen hinweg zu erfassen (vgl. (Chen *u. a.*, 2025, S. 14); (Brynjolfsson, Li und Raymond, 2025, S. 896)).
- **Stochastische Mustererkennung:** Anstatt expliziten linguistischen Regeln zu folgen, lernen diese Modelle durch statistische Korrelationen („Pattern Recognition“), welche Begriffe in einem bestimmten Kontext üblicherweise zusammen auftreten (vgl. (Jiao *u. a.*, 2025, S. 1); (Brynjolfsson, Li und Raymond, 2025, S. 896)).
- **Software-2.0-Paradigma:** Im Gegensatz zur klassischen Programmierung (Software 1.0), bei der jede Anweisung explizit kodiert wird, folgt die Textgenerierung einem datengesteuerten Ansatz. Das Verhalten entsteht dabei aus Berechnungen auf großen Datensätzen, wobei sich das neuronale Netzwerk für die erwünschte Antwort selbst optimiert (vgl. (Chen *u. a.*, 2025, S. 11)).

Abgrenzung und Einsatzgebiete in der Wissensarbeit

Ein wesentliches Merkmal textgenerierender KI ist die Abgrenzung zur **diskriminativen KI**. Diskriminative KI ist dabei primär auf die Klassifikation und Kategorisierung von Daten ausgerichtet, wohingegen generative KI eigenständig neue Inhalte erzeugt, die menschlichen Erzeugnissen in ihrer Qualität nahekommen (vgl. (Felten, Raj und Seamans, 2023, S. 1); (Jiao u. a., 2025, S. 2)). Aufgrund dieser Eigenschaften finden LLMs in der Wissensarbeit breite Anwendung als Allzwecktechnologien (vgl. (Eloundou u. a., 2023, S. 1 und 22)):

- **Textproduktion und -optimierung:** LLMs unterstützen die Erstellung von Erstentwürfen für Berichte, E-Mails oder Marketingmaterialien sowie die Umformulierung komplexer Sachverhalte an verschiedene Tonalitäten (vgl. (Noy und Zhang, 2023, S. 187-188); (Woodruff u. a., 2024, S. 7,13 und 23)).
- **Codegenerierung:** LLMs ermöglichen die Übersetzung natürlicher Sprache in Programmiersprachen (z. B. Python), was die Produktivität in der Softwareentwicklung durch automatisierte Vorschläge erheblich steigert (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 897); (Eloundou u. a., 2023, S. 4); (Chen u. a., 2025, S. 6,11 und 15)).
- **Information Synthesis:** LLMs ermöglichen die Zusammenfassung umfangreicher Dokumente („Summarization“) und die Extraktion relevanter Fakten aus unstrukturierten Textmen- gen (vgl. (Chen u. a., 2025, S. 14-15); (Lee u. a., 2025, S. 4-6 und 12)).

Trotz dieser Potenziale bleibt die Herausforderung der **Halluzination** bestehen, da LLMs auf statistischen Wahrscheinlichkeiten für die Vorhersage des nächsten Tokens auf Basis des bisherigen Kontexts beruhen (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 895)) und dadurch inhaltlich falsche Aussagen mit hoher sprachlicher Überzeugungskraft generieren können (vgl. (Dell'Acqua u. a., 2026, S. 3); (Woodruff u. a., 2024, S. 7 und 23)). Eine kontinuierliche menschliche Validierung („Task Stewardship“) bleibt daher für die Qualitätssicherung in professionellen Kontexten unerlässlich (vgl. (Lee u. a., 2025, S. 12–16)).

3 Forschungsdesign und Vorgehensweise

[Text]

3.1 Fallstudienanalyse nach Yin

Yin definiert die Fallstudie entlang zweier zentraler Dimensionen, nämlich dem Untersuchungsgegenstand einerseits und den methodischen Merkmalen andererseits. Hinsichtlich des Untersuchungsgegenstands handelt es sich bei einer Fallstudie um eine empirische Untersuchung, die ein Phänomen oder einen Fall eingehend und in seinem realen Kontext analysiert. In methodischer Hinsicht zeichnet sich die Fallstudie dadurch aus, dass sie die technisch besondere Situation berücksichtigt, in der mehr relevante Variablen als verfügbare Datenpunkte vorliegen. Um dieser Komplexität gerecht zu werden, stützt sie sich auf mehrere Evidenzquellen, deren Daten durch Triangulation zusammengeführt werden. Insgesamt erweist sich die Fallstudie damit als eine ganzheitliche Forschungsmethode, die Designlogik, Datenerhebung und Datenanalyse gleichermaßen umfasst und folglich nicht auf ein bloßes Erhebungsinstrument reduziert werden kann (vgl. (Yin, 2014, S. 33)).

Arten von Fallstudien

Fallstudien können drei verschiedenen Forschungszwecken dienen. Explorative Fallstudien zielen darauf ab, erste Hypothesen für eine weiterführende Untersuchung zu entwickeln. Deskriptive Fallstudien beschreiben ein Phänomen innerhalb seines Kontextes vollständig. Explanatorische Fallstudien hingegen erklären kausale Zusammenhänge (vgl. (Yin, 2014, S. 23)).

Ein weiteres Unterscheidungsmerkmal betrifft die Anzahl der untersuchten Fälle. Bei der Einzelfallstudie konzentriert sich die Analyse auf einen einzigen Fall, was sich dann anbietet, wenn dieser besonders erkenntnisreich ist, einen Extremfall darstellt oder einen seltenen Zugang zum Untersuchungsgegenstand ermöglicht. Auf diese Weise lässt sich die Existenz eines Phänomens unter außergewöhnlichen Bedingungen gezielt und tiefgehend untersuchen (vgl. (Eisenhardt und Graebner, 2007, S. 25-27)). Die Mehrfachfallstudie erweitert diesen Ansatz, indem sie mehrere Fälle einbezieht und auf dieser Grundlage fallübergreifende Aussagen ableitet (vgl. (Yin, 2014, S. 45)). Der Vergleich verschiedener Fälle erlaubt es zu beurteilen, ob ein Ergebnis fallspezifisch ist oder sich auf andere Kontexte übertragen lässt. Die Fallauswahl erfolgt dabei bewusst, um theoretische Annahmen zu stützen, weiterzuentwickeln, zu kontrastieren oder konkurrierende Erklärungen zu entkräften (vgl. (Eisenhardt und Graebner, 2007, S. 25-27)).

Der Forschungsprozess nach Yin gliedert sich in sechs aufeinander aufbauende Phasen, nämlich Plan, Design, Prepare, Collect, Analyze und Share, die den gesamten Ablauf von der ersten Konzeption bis zur abschließenden Kommunikation der Ergebnisse strukturieren.

Plan

In der Plan-Phase wird grundlegend geklärt, ob die Fallstudie als Forschungsmethode für das jeweilige Erkenntnisinteresse geeignet ist. Nach Yin spricht für ihren Einsatz, wenn die Forschungsfragen auf ein Wie oder Warum abzielen, der Forscher keinen Einfluss auf das untersuchte Geschehen nehmen kann und ein gegenwärtiges Phänomen im Mittelpunkt steht (vgl. (Yin, 2014, S. 3)). Der Formulierung der Forschungsfrage kommt in diesem Zusammenhang eine besondere Bedeutung zu, denn sie ist nicht nur inhaltlicher Ausgangspunkt, sondern entscheidet durch ihre Form als Wie- oder Warum-Frage maßgeblich darüber, ob die Fallstudie als Methode überhaupt in Betracht kommt (vgl. (Yin, 2014, S. 11)).

Design

Die Designphase verfolgt das Ziel, logische Inkonsistenzen im Forschungsaufbau zu vermeiden und sicherzustellen, dass die erhobenen Daten tatsächlich zur Beantwortung der Forschungsfrage beitragen. Yin zufolge umfasst ein vollständiges Fallstudiendesign fünf zentrale Komponenten, nämlich die Forschungsfragen, theoretische Annahmen, die zu untersuchende Einheit, die Logik der Verknüpfung von Daten und Annahmen sowie Kriterien zur Interpretation der Befunde (vgl. (Yin, 2014, S. 61)).

Prepare

Die Prepare-Phase dient der systematischen Vorbereitung der Datenerhebung und gliedert sich nach Yin in fünf Bereiche. Diese umfassen die persönlichen Fähigkeiten des Forschers, ein fallspezifisches Training, die Erstellung eines Studienprotokolls, die Auswahl geeigneter Fälle sowie eine vorgelagerte Pilotstudie. Anders als bei Experimenten oder standardisierten Befragungen gibt es bei der Fallstudienforschung kein festgelegtes Erhebungsverfahren, weshalb der Forscher während der gesamten Datenerhebung fortlaufend eigene Urteile treffen muss. Yin benennt dabei konkrete Anforderungen an den Forscher, der gezielt und präzise fragen, aktiv zuhören, flexibel auf unerwartete Entwicklungen reagieren, die theoretischen Vorannahmen kontinuierlich im Blick behalten und mögliche Verzerrungen bewusst reflektieren sollte (vgl. (Yin, 2014, S. 71f)). Zur Absicherung der Reliabilität empfiehlt Yin die Erstellung eines Fallstudienprotokolls, das vier Bestandteile umfasst, nämlich eine Übersicht über das Forschungsprojekt, eine Beschreibung des Datenerhebungsprozesses, einen Katalog analytischer Fragen als Orientierungshilfe für den Forscher während der Feldarbeit sowie einen Leitfaden für die abschließende Berichterstattung (vgl. (Yin, 2014, S. 84f)).

Ergänzend weist Yin darauf hin, dass die analytischen Fragen des Protokolls nicht mit den Interviewfragen verwechselt werden dürfen, da sie ausschließlich als Reflexionshilfe für den

Forscher selbst konzipiert sind und nicht an die Befragten gerichtet werden (vgl. (Yin, 2014, S. 89f)). Im Anschluss daran folgt das Screening, das der finalen Fallauswahl unmittelbar vor Beginn der Datenerhebung dient (vgl. (Yin, 2014, S. 95)). Da SAP als Untersuchungseinheit von Beginn an feststand, war ein aufwändiges Auswahlverfahren nicht erforderlich. Darüber hinaus empfiehlt Yin die Durchführung einer Pilotstudie, die sich von einem klassischen Pretest insofern unterscheidet, als sie nicht nur das Erhebungsinstrument erprobt, sondern auch konzeptionelle Klärungen für das Gesamtdesign ermöglicht (vgl. (Yin, 2014, S. 96)). In der vorliegenden Arbeit wurde auf eine Pilotstudie verzichtet, da der Forscher als internes Mitglied der SAP-Organisation über einen kontinuierlichen Feldzugang verfügte, der diese konzeptionelle Funktion bereits erfüllte.

Collect

In der Collect-Phase erfolgt die eigentliche Datenerhebung, wobei Fallstudien grundsätzlich auf eine Vielzahl unterschiedlicher Datenquellen zurückgreifen können. Keine dieser Quellen ist den anderen dabei von vornherein überlegen. Stattdessen zeichnet eine qualitativ hochwertige Fallstudie gerade dadurch aus, dass sie möglichst viele verschiedene Quellen miteinander kombiniert und so eine breitere und belastbarere Evidenzbasis schafft. Zu den gängigsten Datenquellen zählen nach Yin Dokumentation, Archivdaten, Interviews, direkte Beobachtung, teilnehmende Beobachtung sowie physische Artefakte (vgl. (Yin, 2014, S. 106f)).

Analyze

Gegenstand der Analysephase ist die systematische Auswertung der erhobenen Belege, die kategorisiert, tabellarisch aufbereitet und zueinander in Beziehung gesetzt werden, um daraus fundierte Erkenntnisse abzuleiten (vgl. (Yin, 2014, S. 133)). Anders als bei quantitativen Methoden stehen dem Forscher dabei weder standardisierte Verfahren noch feste Formeln zur Verfügung, weshalb er frühzeitig eine eigene Analysestrategie entwickeln sollte, idealerweise bereits in der Designphase. Als Orientierungsrahmen benennt Yin vier allgemeine Strategien, wobei der Forscher wahlweise an theoretischen Propositionen anknüpfen, induktiv von den Daten ausgehen, eine deskriptive Fallbeschreibung erarbeiten oder plausible Alternativerklärungen systematisch prüfen kann (vgl. (Yin, 2014, S. 136f)). Aufbauend auf diesen Strategien stehen zudem fünf spezifische Analysetechniken zur Verfügung, nämlich Pattern Matching, Explanation Building, Time-Series Analysis, Logic Models sowie Cross-Case Synthesis (vgl. (Yin, 2014, S. 142)).

Im Kontext der vorliegenden Arbeit kommen zwei Analysetechniken zum Einsatz. Zum einen wird Pattern Matching als primäre Technik genutzt, da die in der Literaturanalyse erarbeiteten theoretischen Muster zu Veränderungen in Arbeitsprozessen und Kompetenzprofilen mit den empirischen Befunden der Experteninterviews abgeglichen werden. Stimmen die beobachteten Muster mit den theoretisch erwarteten überein, stärkt dies die interne Validität der

Ergebnisse (vgl. (Yin, 2014, S. 143)). Ergänzend dazu wird Explanation Building eingesetzt, um auf Basis dieses Abgleichs schrittweise eine konsistente Erklärung dafür zu entwickeln, wie und unter welchen Bedingungen LLMs die Wissensarbeit bei SAP verändern. Die Erklärung entsteht dabei iterativ, indem eine theoretische Ausgangsthese mit den erhobenen Interviewdaten konfrontiert und in mehreren Schritten so lange verfeinert wird, bis ein stimmiges Gesamtbild vorliegt (vgl. (Yin, 2014, S. 147f)). Unabhängig von der gewählten Technik hebt Yin schließlich vier Qualitätsmerkmale einer guten Analyse hervor, nämlich die lückenlose Berücksichtigung aller erhobenen Belege, die aktive Auseinandersetzung mit konkurrierenden Erklärungsansätzen, die konsequente Fokussierung auf den zentralen Forschungsgegenstand sowie die reflektierte Nutzung des eigenen Expertenwissens (vgl. (Yin, 2014, S. 168f)).

Share

Als abschließender Schritt des Fallstudienforschungsprozesses umfasst die Share-Phase die Aufbereitung und Kommunikation der gewonnenen Erkenntnisse. Da die Fallstudie dabei keiner standardisierten Vorlage folgt, stellt Yin zufolge gerade diese Phase besonders hohe Anforderungen an die schriftlichen und kommunikativen Kompetenzen des Forschers. Hinsichtlich der Form ist zu betonen, dass ein Fallstudienbericht nicht auf reine Texte beschränkt ist, sondern ebenso nicht-textuelle Elemente wie Tabellen, Abbildungen, Grafiken oder Präsentationen einschließen kann. Vor der eigentlichen Gestaltung sollte jedoch zunächst die Zielgruppe des Berichts geklärt werden, da Yin zwischen wissenschaftlichen Fachkollegen, Praktikern und politischen Entscheidungsträgern, Prüfungskommissionen sowie Forschungsförderern unterscheidet und jede dieser Gruppen spezifische Erwartungen an den Bericht mitbringt (vgl. (Yin, 2014, S. 177f)). Gerade für wissenschaftliche Abschlussarbeiten bietet sich die linear-analytische Struktur an, bei der die Darstellung von der Forschungsfrage über Methodik und Daten bis hin zu Befunden und Schlussfolgerungen logisch aufgebaut wird (vgl. (Yin, 2014, S. 188)). Zudem empfiehlt Yin, den Schreibprozess nicht auf die Abschlussphase zu verschieben, sondern bereits während der Datenerhebung zu beginnen, um die Qualität des Endberichts nachhaltig zu sichern (vgl. (Yin, 2014, S. 195)). Als übergeordnetes Gütemerkmal gilt schließlich, dass der Bericht so viele Belege enthält, dass sich der Leser auf dieser Basis ein eigenes, unabhängiges Urteil über die präsentierten Befunde bilden kann (vgl. (Yin, 2014, S. 205)).

Grundsätzlich wären für diese Arbeit auch alternative Forschungsdesigns denkbar gewesen, etwa eine Mehrfachfallstudie mit vergleichend untersuchten Unternehmen, ein quantitatives Umfrage-Design mit standardisierten Fragebögen oder eine Grounded-Theory-Studie. Dennoch erweist sich die Einzelfallstudie nach Yin als am besten geeignet, weil die Rollentransformation ein zeitgenössisches Phänomen darstellt, das nicht losgelöst von seinem organisationalen Kontext betrachtet werden kann. Eine quantitative Erhebung schied dabei aus, da sie voraussetzen würde, dass die relevanten Variablen bereits bekannt sind, was hier gerade die

eigentliche Forschungslücke darstellt. Ebenso wenig war eine Mehrfachfallstudie realisierbar, da der Zugang zu vergleichbaren Transformationsprojekten anderer Unternehmen nicht in ausreichendem Maß gegeben war. SAP hingegen bietet als Einzelfall durch die Praxisphase einen seltenen und direkten Einblick in ein laufendes, unternehmensinternes Transformationsprojekt, der von außen, etwa durch reine Literatur oder Sekundärdatenanalyse, kaum zugänglich wäre, und erfüllt damit Yins Kriterium eines Revelatory Case.

3.2 Systematische Literaturanalyse

Methodisches Vorgehen der Literaturanalyse nach Snyder

Um für die Untersuchung der Wissensarbeit bei SAP eine valide und reproduzierbare Grundlage zu schaffen, folgt diese Arbeit dem methodischen Rahmen von (Snyder, 2019). Da im Rahmen dieser Arbeit festgestellt wurde, dass das Forschungsfeld der generativen Künstlichen Intelligenz durch eine hohe Entwicklungsgeschwindigkeit und ein breites fachübergreifendes Spektrum geprägt ist, eignet sich dieser Ansatz besonders, da er nicht auf rein quantitative Methoden beschränkt ist, sondern auch die gemeinsame Auswertung von Quellen aus unterschiedlichen Forschungsrichtungen ermöglicht (vgl. (Snyder, 2019, S. 334)). Das Vorgehen gliedert sich dabei in den vierphasigen Prozess aus Design, Durchführung, Analyse und Verschriftlichung (vgl. (Snyder, 2019, S. 336-337)).

In der ersten Phase, dem Review-Design, wird die methodische Ausrichtung festgelegt. Aufgrund der beschriebenen Aktualitätsproblematik und der Notwendigkeit, verschiedene Perspektiven zu vereinen, wird ein integrativer Review-Ansatz gewählt. Dieser eignet sich nach Snyder besonders für neue Themenbereiche, bei denen noch kein etabliertes theoretisches Modell existiert und das Ziel darin besteht, erste Zusammenhänge und Muster zu erkennen, anstatt bestehende Ansätze lediglich zu bestätigen (vgl. (Snyder, 2019, S. 336)). Entsprechend den Vorgaben von Snyder wurden in dieser Phase zunächst die Forschungsfragen festgelegt, die als Grundlage für die gesamte Suche und Analyse dienen (vgl. (Snyder, 2019, S. 336)). Sie adressieren dabei sowohl theoretische Potenziale als auch praktische Realitäten des KI-Einsatzes bei SAP. Darüber hinaus wurde die Suchstrategie definiert: Die wissenschaftliche Suche erfolgte in den Datenbanken Google Scholar, arXiv, ResearchGate sowie dem Bibliothekskatalog der DHBW Ravensburg mit den Suchbegriffen „how AI shapes and evolves knowledge work“, „generative AI productivity“ sowie „LLM in knowledge work“. Praxisorientierte Quellen wie Beratungsstudien wurden über gezielte KI-gestützte Recherche identifiziert und verifiziert. Da eine Literatursuche in der Regel eine große Anzahl an Treffern liefert, wurden auf Basis der Forschungsfrage zudem konkrete Ein- und Ausschlusskriterien festgelegt, anhand derer die tatsächlich relevanten Quellen identifiziert werden sollten (vgl. (Snyder, 2019, S. 337)). Snyder betont dabei, dass alle Ein- und Ausschlussentscheidungen explizit begründet sein müssen,

um die Transparenz und die Qualität des Reviews sicherzustellen (vgl. (Snyder, 2019, S. 337–338)). Dies wird in dieser Arbeit durch die kritische Würdigung der grauen Literatur realisiert.

In der zweiten Phase der Durchführung wurde die eigentliche Literatursuche anhand der in Phase 1 festgelegten Strategie umgesetzt. Snyder empfiehlt, die Suchbegriffe und Auswahlkriterien zunächst an einer kleineren Auswahl zu testen und den Prozess bei Bedarf anzupassen, bevor die vollständige Suche durchgeführt wird (vgl. (Snyder, 2019, S. 337)). Entsprechend diesem Vorgehen wurden die Suchbegriffe in einem ersten Schritt erprobt und verfeinert. Die Quellenauswahl erfolgte anschließend in zwei Stufen: Zunächst wurden die Treffer anhand von Titel und Abstract auf ihre Relevanz geprüft, bevor die verbliebenen Quellen im Volltext gelesen und abschließend bewertet wurden. Snyder empfiehlt zudem den Einsatz von zwei Reviewern, um die Qualität und Reliabilität der Quellenauswahl zu sichern (vgl. (Snyder, 2019, S. 337)). Da die vorliegende Arbeit von einem einzelnen Autor verfasst wird, konnte diesem Vorgehen nicht entsprochen werden; diesem Umstand wird durch die explizite Dokumentation der Ein- und Ausschlusskriterien begegnet. Alle Entscheidungen wurden dabei auf Basis der in Phase 1 definierten Kriterien getroffen und sind durch die kritische Würdigung der Quellenkategorien nachvollziehbar dokumentiert (vgl. (Snyder, 2019, S. 337)).

Nach der Identifikation der relevanten Quellen erfolgt in der dritten Phase die Analyse. Snyder betont, dass nach der Festlegung der endgültigen Quellen ein einheitliches Vorgehen zur Informationsentnahme angewendet werden sollte, um Qualität und Verlässlichkeit der Auswertung sicherzustellen (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit wurden aus den ausgewählten Quellen relevante Informationen in Form von Befunden, Einschätzungen und thematischen Schwerpunkten entnommen. Die Analyse erfolgt dabei nicht rein autorenenorientiert, sondern konzeptzentriert: Themen wie „Veränderung von Arbeitsprozessen“, „Kompetenzwandel durch KI“ oder „Chancen und Risiken des KI-Einsatzes“, wurden über die verschiedenen Quellenkategorien hinweg extrahiert und miteinander verglichen. Da das Ziel dieser Arbeit nicht die statistische Auswertung von Effektgrößen, sondern die Entwicklung eines inhaltlichen Überblicks ist, wurde eine für integrative Reviews geeignete Analysetechnik gewählt (vgl. (Snyder, 2019, S. 337)).

In der abschließenden Phase der Verschriftlichung werden die Ergebnisse so aufbereitet, dass Motivation, Vorgehen und Erkenntnisse des Reviews klar und nachvollziehbar kommuniziert werden (vgl. (Snyder, 2019, S. 337)). Snyder verweist dabei auf anerkannte Richtlinien zur Berichterstattung von Literaturreviews, darunter die Leitlinien für integrative Reviews nach Torracco (Torraco, 2005, zitiert nach (Snyder, 2019, S. 337)). Unabhängig vom gewählten Ansatz wird erwartet, dass der gesamte Prozess von der Planung über die Suche bis hin zur Analyse transparent beschrieben wird, damit der Leser die Qualität und Verlässlichkeit der Ergebnisse einschätzen kann (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit wird diesem Anspruch durch die detaillierte Beschreibung der vier Phasen in diesem Kapitel entsprochen.

Snyder beschreibt, dass der Beitrag eines Reviews verschiedene Formen annehmen kann, etwa eine konzeptionelle Aufarbeitung eines Forschungsfelds (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit besteht der Beitrag darin, einen strukturierten Überblick über den aktuellen Wissensstand zur Veränderung der Wissensarbeit durch generative KI zu schaffen.

Zielsetzung und Vorgehen

Die vorliegende Arbeit untersucht, wie generative Künstliche Intelligenz Arbeitsprozesse und Kompetenzprofile in der Wissensarbeit bei SAP verändert sowie welche Chancen und Risiken sich daraus ergeben. Da es sich um ein Forschungsfeld handelt, in dem im Rahmen dieser Arbeit festgestellt wurde, dass die akademische Literatur der technologischen Entwicklung teils mit zeitlichem Verzug folgt, wurde die Literaturanalyse bewusst mehrstufig angelegt: Sie kombiniert drei Quellenkategorien, die zwei unterschiedliche Funktionen erfüllen, nämlich die theoretisch-methodische Fundierung durch wissenschaftliche Studien einerseits sowie die Abbildung empirischer Aktualität und Praxisrelevanz durch Berater- und Fachpressequellen andererseits.

Die einbezogene Literatur lässt sich dabei in drei Kategorien unterteilen. Wissenschaftliche Literatur in Form von peer-reviewten Studien und Working Papern bildet die theoretische Basis der Arbeit und liefert methodisch abgesicherte Erkenntnisse zu Automatisierungspotenzialen und Produktivitätseffekten. Beratungsstudien (graue Literatur) großer Institute liefern ergänzend aktuelle, breit angelegte empirische Daten zu Skill-Wandel oder Adoptionsraten, die wissenschaftlich oft noch nicht verfügbar sind. Fachpresse und Praxisbeiträge runden das Bild ab, indem sie die praktische Rezeption der Entwicklungen in Unternehmen abbilden.

Zur Sicherung der Quellenqualität werden spezifische Auswahlkriterien angelegt. Neben einer strikten Aktualität (Fokus auf 2024–2026) wird bei Beratungsstudien die Transparenz der Methodik (Stichprobengröße, Erhebungszeitraum) geprüft. Um eine einseitige Darstellung zu vermeiden, wird auf Ausgewogenheit geachtet, indem auch kritische Gegenpositionen zum KI-Einsatz in Unternehmen einbezogen werden. Reine Meinungsbeiträge ohne empirische Grundlage werden ausgeschlossen.

Diese einbezogenen Beratungs- und Fachpressequellen stellen keine peer-reviewte Literatur im engeren Sinne dar und sind entsprechend kritisch zu würdigen. Insbesondere bei Studien von Unternehmensberatungen ist ein potenzieller Interessenkonflikt zu berücksichtigen, da diese Institute selbst kommerzielle KI-Transformationsleistungen anbieten. Dieser methodischen Einschränkung wird dadurch begegnet, dass Beratungsquellen ausschließlich zur Illustration aktueller Marktentwicklungen herangezogen werden, während die inhaltliche Argumentation auf der wissenschaftlichen Literatur aufbaut.

3.3 Experteninterviews

Als eine der zentralen Methoden qualitativer Forschung findet das Experteninterview in unterschiedlichen Forschungsfeldern Anwendung und kann dabei sowohl als eigenständiges Instrument als auch in Kombination mit weiteren Forschungsmethoden eingesetzt werden (vgl. (Burger, 2011, S. 127)). Im Mittelpunkt steht die gezielte Erschließung des Fachwissens ausgewählter Experten, um auf dieser Basis wissenschaftlich fundierte Erkenntnisse zu gewinnen (vgl. (Bogner, Littig und Menz, 2014, S. 17)).

Das Interview stellt in seiner grundlegenden Form eine mündliche Befragung dar (vgl. (Renner und Jacob, 2020, S. 1)). Befragungen lassen sich dabei generell in quantitative und qualitative Verfahren unterteilen (vgl. (Fantapié Altobelli, 2017, S. 55, 357)). Leitfadengestützte Experteninterviews zählen zu den qualitativen Methoden der Datenerhebung. Da die gewonnenen Daten im Anschluss unmittelbar weiterverarbeitet werden, ist bei der Durchführung besondere Sorgfalt geboten (vgl. (Baur und Blasius, 2022, S. 875)).

Qualitative Befragungen unterscheiden sich von quantitativen Verfahren insbesondere durch ihren kleineren Umfang. Anstelle standardisierter Fragen stehen individualisierte Fragen im Vordergrund, die auf Informationen abzielen, die für Außenstehende nicht ohne Weiteres zugänglich sind (vgl. (Fantapié Altobelli, 2017, S. 357)). Ein Leitfadeninterview eignet sich insbesondere dann, wenn der Interviewer mit dem Thema vertraut ist oder es gezielt eingrenzen kann. In beiden Fällen ermöglichen vorab formulierte Fragen eine strukturierte Gesprächsführung (vgl. (Porst, 2015, S. 95)). Das Experteninterview stellt eine besondere Form des Leitfadeninterviews dar, bei der der Fokus auf dem Fachwissen und der Praxiserfahrung der befragten Person liegt. Dies erlaubt es, zielgerichtete und komplexere Fragestellungen zu adressieren, die ausschließlich durch den Sachverstand eines Experten beantwortet werden können (vgl. (Baur und Blasius, 2022, S. 888–889)).

Nach Renner und Jacob lassen sich Interviews grundsätzlich in drei Formen unterteilen: hoch standardisierte, unstandardisierte sowie teilstandardisierte bzw. halbstrukturierte Interviews (vgl. (Renner und Jacob, 2020, S. 13–17)). Hoch standardisierte Interviews folgen einem strikten Ablaufplan, der weder in der Reihenfolge der Fragen noch in den vorgegebenen Antwortmöglichkeiten Abweichungen erlaubt, wodurch sie schnell und einfach durchführbar sind. Im Gegensatz dazu sind beim unstandardisierten Interview weder Fragen noch Antworten festgelegt, sondern lediglich Themen, die im Gesprächsverlauf frei vertieft werden können. Das teilstandardisierte bzw. halbstrukturierte Interview versucht schließlich, die Vorteile beider Formen zu vereinen: Es orientiert sich an einem Leitfaden mit vorab formulierten Fragen, lässt jedoch gleichzeitig Raum für ergänzende Fragen, die sich im Gesprächsverlauf ergeben. Damit schließt diese Form unmittelbar an das zuvor beschriebene Konzept des Leitfadeninterviews nach Porst an.

Der Leitfaden strukturiert den Ablauf aller Gespräche und ermöglicht so eine einheitliche Gesprächsführung. Er kann Erzählaufforderungen, vorformulierte Fragen sowie Stichpunkte enthalten und bei Bedarf auch Stimuli wie Bilder oder Geschichten einbeziehen. Dabei wird stets eine Balance zwischen Offenheit und Strukturiertheit angestrebt. Bei der Erstellung empfiehlt sich ein dreistufiges Vorgehen: Zunächst werden möglichst offene Fragen gestellt, die dem Befragten freie Antworten ermöglichen und so alle relevanten Informationen erschließen. Anschließend können gezielte Nachfragen zu Themen gestellt werden, die bisher unbeantwortet oder unzureichend behandelt wurden. Abschließend werden vorformulierte Fragen in einer logischen Reihenfolge an den Interviewten gerichtet (vgl. (Baur und Blasius, 2022, S. 881–883)).

Als Experten können Personen herangezogen werden, die über ein überdurchschnittliches, umfangreiches Wissen oder eine besondere fachliche Tiefe in einem bestimmten Bereich verfügen. Dies umfasst sowohl Insiderwissen, das für Außenstehende nur schwer zugänglich ist, als auch einen allgemein vertieften Wissensstand im jeweiligen Fachgebiet. Expertenwissen beschränkt sich dabei nicht auf die Berufswelt: Auch Personen, die sich ein spezifisches Thema eigenständig erschlossen oder darin besondere Fähigkeiten entwickelt haben, können in diesen Bereichen als Experten gelten. Im Mittelpunkt der Interviews steht die fachliche Expertise der Befragten und nicht ihre persönliche Lebenssituation. Den Interviewpartnern wird dabei verdeutlicht, welche bedeutsame Rolle ihr Wissen für die Beantwortung der Forschungsfrage einnimmt (vgl. (Baur und Blasius, 2022, S. 887–888)).

4 Auswirkungen von KI-Textgenerierung auf die Wissensarbeit (Ergebnisse der Literaturanalyse)

[Text]

4.1 Veränderungen von Arbeitsprozessen

Die Integration von Large Language Models (LLMs) führt dazu, dass Arbeitsprozesse in der Wissensarbeit nicht mehr nur auf der Ebene einzelner Aufgaben (Tasks), sondern konsequent auf der Ebene gesamter Arbeitsabläufe (Workflows) neu gestaltet werden müssen (vgl. (Yee *u. a.*, 2025), S. 35). Der entscheidende Mehrwert entsteht dabei durch ein umfassendes Workflow-Redesign, bei dem Aufgaben dekonstruiert werden, um Aktivitäten zu identifizieren, die durch KI substituiert, ergänzt oder grundlegend transformiert werden können (vgl. (Jesuthasan, 2025), S. 2). Ein erfolgreiches Redesign zeichnet sich dadurch aus, dass bisher über verschiedene Rollen fragmentierte Aktivitäten integriert und Übergabepunkte zwischen Mensch und Maschine optimiert werden (vgl. (Johansson *u. a.*, 2026b), S. 19).

In diesem Kontext verschiebt sich die Rolle des Wissensarbeiters bei SAP weg vom reinen Ausführer hin zu einem Orchestrator und Validator, der die von KI-Agenten erstellten Entwürfe steuert, prüft und finalisiert (vgl. (Yee *u. a.*, 2025), S. 42f.; (Weiss und Gesien, 2024), S.14). Da KI-Systeme zunehmend in der Lage sind, komplexe Workflows end-to-end zu unterstützen, müssen Unternehmen Rollen und Entscheidungspunkte aktiv auf diese hybride Zusammenarbeit ausrichten (vgl. McKinsey Global Institute 2025, S. 52). Zur organisatorischen Absicherung dieser neuen Verantwortlichkeiten ist eine klare Zuweisung nach der RACI-Methode notwendig, um eindeutig zu definieren, welche menschliche Instanz für die KI-generierten Ergebnisse letztlich rechenschaftspflichtig (Accountable) bleibt (vgl. André & Bauer et al. 2021, S. 14). Erst durch dieses systemische Überdenken der Prozessarchitektur, anstatt KI lediglich als punktuell Werkzeug einzusetzen, lassen sich signifikante Produktivitätsgewinne realisieren (vgl. McKinsey Global Institute 2025, S. 35).

4.2 Veränderungen der Kompetenzprofile

Die Anforderungen an Wissensarbeiter wandeln sich durch den Einsatz von LLMs grundlegend von reinem Fachwissen hin zu prozessübergreifenden Metakompetenzen (vgl. André & Bauer et al. 2021, S. 23). Während die Bedeutung klassischer digitaler Grundfertigkeiten tendenziell abnimmt, gewinnen Fähigkeiten in der Mensch-Maschine-Interaktion (MMI), fortgeschrittene Datenkompetenz und ein tieferes statistisches Verständnis massiv an Relevanz (vgl. André & Bauer et al. 2021, S. 27–28). Klassische Fachkompetenz verliert dabei an relativer Gewich-

tung, während Reflexionskompetenz und Entscheidungsfähigkeit zu neuen Kernfeilern der beruflichen Handlungsfähigkeit werden (vgl. André & Bauer et al. 2021, S. 29).

Besonders kritisch wird hierbei die Fähigkeit zum kritischen Denken, um KI-generierte Inhalte auf Bias zu prüfen und fundierte Urteile zu fällen, statt Informationen ungeprüft zu übernehmen (vgl. Deloitte 2024). Die Dynamik dieses Wandels ist außergewöhnlich hoch, da in KI-exponierten Bereichen ständig neue Anforderungen entstehen, was die Halbwertszeit von Wissen drastisch verkürzt (vgl. PwC 2026). Diese Entwicklung macht Anpassungsfähigkeit sowie lebenslanges Lernen von einer Zusatzqualifikation zur operativen Notwendigkeit für Wissensarbeiter (vgl. (Kusterer, 2008, S. 17); André & Bauer et al. 2021, S. 33). Ergänzend zeigt der Fokus auf Skill-Partnerschaften, dass wissenstypische Kernkompetenzen durch die Technologie nicht einfach ersetzt, sondern in ihrer Anwendung grundlegend transformiert werden (vgl. McKinsey Global Institute 2025, S. 21). Wissensarbeiter müssen daher künftig in der Lage sein, KI-Systeme als Partner in einem hybriden Arbeitsumfeld zu steuern, wobei die menschliche Urteilsfähigkeit insbesondere bei komplexen oder ethisch sensiblen Entscheidungsprozessen unverzichtbar bleibt (vgl. Afroogh et al. 2024, S. 2).

4.3 Chancen und Risiken

Der Einsatz von LLMs in der Wissensarbeit ist durch eine ausgeprägte Ambivalenz zwischen erheblichen Produktivitätspotenzialen und fundamentalen neuen Risiken geprägt (vgl. Afroogh et al. 2024, S. 9). Unternehmen mit hoher KI-Exposition verzeichnen bereits heute signifikante Vorteile bei der Neugestaltung ihrer Arbeitskraft (vgl. PwC 2026). Eine zentrale theoretische Chance liegt in der Transformation des organisationalen Wissens: LLMs fungieren als Katalysatoren für die Externalisierung von implizitem Expertenwissen, indem sie unstrukturierte Informationen synthetisieren und für die gesamte Organisation nutzbar machen (vgl. (Kusterer, 2008, S. 19); André & Bauer et al. 2021, S. 7). Dies ermöglicht es, routinierte Analyseaufgaben zu substituieren und Ressourcen in strategische Aktivitäten zu investieren (vgl. Jesuthasan 2025, S. 3).

Demgegenüber stehen signifikante operationale Risiken. Die Leistungsfähigkeit von LLMs folgt der Logik einer sogenannten „Jagged Technological Frontier“: Während Aufgaben innerhalb dieser Grenze mit hoher Qualität automatisiert werden, führen Aufgaben außerhalb zu schwer erkennbaren Fehlern und Halluzinationen (vgl. (Dell'Acqua u. a., 2026, S. 405)). Wenn fehlerhafte Inhalte ungeprüft in interne Systeme einfließen, droht ein massiver Vertrauensverlust, der letztlich in einer „Todesspirale der Wissensbasis“ enden kann, bei der sinkende Datenqualität und abnehmendes Vertrauen zum Kollaps des Wissensmanagements führen (vgl. (Kusterer, 2008, S. 63)). Ein weiteres strategisches Risiko betrifft die langfristige Kompetenzentwicklung, da durch die Automatisierung von Standardaufgaben klassische Lernpfade für Junior-Rollen unter Druck geraten und der Aufbau von erfahrungsbasiertem Urteilsvermögen erschwert wird

(vgl. PwC 2026). Ohne eine etablierte KI-Führungskultur, die kritisches Denken fördert und Verantwortlichkeiten eindeutig zuweist, riskieren Unternehmen, dass die Koordinationskosten die tatsächlichen Produktivitätsgewinne übersteigen (vgl. Deloitte 2024; André & Bauer et al. 2021, S. 33).

Tägliche Aktivitäten: Vom Entwurf zur Revision In der täglichen Arbeit verschieben sich die Schwerpunkte von der manuellen Erstellung einfacher Textbausteine hin zu komplexen, urteilsbasierten Aufgaben. In der pharmazeutischen Industrie führt dies beispielsweise dazu, dass „Medical Writer“ nicht mehr primär Berichte entwerfen, sondern KI-generierte klinische Dokumentationen auf Genauigkeit, Konformität und klinisches Urteilsvermögen prüfen (vgl. (Johansson u. a., 2026b, S. 19); (Yee u. a., 2025, S. 46)). Dieser Trend zur „Augmentierung“ statt reiner Ersetzung zeigt sich auch im Rechtswesen, wo LLMs die Recherche und erste Vertragsentwürfe beschleunigen, während die juristische Bewertung und die Berücksichtigung spezifischer Mandantenpräferenzen weiterhin eine menschliche Kernkompetenz bleiben (vgl. (Emerson u. a., 2026, S. 10)).

, S. 7; , S. 24)

Tech savviness

Security

Quality

Ethical Compass

5 Ergebnisse der Experteninterviews, Diskussion und Handlungsempfehlungen

[Text]

5.1 Durchführung und Auswertung der Interviews

[Text]

5.2 Diskussion der Ergebnisse im Abgleich mit der Literatur

[Text]

5.3 Limitationen der Untersuchung

[Text]

5.4 Handlungsempfehlungen

[Text]

6 Fazit und Ausblick

[Text]

6.1 Zusammenfassung der Ergebnisse

[Text]

6.2 Ausblick

[Text]

Anhang

A1: Übersicht eingesetzter KI-Werkzeuge

Werkzeug	Beschreibung der Nutzung
ChatGPT	• Verständnis von Grundbegriffen im Themenfeld – Beschreibung (Kapitel X.X) • Recherche/Identifikation von Literaturstellen zu – Thema (Kapitel X) • ...
ChatPDF	• Recherche und Zusammenfassung von wissenschaftlichen Studien im Themenfeld – Thema (Kapitel X und X.X) • ...
Microsoft CoPilot	• Nutzung von CoPilot in Microsoft Word 365 für Korrektur- und Formulierungshilfe (gesamt) • Übersetzung von Textpassagen zwischen deutsch und englisch (gesamt)

Tabelle 1: Übersicht über die Nutzung von KI-basierten Werkzeugen

Interviewleitfaden: LLMs in der Wissensarbeit bei SAP

Interviewleitfaden: KI-Tools in der Wissensarbeit bei SAP

Datum und Uhrzeit: xx.xx.xxxx um xx:xx Uhr	Ort: Microsoft Teams-Besprechung
Befragter: xxx	Interviewer: Anton Nguyen

Alle Daten werden anonymisiert behandelt und nicht weitergegeben. Die Arbeit ist nur meinem wissenschaftlichen Betreuer an der DHBW Ravensburg sowie ausgewählten Kollegen intern bei SAP zugänglich.

	Inhaltliche Aspekte	(Nach-)Fragen mit obligatorischer Formulierung
Erzählaufforderung	Würdest du dich zu Beginn kurz vorstellen und etwas über deinen beruflichen Hintergrund und deine aktuellen Aufgaben erzählen?	
Erzählaufforderung	Wie nutzt du KI-Tools wie ChatGPT oder Claude aktuell in deinem Arbeitsalltag – wofür genau setzt du sie ein?	<i>Gibt es bestimmte Aufgaben oder Situationen, in denen du sie besonders häufig nutzt?</i>
Erzählaufforderung	Was hat sich bei deiner Arbeit konkret verändert, seit du solche KI-Tools nutzt?	<i>Was hat sich dadurch für dein Team oder deine Abteilung verändert?</i>
Erzählaufforderung	Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist oder ob du sie lieber selbst übernimmst?	<i>Fällt dir ein konkretes Beispiel aus deinem Bereich dazu ein?</i>
Erzählaufforderung	KI-Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	<i>Hattest du selbst schon einmal so eine Situation? Was ist passiert, und wie bist du damit umgegangen?</i>
Erzählaufforderung	Worauf achtest du beim Thema Datenschutz und Vertraulichkeit, wenn du diese Tools bei SAP nutzt?	<i>Gibt es dazu klare Vorgaben oder Regeln in deinem Bereich?</i>
Erzählaufforderung	Prüfst und überarbeitest du inzwischen mehr KI-generierte Inhalte, statt Dinge komplett selbst von null zu erstellen?	<i>Was musstest du dafür neu lernen, oder welche Fähigkeiten sind dadurch wichtiger geworden?</i>
Erzählaufforderung	Hast du manchmal das Gefühl, dass du dich zu sehr auf die Tools verlässt und dadurch etwas verlernst?	
Erzählaufforderung	Wo bringt dir KI am meisten Zeit- oder Qualitätsvorteil, und wo stößt sie an ihre Grenzen?	<i>Fallen dir weitere Vor- oder Nachteile ein, die wir noch nicht angesprochen haben?</i>
Erzählaufforderung	Was sollte SAP als Unternehmen tun, damit die Vorteile genutzt werden, ohne dass die Risiken überhandnehmen?	<i>Was würdest du speziell für deinen eigenen Bereich empfehlen?</i>
Abschlussfrage:	Gibt es sonst noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist und das wir noch nicht besprochen haben?	

Literaturverzeichnis

Agrawal, A., Gans, J.S. und Goldfarb, A. (2024) „Artificial intelligence adoption and system-wide change“, *Journal of Economics & Management Strategy*, 33(2), S. 327–337. Verfügbar unter: <https://doi.org/10.1111/jems.12521>.

Baur, N. und Blasius, J. (Hrsg.) (2022) *Handbuch Methoden der empirischen Sozialforschung*. 3. Aufl. Wiesbaden: Springer VS. Verfügbar unter: <https://doi.org/10.1007/978-3-658-37985-8>.

Bender, E.M. u. a. (2021) „On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?“, in *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. New York, NY, USA: Association for Computing Machinery, S. 610–623. Verfügbar unter: <https://doi.org/10.1145/3442188.3445922>.

Bogner, A., Littig, B. und Menz, W. (2014) *Interviews mit Experten: Eine praxisorientierte Einführung*. Wiesbaden: Springer VS (Qualitative Sozialforschung). Verfügbar unter: <https://doi.org/10.1007/978-3-531-19416-5>.

Brynjolfsson, E., Li, D. und Raymond, L.R. (2025) „Generative AI at Work“, *The Quarterly Journal of Economics*, 140(2), S. 889–942. Verfügbar unter: <https://doi.org/10.1093/qje/qjae044>.

Bubeck, S. u. a. (2023) *Sparks of Artificial General Intelligence: Early Experiments with GPT-4*. arXiv. Verfügbar unter: <https://doi.org/10.48550/arXiv.2303.12712>.

Burger, D. (2011) *Computergestützter organisationaler Wissenstransfer und Wissensgenerierung: Ein Experteninterview basierter Forschungsansatz*. Wiesbaden: VS Verlag für Sozialwissenschaften (SpringerLink Bücher). Verfügbar unter: <https://doi.org/10.1007/978-3-531-93047-3>.

Chen, Q. u. a. (2025) „Large language models at work in China's labor market“, *China Economic Review*, 92, S. 102413. Verfügbar unter: <https://doi.org/10.1016/j.chieco.2025.102413>.

Dell'Acqua, F. u. a. (2026) „Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality“, *Organization Science*, S. 1–21. Verfügbar unter: <https://doi.org/10.1287/orsc.2025.21838>.

Drucker, P.F. (1999) „Knowledge-Worker Productivity: The Biggest Challenge“, *California Management Review*, 41(2), S. 79–94.

Eisenhardt, K.M. und Graebner, M.E. (2007) „Theory Building from Cases: Opportunities and Challenges“, *Academy of Management Journal*, 50(1), S. 25–32. Verfügbar unter: <https://doi.org/10.5465/AMJ.2007.24160888>.

Eloundou, T. u. a. (2023) *GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models*. arXiv. Verfügbar unter: <https://doi.org/10.48550/arXiv.2303.10130>.

Emerson, G. u. a. (2026) *AI Will Reshape More Jobs Than It Replaces*. Verfügbar unter: <https://web-assets.bcg.com/pdf-src/prod-live/ai-will-reshape-more-jobs-than-it-replaces.pdf> (Zugegriffen: 23 Juli 2026).

Fantapié Altobelli, C. (2017) *Marktforschung: Methoden, Anwendungen, Praxisbeispiele*. 3. Aufl. Konstanz und München: UVK Verlagsgesellschaft mbH. Verfügbar unter: <https://doi.org/10.36198/9783838587219>.

Felten, E., Raj, M. und Seamans, R. (2023) „Occupational Heterogeneity in Exposure to Generative AI“, *SSRN Electronic Journal* [Preprint], (4414065). Verfügbar unter: <https://doi.org/10.2139/ssrn.4414065>.

Gerlich, M. (2025) „AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking“, *Societies*, 15(1), S. 6. Verfügbar unter: <https://doi.org/10.3390/soc15010006>.

Heerwagen, J.H. u. a. (2004) „Collaborative Knowledge Work Environments“, *Building Research & Information*, 32(6), S. 510–528. Verfügbar unter: <https://doi.org/10.1080/09613210412331313025>.

Janz, B.D., Colquitt, J.A. und Noe, R.A. (1997) „Knowledge Worker Team Effectiveness: The Role of Autonomy, Interdependence, Team Development, and Contextual Support Variables“, *Personnel Psychology*, 50(4), S. 877–904. Verfügbar unter: <https://doi.org/10.1111/j.1744-6570.1997.tb01486.x>.

Jesuthasan, R. (2025) „Want AI-Driven Productivity? Redesign Work“, *MIT Sloan Management Review*, 66(4). Verfügbar unter: <https://stsroundtable.com/wp-content/uploads/AI.Productivity.Work-Redesign.pdf> (Zugegriffen: 22 Juli 2026).

Jiao, J. u. a. (2025) *Generative AI and LLMs in Industry: A Text-Mining Analysis and Critical Evaluation of Guidelines and Policy Statements Across Fourteen Industrial Sectors*. Verfügbar unter: <https://arxiv.org/abs/2501.00957>.

Johansson, S. u. a. (2026a) *Agents, robots, and us: How AI reshapes work and skills in Europe*. technical report.

Johansson, S. u. a. (2026b) *Agents, Robots, and Us: How AI Reshapes Work and Skills in Europe*. Report. Verfügbar unter: <https://www.mckinsey.com/~media/mckinsey/mckinsey%20global%20institute/our%20research/agents%20robots%20and%20us%20how%20ai%20reshapes%20work%20and%20skills%20in%20europe/agents-robots-and-us-how-ai-reshapes-work-and-skills-in-europe.pdf> (Zugegriffen: 22 Juli 2026).

Kusterer, S. (2008) *Qualitätssicherung im Wissensmanagement: Eine Fallstudienanalyse*. Wiesbaden: Gabler Edition Wissenschaft.

Lee, H.-P. u. a. (2025) „The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Stewardship“, in *Proceedings of the CHI Conference on*

Human Factors in Computing Systems (CHI '25). ACM. Verfügbar unter: <https://doi.org/10.1145/3706598.3713778>.

Noy, S. und Zhang, W. (2023) „Experimental evidence on the productivity effects of generative artificial intelligence“, *Science*, 381(6654), S. 187–192. Verfügbar unter: <https://doi.org/10.1126/science.adh2586>.

Porst, R. (2015) „Arten von Befragungen und Befragungstechniken“, *Gesellschaft, Wirtschaft, Politik (GWP)*, 64(1), S. 93–103. Verfügbar unter: <https://www.budrich-journals.de/>.

Renner, K.-H. und Jacob, N.-C. (2020) *Das Interview: Grundlagen und Anwendung in Psychologie und Sozialwissenschaften*. Berlin and Heidelberg: Springer (Basiswissen Psychologie). Verfügbar unter: <https://doi.org/10.1007/978-3-662-60441-0>.

Snyder, H. (2019) „Literature review as a research methodology: An overview and guidelines“, *Journal of Business Research*, 104, S. 333–339. Verfügbar unter: <https://doi.org/10.1016/j.jbusres.2019.07.039>.

Trenerry, B. u. a. (2021) „Preparing Workplaces for Digital Transformation: An Integrative Review and Framework of Multi-Level Factors“, *Frontiers in Psychology*, 12, S. 620766. Verfügbar unter: <https://doi.org/10.3389/fpsyg.2021.620766>.

Weiss, C. und Gesien, J. (2024) *From Reaction to Action: Leading in the Age of GenAI — Leadership Competences as the Key Success Factor in the Age of GenAI*. Whitepaper. Verfügbar unter: <https://www2.deloitte.com/content/dam/Deloitte/de/Documents/human-capital/Deloitte-Leadership-GenAI.pdf> (Zugegriffen: 22 Juli 2026).

Woodruff, A. u. a. (2024) „How Knowledge Workers Think Generative AI Will (Not) Transform Their Industries“, in *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '24)*. ACM. Verfügbar unter: <https://doi.org/10.1145/3613904.3642700>.

Yee, L. u. a. (2025) *Agents, Robots, and Us: Skill Partnerships in the Age of AI*. Report. Verfügbar unter: <https://www.mckinsey.com/~media/mckinsey/mckinsey%20global%20institute/our%20research/agents%20robots%20and%20us%20skill%20partnerships%20in%20the%20age%20of%20ai/agents-robots-and-us-skill-partnerships-in-the-age-of-ai.pdf> (Zugegriffen: 22 Juli 2026).

Yin, R.K. (2014) *Case Study Research: Design and Methods*. Thousand Oaks, California: SAGE Publications.

Selbständigkeitserklärung

Ich versichere hiermit, dass ich die vorliegende Projektarbeit mit dem Thema

Wissensarbeit im Zeitalter generativer Künstlicher Intelligenz bei SAP

Eine systematische Analyse der Auswirkungen von Large Language Models auf Arbeitsprozesse und Kompetenzprofile

selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe und diese Arbeit bei keiner anderen Prüfung mit gleichem oder vergleichbarem Inhalt vorgelegt habe und diese bislang nicht veröffentlicht wurde. Des Weiteren versichere ich, dass die eingereichte elektronische Fassung mit der gedruckten Ausfertigung übereinstimmt.

Ort, Datum

Unterschrift

Erklärung und Nutzungsdokumentation zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten als Prüfungsleistungen

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts „Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten als Prüfungsleistungen im prüfungsrechtlichen Kontext“ Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Arbeit habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlicher oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Verfasser:in der Arbeit die volle Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, sind diese zu den Produktnamen, den formulierten Eingaben (Prompts), den Einsatzzwecken und der entsprechenden Seiten-/Bereichsreferenzierung auf die Arbeit im KI-Verzeichnis am Ende der Arbeit vollständig ausgewiesen und im Text belegt (z.B. als Fußnote).

Ort, Datum

Unterschrift