

Wissensarbeit im Zeitalter generativer Künstlicher Intelligenz bei SAP

Eine systematische Analyse der Auswirkungen von Large Language Models auf Arbeitsprozesse und Kompetenzprofile

2. Projektarbeit

des Studienganges Wirtschaftsinformatik-Business Engineering
an der DHBW Ravensburg

von Anton Nguyen

Kurs:	WWIBE224
Matrikelnummer:	5282932
Dualer Partner:	SAP SE, 88677 Markdorf
Projektbetreuer:	Dagmar Schulte
Gutachter DHBW:	Kerem Ünal
Abgabedatum:	15.09.2026

Inhaltsverzeichnis

Abkürzungsverzeichnis.....	III
Abbildungsverzeichnis.....	IV
Tabellenverzeichnis.....	V
1 Einleitung.....	1
1.1 Problemstellung.....	1
1.2 Zielsetzung und Aufbau der Arbeit.....	1
2 Theoretische Grundlagen.....	3
2.1 Wissensarbeit im digitalen Wandel.....	3
2.2 Textgenerierung mittels Künstlicher Intelligenz: Large Language Models und Einsatzmöglichkeiten.....	5
3 Forschungsdesign und Vorgehensweise.....	7
3.1 Fallstudienanalyse nach Yin.....	7
3.2 Systematische Literaturanalyse.....	11
3.3 Experteninterviews.....	14
4 Auswirkungen von KI-Textgenerierung auf die Wissensarbeit (Ergebnisse der Literaturanalyse).....	16
4.1 Veränderungen von Arbeitsprozessen.....	16
4.2 Veränderungen der Kompetenzprofile.....	19
4.3 Chancen und Risiken.....	24
5 Experteninterviews, Diskussion und Handlungsempfehlungen.....	26
5.1 Durchführung und Auswertung der Interviews.....	26
5.2 Diskussion der Ergebnisse im Abgleich mit der Literatur.....	29
5.3 Limitationen der Untersuchung.....	32
5.4 Handlungsempfehlungen.....	33
6 Fazit und Ausblick.....	36
6.1 Zusammenfassung der Ergebnisse.....	36
6.2 Ausblick.....	37
Anhang.....	39
Literaturverzeichnis.....	45

Abkürzungsverzeichnis

ABAP	Advanced Business Application Programming
AI	Artificial Intelligence
BCG	Boston Consulting Group
CEO	Chief Executive Officer
DHBW	Duale Hochschule Baden-Württemberg
EKX	Enterprise Knowledge Experience
ERP	Enterprise Resource Planning
GenAI	Generative Artificial Intelligence
HANA	High-performance ANalytic Appliance
KI	Künstliche Intelligenz
KPI	Key Performance Indicator
LLM	Large Language Model
LLMOps	Large Language Model Operations
ML	Machine Learning
MS	Microsoft
PCG	Productivity Consulting Group
PII	Personally Identifiable Information
PM	Projektmanagement
PwC	PricewaterhouseCoopers
SAP	Systeme, Anwendungen und Produkte in der Datenverarbeitung
UI	User Interface
UI5	User Interface 5
US	United States
USA	United States of America

Abbildungsverzeichnis

Abbildung 1	Interviewleitfaden: KI Tools in der Wissensarbeit bei SAP.....	40
--------------------	--	----

Tabellenverzeichnis

Tabelle 1	Übersicht über die Nutzung von KI-basierten Werkzeugen.....	39
Tabelle 2	Gesprächsprotokoll: Interview mit Person A — KI Tools in der Wissensarbeit bei SAP.....	41
Tabelle 3	Gesprächsprotokoll: Interview mit Person B — KI Tools in der Wissensarbeit bei SAP.....	42
Tabelle 4	Gesprächsprotokoll: Interview mit Person C — KI Tools in der Wissensarbeit bei SAP.....	43
Tabelle 5	Gesprächsprotokoll: Interview mit Person D — KI Tools in der Wissensarbeit bei SAP.....	44

1 Einleitung

Die fortschreitende Digitalisierung der Arbeitswelt führt zu grundlegenden Veränderungen von Arbeitstätigkeiten und -abläufen und schafft damit neue Rahmenbedingungen für die Wissensarbeit (vgl. (Arlinghaus, 2017, S.2)). Anders als frühere Digitalisierungsschritte, die vor allem repetitive Tätigkeiten betrafen, zielt generative KI erstmals unmittelbar auf kognitive Kernaufgaben von Wissensarbeitenden ab (vgl. (Dell'Acqua *u. a.*, 2026, S. 1); (Eloundou *u. a.*, 2023, S. 1-3)). Für Unternehmen wie SAP, deren Wertschöpfung wesentlich auf wissensintensiver Arbeit beruht, ergibt sich daraus eine unmittelbare strategische Relevanz. Wie diese Werkzeuge Arbeitsprozesse und Kompetenzprofile verändern und welche Chancen sowie Risiken damit verbunden sind, ist für die Gestaltung zukunftsfähiger Arbeitsumgebungen von zentraler Bedeutung.

1.1 Problemstellung

Für Unternehmen wie SAP, die im Zentrum der digitalen Transformation von Geschäftsprozessen stehen und gleichzeitig eine wissensintensive Belegschaft beschäftigen, ist diese Entwicklung von besonderer Tragweite. KI-Tools wie Large Language Models werden bei SAP bereits aktiv in Arbeitsprozessen eingesetzt, und der Einsatz wächst kontinuierlich. Dennoch fehlt bislang eine systematische Untersuchung, wie sich diese Nutzung konkret auf Arbeitsprozesse und Kompetenzprofile der Mitarbeitenden auswirkt und welche Chancen und Risiken sich daraus für die Organisation ergeben. Einerseits bergen Large Language Models erhebliche Potenziale zur Entlastung von Routinetätigkeiten und zur Aufwertung strategisch-inhaltlicher Arbeit. Andererseits arbeiten diese Systeme nicht deterministisch, neigen zu Halluzinationen und stellen neue Anforderungen an kritisches Denken, Datenschutzkompetenz und ethisches Urteilsvermögen, für die in vielen Unternehmen noch keine ausreichenden Strukturen bestehen. Daraus ergibt sich die zentrale Forschungsfrage dieser Arbeit, nämlich wie KI-Textgenerierung Arbeitsprozesse und Kompetenzprofile in der Wissensarbeit bei SAP verändert und welche Chancen und Risiken sich daraus ergeben.

1.2 Zielsetzung und Aufbau der Arbeit

Die vorliegende Arbeit soll diese Frage beantworten, indem sie die Auswirkungen von KI-Textgenerierung auf die Wissensarbeit bei SAP systematisch analysiert und daraus konkrete Handlungsempfehlungen ableitet. Dazu folgt die Arbeit dem Einzelfallstudiendesign nach Yin und kombiniert zwei Erhebungsmethoden, nämlich eine systematische Literaturanalyse nach Snyder als sekundäre Evidenzbasis sowie leitfadengestützte Experteninterviews als primäre Erhebungsmethode.

Kapitel 2 legt die theoretischen Grundlagen, indem es den Begriff der Wissensarbeit im digitalen Wandel definiert und Large Language Models in ihrer technischen Funktionsweise sowie ihren Einsatzmöglichkeiten einordnet. Das darauffolgende Kapitel 3 beschreibt das Forschungsdesign und erläutert die methodische Vorgehensweise nach Yin. Es begründet zunächst die Wahl der Einzelfallstudie als Forschungsdesign und beschreibt den sechsstufigen Prozess nach Yin. In der Prepare-Phase wird der Interviewleitfaden entwickelt und geeignete Interviewpartner werden identifiziert. In der Collect-Phase kommen beide Methoden zum Einsatz, wobei die systematische Literaturanalyse nach Snyder als sekundäre Evidenzbasis dient und die Experteninterviews als primäre Datenerhebung durchgeführt werden. In der anschließenden Analyze-Phase werden die Befunde beider Methoden mithilfe von Pattern Matching und Explanation Building zusammengeführt. Die Share-Phase umfasst schließlich die Aufbereitung und Kommunikation der Ergebnisse in der vorliegenden Arbeit. Aufbauend darauf stellt Kapitel 4 die Ergebnisse der Literaturanalyse dar und beleuchtet Veränderungen in Arbeitsprozessen und Kompetenzprofilen sowie die damit verbundenen Chancen und Risiken. Im anschließenden Kapitel 5 werden die Ergebnisse der Experteninterviews mit vier Wissensarbeitenden bei SAP präsentiert, mit der Literatur abgeglichen und in Handlungsempfehlungen für die Organisation überführt. Abgeschlossen wird die Arbeit durch Kapitel 6 mit einer Zusammenfassung der zentralen Erkenntnisse und einem Ausblick auf weiterführende Forschungsfragen.

Die Arbeit unterliegt dabei einigen methodischen Einschränkungen. Als Einzelfallstudie mit vier Interviewpartnerinnen und Interviewpartnern, von denen drei aus derselben Organisationseinheit stammen, sind die Ergebnisse nicht ohne Weiteres auf andere Unternehmen übertragbar. Darüber hinaus entwickelt sich das Forschungsfeld der generativen KI außergewöhnlich schnell, sodass die Befunde als Momentaufnahme zu verstehen sind und keinen Anspruch auf abschließende Gültigkeit erheben können.

2 Theoretische Grundlagen

Generative Künstliche Intelligenz verbreitet sich zunehmend in der Arbeitswelt und wird in Wissenschaft und Praxis als potenziell transformative Kraft für die Wissensarbeit diskutiert (vgl. (Woodruff *u. a.*, 2024, S. 1)). Besonders Large Language Models markieren in diesem Zusammenhang einen bedeutenden Entwicklungsschritt, da sie zunehmend Aufgabenbereiche erschließen, die bislang überwiegend menschlicher Expertise vorbehalten waren, wie etwa komplexes Sprachverständnis, kreative Textgenerierung und analytische Problemlösung (vgl. (Dell'Acqua *u. a.*, 2026, S.403); (Eloundou *u. a.*, 2023, S.1-3)).

Um die Auswirkungen dieser Entwicklung auf die Wissensarbeit bei SAP im weiteren Verlauf der Arbeit systematisch analysieren zu können, werden in diesem Kapitel zunächst die theoretischen Grundlagen erarbeitet, auf denen die nachfolgende Untersuchung aufbaut. Abschnitt 2.1 definiert zunächst den Begriff der Wissensarbeit und beschreibt den durch LLMs ausgelösten Wandel. Abschnitt 2.2 erläutert anschließend die technische Funktionsweise von Large Language Models sowie deren Einsatzmöglichkeiten in der Wissensarbeit, wobei die Betrachtung bewusst auf die Textgenerierung beschränkt bleibt, da diese im unternehmerischen Kontext die dominierende Anwendungsform darstellt.

Zur begrifflichen Klarheit sei vorab darauf hingewiesen, dass generative KI der übergeordnete Technologiebereich ist, der neben Textgenerierung auch Anwendungen wie Bild-, Audio- und Videogenerierung umfasst. Large Language Models sind die konkrete Technologieklasse innerhalb dieses Bereichs, die auf Sprachverarbeitung spezialisiert ist und Textgenerierung ermöglicht. KI-Textgenerierung beschreibt entsprechend die Anwendung dieser Modelle. In der vorliegenden Arbeit werden diese Begriffe daher nicht synonym verwendet, sondern beziehen sich jeweils auf diese spezifischen Bedeutungsebenen.

2.1 Wissensarbeit im digitalen Wandel

Der Begriff des Wissensarbeitenden wurde durch Peter Drucker geprägt (vgl. (Drucker, 1999)). Unter Wissensarbeit wird dabei eine Form spezialisierter Arbeit verstanden, bei der nicht physische Ressourcen, sondern Wissen die zentrale produktive Grundlage bildet (vgl. (Woodruff *u. a.*, 2024, S. 2)). Dementsprechend wird Wissen in Unternehmen häufig als eine der wichtigsten Ressourcen betrachtet und kann einen wesentlichen Wettbewerbsvorteil darstellen (vgl. (Kusterer, 2008, S. 1)). Wissensarbeit setzt ein hohes Maß an formaler Bildung voraus und erfordert die Fähigkeit, theoretisches und analytisches Wissen in der Praxis anzuwenden, sowie die Bereitschaft zum kontinuierlichen Lernen (vgl. (Drucker, 1994)). Des Weiteren wird Wissen im ressourcenbasierten Ansatz als immaterielle Ressource verstanden, die aufgrund ihres Wertes, ihrer Seltenheit sowie ihrer eingeschränkten Imitier- und Substituierbarkeit zur Schaffung eines strategischen Wettbewerbsvorteils beitragen kann (vgl. (Kusterer, 2008, S. 13)). Die

zunehmende Digitalisierung verändert die Rahmenbedingungen der Arbeit grundlegend und beeinflusst damit auch die Wissensarbeit (vgl. (Trenerry u. a., 2021, S. 1–2)). Insbesondere digitale Technologien wie künstliche Intelligenz, Automatisierung, Cloud Computing und das Internet of Things verändern die Art und Weise, wie Arbeit organisiert und ausgeführt wird (vgl. (Trenerry u. a., 2021, S. 1–2)). Als spezifische Gruppe von Arbeitnehmenden, deren zentrale Ressource Wissen ist (vgl. (Woodruff u. a., 2024, S. 2)), sind Wissensarbeitende von diesen Veränderungen unmittelbar betroffen. Darüber hinaus ermöglichen digitale Technologien einen erleichterten Zugang zu Informationen und unterstützen die Zusammenarbeit über räumliche Grenzen hinweg, beispielsweise durch digitale Kommunikations- und Kollaborationstechnologien (vgl. (Trenerry u. a., 2021, S. 10)). Gleichzeitig verändern sich die Anforderungen an die Kompetenzen von Arbeitnehmenden, da digitale Fähigkeiten zunehmend notwendig werden, um Aufgaben in digitalen Arbeitsumgebungen ausführen zu können (vgl. (Trenerry u. a., 2021, S. 7)). Dies betrifft insbesondere Wissensarbeitende, deren Tätigkeiten auf der Verarbeitung, Analyse und Nutzung von Informationen beruhen (vgl. (Woodruff u. a., 2024, S. 2)).

Merkmale der Wissensarbeit

In der Literatur werden der Wissensarbeit häufig folgende Charakteristika zugeschrieben, die sie von manuellen oder rein administrativen Tätigkeiten abgrenzen:

- **Kognitive Intensität:** Wissensarbeit ist durch nicht-routinemäßige, kognitiv anspruchsvolle Tätigkeiten gekennzeichnet, die auf dem Aufbau, der Anwendung und der Verknüpfung spezialisierten intellektuellen Wissens beruhen (vgl. (Dell'Acqua u. a., 2026, S. 406)).
- **Autonomie und Verantwortung:** Wissensarbeitende entscheiden innerhalb definierter Grenzen autonom über die Herangehensweise an eine Aufgabe und tragen die Verantwortung für die Produktivität ihrer Arbeit (vgl. (Drucker, 1999, S. 84, S. 86)).
- **Kontinuierliches Lernen:** Wissensarbeit erfordert die fortwährende Bereitschaft, bestehendes Wissen zu aktualisieren und neue Fähigkeiten zu erwerben, da sich die Anforderungen in digitalisierten Arbeitsumgebungen kontinuierlich verändern (vgl. (Drucker, 1994)).

Herausforderungen im digitalen Wandel

Durch den Einzug von Large Language Models (LLMs) steht die Wissensarbeit vor einer tiefgreifenden Transformation, die neue **Herausforderungen** mit sich bringt.

1. **Die diskontinuierliche technologische Grenze (Jagged Frontier):** KI-Systeme zeigen in kognitiven Domänen eine ungleichmäßige Leistung. Während sie bei kreativen Aufgaben oft menschliche Experten übertreffen, können sie bei logisch ähnlich komplexen Aufgaben unvorhersehbar scheitern (vgl. (Dell'Acqua u. a., 2026, S. 403)).
2. **Wandel zur Stewardship-Rolle:** Die Tätigkeit von Wissensarbeitenden verlagert sich von der Erstellung hin zur Überwachung und Integration von KI-Outputs, was eine erhöhte kritische Reflexionsfähigkeit erfordert (vgl. (Lee u. a., 2025, S. 15)).

3. **Cognitive Offloading:** Die zunehmende Delegation kognitiver Aufgaben an KI-Systeme birgt die Gefahr einer Schwächung des kritischen Denkens sowie einer kognitiven Abhängigkeit (vgl. (Gerlich, 2025, S. 2)).
4. **Validierungsaufwand:** Da LLMs zu Halluzinationen und inhaltlich falschen, aber plausibel klingenden Ausgaben neigen, steigt der Aufwand für Verifizierungsprozesse (vgl. (Lee u. a., 2025, S. 15); (Brynjolfsson, Li und Raymond, 2025, S. 897); (Dell'Acqua u. a., 2026, S. 404)).

Um diese Herausforderungen einordnen zu können, bedarf es zunächst eines Überblicks über die technische Grundlage von LLMs sowie deren konkrete Einsatzmöglichkeiten in der Wissensarbeit.

2.2 Textgenerierung mittels Künstlicher Intelligenz: Large Language Models und Einsatzmöglichkeiten

Large Language Models (LLMs) zählen zu den bedeutendsten Entwicklungen innerhalb der jüngeren KI-Forschung (vgl. (Bubeck u. a., 2023, S. 4)). Es handelt sich dabei um neuronale Netzwerkmodelle, die anhand riesiger Mengen an Textdaten aus dem Internet trainiert werden. Das Modell lernt dabei, auf Basis eines gegebenen Kontextes die Wahrscheinlichkeit nachfolgender Tokens vorherzusagen (vgl. (Bubeck u. a., 2023, S. 4)). Obwohl der Begriff menschliche Sprache impliziert, lassen sich diese Techniken auch auf andere Formen sequenzieller Daten anwenden, etwa Computercode, Proteinsequenzen oder Schachpartien (vgl. (Eloundou u. a., 2023, S. 1)). Dabei bezeichnet der Begriff ein Modell, das auf extrem großen Datensätzen (oft im Tera- oder Petabyte-Bereich) trainiert wurde und über Milliarden von Parametern verfügt, um komplexe linguistische Strukturen abzubilden (vgl. (Woodruff u. a., 2024, Fn. 1)).

Technische Funktionsweise der Textgenerierung

Der Kern der Textgenerierung basiert auf der **wahrscheinlichkeitsbasierten Vorhersage** des nächsten Wortes (bzw. Tokens) in einer Sequenz (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 895); (Chen u. a., 2025, S. 14)). Der entscheidende Fortschritt gelang durch die Einführung von Transformer-Modellen, die einen sogenannten Attention-Mechanismus nutzen, der es dem System erlaubt, Wörtern innerhalb eines Textes unterschiedliche Relevanzgewichte zuzuweisen und so semantische Abhängigkeiten über weite Distanzen hinweg zu erfassen (vgl. (Chen u. a., 2025, S. 14); (Brynjolfsson, Li und Raymond, 2025, S. 896)). Anstatt expliziten linguistischen Regeln zu folgen, lernen diese Modelle durch statistische Korrelationen, welche Begriffe in einem bestimmten Kontext üblicherweise zusammen auftreten (vgl. (Jiao u. a., 2025, S. 1); (Brynjolfsson, Li und Raymond, 2025, S. 896)).

Einsatzmöglichkeiten in der Wissensarbeit

Im Gegensatz zur diskriminativen KI, die primär Daten klassifiziert, erzeugt generative KI eigenständig neue Inhalte, die menschlichen Erzeugnissen in ihrer Qualität nahekommen (vgl. (Felten, Raj und Seamans, 2023, S. 1); (Jiao *u. a.*, 2025, S. 2)). Aufgrund dieser Eigenschaften finden LLMs in der Wissensarbeit breite Anwendung, etwa bei der Texterstellung und Dokumentation, der Codegenerierung sowie der Zusammenfassung und Extraktion von Informationen aus umfangreichen Dokumenten (vgl. (Eloundou *u. a.*, 2023, S. 1-2); (Noy und Zhang, 2023, S. 1-2); (Chen *u. a.*, 2025, S. 14-15)).

Trotz dieser Potenziale bleibt die Herausforderung der **Halluzination** bestehen, da LLMs auf statistischen Wahrscheinlichkeiten für die Vorhersage des nächsten Tokens auf Basis des bisherigen Kontexts beruhen (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 895)) und dadurch inhaltlich falsche Aussagen mit hoher sprachlicher Überzeugungskraft generieren können (vgl. (Dell'Acqua *u. a.*, 2026, S.405); (Woodruff *u. a.*, 2024, S.7 und 23)). Eine kontinuierliche menschliche Validierung („Task Stewardship“) bleibt daher für die Qualitätssicherung in professionellen Kontexten unerlässlich (vgl. (Lee *u. a.*, 2025, S. 12–16)).

3 Forschungsdesign und Vorgehensweise

Eine Methode beschreibt eine systematische Vorgehensweise, mit der innerhalb eines festgelegten Ziels Erkenntnisse gewonnen werden können. Dabei zeichnen sich Methoden durch verschiedene charakteristische Merkmale aus. Zunächst ist entscheidend, dass eine Methode auch für Personen nachvollziehbar ist, die bisher keine Kenntnisse über deren Anwendung besitzen. Darüber hinaus sollte die Durchführung unabhängig von der jeweiligen Person immer zu vergleichbaren Ergebnissen führen.

Des Weiteren basieren Methoden auf einem klar strukturierten und durchdachten Prinzip, wodurch eine objektive Vorgehensweise ermöglicht wird. Folglich werden persönliche Annahmen oder subjektive Einschätzungen, die bereits im Vorfeld entstanden sind, nicht in die Bewertung einbezogen. Abschließend ist es wichtig, dass Methoden nach einheitlichen Grundsätzen aufgebaut sind, sodass sie vermittelbar, erlernbar und wiederholbar bleiben (vgl. (Balzert, 2009, S. 53)).

3.1 Fallstudienanalyse nach Yin

Yin definiert die Fallstudie entlang zweier zentraler Dimensionen, nämlich dem Untersuchungsgegenstand einerseits und den methodischen Merkmalen andererseits. Hinsichtlich des Untersuchungsgegenstands handelt es sich bei einer Fallstudie um eine empirische Untersuchung, die ein Phänomen oder einen Fall eingehend und in seinem realen Kontext analysiert. In methodischer Hinsicht zeichnet sich die Fallstudie dadurch aus, dass sie die technisch besondere Situation berücksichtigt, in der mehr relevante Variablen als verfügbare Datenpunkte vorliegen. Um dieser Komplexität gerecht zu werden, stützt sie sich auf mehrere Evidenzquellen, deren Daten durch Triangulation zusammengeführt werden. Insgesamt erweist sich die Fallstudie damit als eine ganzheitliche Forschungsmethode, die Designlogik, Datenerhebung und Datenanalyse gleichermaßen umfasst und folglich nicht auf ein bloßes Erhebungsinstrument reduziert werden kann (vgl. (Yin, 2014, S. 33)).

Arten von Fallstudien

Fallstudien können drei verschiedenen Forschungszwecken dienen. Explorative Fallstudien zielen darauf ab, erste Hypothesen für eine weiterführende Untersuchung zu entwickeln. Deskriptive Fallstudien beschreiben ein Phänomen innerhalb seines Kontextes vollständig. Explanatorische Fallstudien hingegen erklären kausale Zusammenhänge (vgl. (Yin, 2014, S. 23)).

Ein weiteres Unterscheidungsmerkmal betrifft die Anzahl der untersuchten Fälle. Bei der Einzelfallstudie konzentriert sich die Analyse auf einen einzigen Fall, was sich dann anbietet, wenn dieser besonders erkenntnisreich ist, einen Extremfall darstellt oder einen seltenen Zugang

zum Untersuchungsgegenstand ermöglicht. Auf diese Weise lässt sich die Existenz eines Phänomens unter außergewöhnlichen Bedingungen gezielt und tiefgehend untersuchen (vgl. (Eisenhardt und Graebner, 2007, S. 25-27)). Die Mehrfachfallstudie erweitert diesen Ansatz, indem sie mehrere Fälle einbezieht und auf dieser Grundlage fallübergreifende Aussagen ableitet (vgl. (Yin, 2014, S. 45)). Der Vergleich verschiedener Fälle erlaubt es zu beurteilen, ob ein Ergebnis fallspezifisch ist oder sich auf andere Kontexte übertragen lässt. Die Fallauswahl erfolgt dabei bewusst, um theoretische Annahmen zu stützen, weiterzuentwickeln, zu kontrastieren oder konkurrierende Erklärungen zu entkräften (vgl. (Eisenhardt und Graebner, 2007, S. 25-27)).

Der Forschungsprozess nach Yin gliedert sich in sechs aufeinander aufbauende Phasen, nämlich Plan, Design, Prepare, Collect, Analyze und Share, die den gesamten Ablauf von der ersten Konzeption bis zur abschließenden Kommunikation der Ergebnisse strukturieren.

Plan

In der Plan-Phase wird grundlegend geklärt, ob die Fallstudie als Forschungsmethode für das jeweilige Erkenntnisinteresse geeignet ist. Nach Yin spricht für ihren Einsatz, wenn die Forschungsfragen auf ein Wie oder Warum abzielen, der Forscher keinen Einfluss auf das untersuchte Geschehen nehmen kann und ein gegenwärtiges Phänomen im Mittelpunkt steht (vgl. (Yin, 2014, S. 3)). Der Formulierung der Forschungsfrage kommt in diesem Zusammenhang eine besondere Bedeutung zu, denn sie ist nicht nur inhaltlicher Ausgangspunkt, sondern entscheidet durch ihre Form als Wie- oder Warum-Frage maßgeblich darüber, ob die Fallstudie als Methode überhaupt in Betracht kommt (vgl. (Yin, 2014, S. 11)).

Design

Die Designphase verfolgt das Ziel, logische Inkonsistenzen im Forschungsaufbau zu vermeiden und sicherzustellen, dass die erhobenen Daten tatsächlich zur Beantwortung der Forschungsfrage beitragen. Yin zufolge umfasst ein vollständiges Fallstudiendesign fünf zentrale Komponenten, nämlich die Forschungsfragen, theoretische Annahmen, die zu untersuchende Einheit, die Logik der Verknüpfung von Daten und Annahmen sowie Kriterien zur Interpretation der Befunde (vgl. (Yin, 2014, S. 61)).

Prepare

Die Prepare-Phase dient der systematischen Vorbereitung der Datenerhebung und gliedert sich nach Yin in fünf Bereiche. Diese umfassen die persönlichen Fähigkeiten des Forschers, ein fallspezifisches Training, die Erstellung eines Studienprotokolls, die Auswahl geeigneter Fälle sowie eine vorgelagerte Pilotstudie. Anders als bei Experimenten oder standardisierten Befragungen gibt es bei der Fallstudienforschung kein festgelegtes Erhebungsverfahren, weshalb der Forscher während der gesamten Datenerhebung fortlaufend eigene Urteile treffen muss. Yin benennt dabei konkrete Anforderungen an den Forscher, der gezielt und präzise

fragen, aktiv zuhören, flexibel auf unerwartete Entwicklungen reagieren, die theoretischen Vorannahmen kontinuierlich im Blick behalten und mögliche Verzerrungen bewusst reflektieren sollte (vgl. (Yin, 2014, S. 71f)). Zur Absicherung der Reliabilität empfiehlt Yin die Erstellung eines Fallstudienprotokolls, das vier Bestandteile umfasst, nämlich eine Übersicht über das Forschungsprojekt, eine Beschreibung des Datenerhebungsprozesses, einen Katalog analytischer Fragen als Orientierungshilfe für den Forscher während der Feldarbeit sowie einen Leitfaden für die abschließende Berichterstattung (vgl. (Yin, 2014, S. 84f)).

Ergänzend weist Yin darauf hin, dass die analytischen Fragen des Protokolls nicht mit den Interviewfragen verwechselt werden dürfen, da sie ausschließlich als Reflexionshilfe für den Forscher selbst konzipiert sind und nicht an die Befragten gerichtet werden (vgl. (Yin, 2014, S. 89f)). Im Anschluss daran folgt das Screening, das der finalen Fallauswahl unmittelbar vor Beginn der Datenerhebung dient (vgl. (Yin, 2014, S. 95)). Da als Untersuchungseinheit Wissensarbeitende bei SAP, die aktiv Large Language Models einsetzen, von Beginn an feststanden, war ein aufwändiges Auswahlverfahren nicht erforderlich. Darüber hinaus empfiehlt Yin die Durchführung einer Pilotstudie, die sich von einem klassischen Pretest insofern unterscheidet, als sie nicht nur das Erhebungsinstrument erprobt, sondern auch konzeptionelle Klärungen für das Gesamtdesign ermöglicht (vgl. (Yin, 2014, S. 96)). In der vorliegenden Arbeit wurde auf eine Pilotstudie verzichtet, da der Forscher als internes Mitglied der SAP-Organisation über einen kontinuierlichen Feldzugang verfügte, der diese konzeptionelle Funktion bereits erfüllte.

Collect

In der Collect-Phase erfolgt die eigentliche Datenerhebung, wobei Fallstudien grundsätzlich auf eine Vielzahl unterschiedlicher Datenquellen zurückgreifen können. Keine dieser Quellen ist den anderen dabei von vornherein überlegen. Stattdessen zeichnet eine qualitativ hochwertige Fallstudie gerade dadurch aus, dass sie möglichst viele verschiedene Quellen miteinander kombiniert und so eine breitere und belastbarere Evidenzbasis schafft. Zu den gängigsten Datenquellen zählen nach Yin Dokumentation, Archivdaten, Interviews, direkte Beobachtung, teilnehmende Beobachtung sowie physische Artefakte (vgl. (Yin, 2014, S. 106f)). In der vorliegenden Arbeit werden zwei dieser Quelltypen kombiniert, nämlich Experteninterviews als primäre Erhebungsmethode sowie wissenschaftliche und praxisorientierte Literatur als sekundäre Evidenzbasis. Weitere bei Yin genannte Quellen wie interne Dokumente, direkte Beobachtung oder Archivdaten konnten aus forschungspraktischen Gründen nicht einbezogen werden, da der Feldzugang auf die Durchführung von Interviews begrenzt war.

Analyze

Gegenstand der Analysephase ist die systematische Auswertung der erhobenen Belege, die kategorisiert, tabellarisch aufbereitet und zueinander in Beziehung gesetzt werden, um daraus

fundierte Erkenntnisse abzuleiten (vgl. (Yin, 2014, S. 133)). Anders als bei quantitativen Methoden stehen dem Forscher dabei weder standardisierte Verfahren noch feste Formeln zur Verfügung, weshalb er frühzeitig eine eigene Analysestrategie entwickeln sollte, idealerweise bereits in der Designphase. Als Orientierungsrahmen benennt Yin vier allgemeine Strategien, wobei der Forscher wahlweise an theoretischen Propositionen anknüpfen, induktiv von den Daten ausgehen, eine deskriptive Fallbeschreibung erarbeiten oder plausible Alternativerklärungen systematisch prüfen kann (vgl. (Yin, 2014, S. 136f)). Aufbauend auf diesen Strategien stehen zudem fünf spezifische Analysetechniken zur Verfügung, nämlich Pattern Matching, Explanation Building, Time-Series Analysis, Logic Models sowie Cross-Case Synthesis (vgl. (Yin, 2014, S. 142)).

Im Kontext der vorliegenden Arbeit kommen zwei Analysetechniken zum Einsatz. Zum einen wird Pattern Matching als primäre Technik genutzt, da die in der Literaturanalyse erarbeiteten theoretischen Muster zu Veränderungen in Arbeitsprozessen und Kompetenzprofilen mit den empirischen Befunden der Experteninterviews abgeglichen werden. Stimmen die beobachteten Muster mit den theoretisch erwarteten überein, stärkt dies die interne Validität der Ergebnisse (vgl. (Yin, 2014, S. 143)). Ergänzend dazu wird Explanation Building eingesetzt, um auf Basis dieses Abgleichs schrittweise eine konsistente Erklärung dafür zu entwickeln, wie und unter welchen Bedingungen LLMs die Wissensarbeit bei SAP verändern. Die Erklärung entsteht dabei iterativ, indem eine theoretische Ausgangsthese mit den erhobenen Interviewdaten konfrontiert und in mehreren Schritten so lange verfeinert wird, bis ein stimmiges Gesamtbild vorliegt (vgl. (Yin, 2014, S. 147f)). Unabhängig von der gewählten Technik hebt Yin schließlich vier Qualitätsmerkmale einer guten Analyse hervor, nämlich die lückenlose Berücksichtigung aller erhobenen Belege, die aktive Auseinandersetzung mit konkurrierenden Erklärungsansätzen, die konsequente Fokussierung auf den zentralen Forschungsgegenstand sowie die reflektierte Nutzung des eigenen Expertenwissens (vgl. (Yin, 2014, S. 168f)).

Share

Als abschließender Schritt des Fallstudienforschungsprozesses umfasst die Share-Phase die Aufbereitung und Kommunikation der gewonnenen Erkenntnisse. Für wissenschaftliche Abschlussarbeiten bietet sich dabei die linear-analytische Struktur an, bei der die Darstellung von der Forschungsfrage über Methodik und Daten bis hin zu Befunden und Schlussfolgerungen logisch aufgebaut wird (vgl. (Yin, 2014, S. 188)). Als übergeordnetes Gütemerkmal gilt, dass der Bericht so viele Belege enthält, dass sich der Leser auf dieser Basis ein eigenes, unabhängiges Urteil über die präsentierten Befunde bilden kann (vgl. (Yin, 2014, S. 205)).

Grundsätzlich wären für diese Arbeit auch alternative Forschungsdesigns denkbar gewesen, etwa eine Mehrfachfallstudie oder ein quantitatives Umfragedesign. Dennoch erweist sich die Einzelfallstudie nach Yin als am besten geeignet, weil die Rollentransformation ein zeitgenössisches Phänomen darstellt, das nicht losgelöst von seinem organisationalen Kontext betrachtet

werden kann, und weil eine quantitative Erhebung voraussetzen würde, dass die relevanten Variablen bereits bekannt sind. SAP erfüllt dabei Yins Kriterium eines Revelatory Case, da der Forscher als internes Mitglied der SAP-Organisation einen Feldzugang zu einem Phänomen besitzt, das externen Forschern bislang weitgehend verschlossen ist. Der reale Einsatz von Large Language Models in der Wissensarbeit eines Großunternehmens ist empirisch kaum dokumentiert, sodass bereits die deskriptiven Befunde einen eigenständigen Erkenntniswert besitzen (vgl. (Yin, 2014, S. 52)). Als Analyseeinheit werden dabei Wissensarbeitende bei SAP definiert, die im Rahmen ihrer beruflichen Tätigkeit aktiv Large Language Models einsetzen.

Die Kombination aus systematischer Literaturanalyse und Experteninterviews wurde dabei bewusst gewählt, weil weder eine reine Literaturanalyse noch ein alleiniges Interviewdesign das Erkenntnisinteresse dieser Arbeit vollständig erfüllen könnte. Eine reine Literaturanalyse hätte zwar einen fundierten theoretischen Überblick ermöglicht, aber keine Aussage darüber getroffen, ob die beschriebenen Veränderungen im konkreten Unternehmenskontext von SAP tatsächlich eintreten. Umgekehrt hätten Interviews ohne theoretische Fundierung keine Einordnung der Praxiserfahrungen in einen übergeordneten Forschungsstand erlaubt. Erst die Kombination beider Methoden ermöglicht es, theoretische Muster aus der Literatur zu identifizieren und ihre Gültigkeit im spezifischen Unternehmenskontext empirisch zu prüfen.

3.2 Systematische Literaturanalyse

Methodisches Vorgehen der Literaturanalyse nach Snyder

Um für die Untersuchung der Wissensarbeit bei SAP eine valide und reproduzierbare Grundlage zu schaffen, folgt diese Arbeit dem methodischen Rahmen von (Snyder, 2019). Da im Rahmen dieser Arbeit festgestellt wurde, dass das Forschungsfeld der generativen Künstlichen Intelligenz durch eine hohe Entwicklungsgeschwindigkeit und ein breites fachübergreifendes Spektrum geprägt ist, eignet sich dieser Ansatz besonders, da er nicht auf rein quantitative Methoden beschränkt ist, sondern auch die gemeinsame Auswertung von Quellen aus unterschiedlichen Forschungsrichtungen ermöglicht (vgl. (Snyder, 2019, S. 334)). Das Vorgehen gliedert sich dabei in den vierphasigen Prozess aus Design, Durchführung, Analyse und Verschriftlichung (vgl. (Snyder, 2019, S. 336-337)).

In der ersten Phase, dem Review-Design, wird die methodische Ausrichtung festgelegt. Aufgrund der beschriebenen Aktualitätsproblematik und der Notwendigkeit, verschiedene Perspektiven zu vereinen, wird ein integrativer Review-Ansatz gewählt. Dieser eignet sich nach Snyder besonders für neue Themenbereiche, bei denen noch kein etabliertes theoretisches Modell existiert und das Ziel darin besteht, erste Zusammenhänge und Muster zu erkennen, anstatt bestehende Ansätze lediglich zu bestätigen (vgl. (Snyder, 2019, S. 336)). Entsprechend den Vorgaben von Snyder wurden in dieser Phase zunächst die Forschungsfragen festgelegt,

die als Grundlage für die gesamte Suche und Analyse dienen (vgl. (Snyder, 2019, S. 336)). Sie adressieren dabei sowohl theoretische Potenziale als auch praktische Realitäten des KI-Einsatzes bei SAP. Darüber hinaus wurde die Suchstrategie definiert: Die wissenschaftliche Suche erfolgte in den Datenbanken Google Scholar, arXiv, ResearchGate sowie dem Bibliothekskatalog der DHBW Ravensburg mit den Suchbegriffen „how AI shapes and evolves knowledge work“, „generative AI productivity“ sowie „LLM in knowledge work“. Praxisorientierte Quellen wie Beratungsstudien wurden über gezielte KI-gestützte Recherche identifiziert und verifiziert. Da eine Literatursuche in der Regel eine große Anzahl an Treffern liefert, wurden auf Basis der Forschungsfrage zudem konkrete Ein- und Ausschlusskriterien festgelegt, anhand derer die tatsächlich relevanten Quellen identifiziert werden sollten (vgl. (Snyder, 2019, S. 337)). Snyder betont dabei, dass alle Ein- und Ausschlussentscheidungen explizit begründet sein müssen, um die Transparenz und die Qualität des Reviews sicherzustellen (vgl. (Snyder, 2019, S. 337–338)). Dies wird in dieser Arbeit durch die kritische Würdigung der grauen Literatur realisiert.

In der zweiten Phase der Durchführung wurde die eigentliche Literatursuche anhand der in Phase 1 festgelegten Strategie umgesetzt. Snyder empfiehlt, die Suchbegriffe und Auswahlkriterien zunächst an einer kleineren Auswahl zu testen und den Prozess bei Bedarf anzupassen, bevor die vollständige Suche durchgeführt wird (vgl. (Snyder, 2019, S. 337)). Entsprechend diesem Vorgehen wurden die Suchbegriffe in einem ersten Schritt erprobt und verfeinert. Die Quellenauswahl erfolgte anschließend in zwei Stufen: Zunächst wurden die Treffer anhand von Titel und Abstract auf ihre Relevanz geprüft, bevor die verbliebenen Quellen im Volltext gelesen und abschließend bewertet wurden. Snyder empfiehlt zudem den Einsatz von zwei Reviewern, um die Qualität und Reliabilität der Quellenauswahl zu sichern (vgl. (Snyder, 2019, S. 337)). Da die vorliegende Arbeit von einem einzelnen Autor verfasst wird, konnte diesem Vorgehen nicht entsprochen werden; diesem Umstand wird durch die explizite Dokumentation der Ein- und Ausschlusskriterien begegnet. Alle Entscheidungen wurden dabei auf Basis der in Phase 1 definierten Kriterien getroffen und sind durch die kritische Würdigung der Quellenkategorien nachvollziehbar dokumentiert (vgl. (Snyder, 2019, S. 337)).

Nach der Identifikation der relevanten Quellen erfolgt in der dritten Phase die Analyse. Snyder betont, dass nach der Festlegung der endgültigen Quellen ein einheitliches Vorgehen zur Informationsentnahme angewendet werden sollte, um Qualität und Verlässlichkeit der Auswertung sicherzustellen (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit wurden aus den ausgewählten Quellen relevante Informationen in Form von Befunden, Einschätzungen und thematischen Schwerpunkten entnommen. Die Analyse erfolgt dabei nicht rein autorenenorientiert, sondern konzeptzentriert: Themen wie „Veränderung von Arbeitsprozessen“, „Kompetenzwandel durch KI“ oder „Chancen und Risiken des KI-Einsatzes“, wurden über die verschiedenen Quellenkategorien hinweg extrahiert und miteinander verglichen. Da das Ziel dieser Arbeit nicht die statistische Auswertung von Effektgrößen, sondern die Entwicklung eines inhaltlichen Über-

blicks ist, wurde eine für integrative Reviews geeignete Analysetechnik gewählt (vgl. (Snyder, 2019, S. 337)).

In der abschließenden Phase der Verschriftlichung werden die Ergebnisse so aufbereitet, dass Motivation, Vorgehen und Erkenntnisse des Reviews klar und nachvollziehbar kommuniziert werden (vgl. (Snyder, 2019, S. 337)). Snyder verweist dabei auf anerkannte Richtlinien zur Berichterstattung von Literaturreviews, darunter die Leitlinien für integrative Reviews nach Torracco (Torraco, 2005, zitiert nach (Snyder, 2019, S. 337)). Unabhängig vom gewählten Ansatz wird erwartet, dass der gesamte Prozess von der Planung über die Suche bis hin zur Analyse transparent beschrieben wird, damit der Leser die Qualität und Verlässlichkeit der Ergebnisse einschätzen kann (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit wird diesem Anspruch durch die detaillierte Beschreibung der vier Phasen in diesem Kapitel entsprochen. Snyder beschreibt, dass der Beitrag eines Reviews verschiedene Formen annehmen kann, etwa eine konzeptionelle Aufarbeitung eines Forschungsfelds (vgl. (Snyder, 2019, S. 337)). In dieser Arbeit besteht der Beitrag darin, einen strukturierten Überblick über den aktuellen Wissensstand zur Veränderung der Wissensarbeit durch KI-Textgenerierung zu schaffen.

Zielsetzung und Vorgehen

Die vorliegende Arbeit untersucht, wie KI-Textgenerierung mittels Large Language Models Arbeitsprozesse und Kompetenzprofile in der Wissensarbeit bei SAP verändert sowie welche Chancen und Risiken sich daraus ergeben. Da es sich um ein Forschungsfeld handelt, in dem im Rahmen dieser Arbeit festgestellt wurde, dass die akademische Literatur der technologischen Entwicklung teils mit zeitlichem Verzug folgt, wurde die Literaturanalyse bewusst mehrstufig angelegt: Sie kombiniert drei Quellenkategorien, die zwei unterschiedliche Funktionen erfüllen, nämlich die theoretisch-methodische Fundierung durch wissenschaftliche Studien einerseits sowie die Abbildung empirischer Aktualität und Praxisrelevanz durch Berater- und Fachpressequellen andererseits.

Die einbezogene Literatur lässt sich dabei in drei Kategorien unterteilen. Wissenschaftliche Literatur in Form von peer-reviewten Studien und Working Papern bildet die theoretische Basis der Arbeit und liefert methodisch abgesicherte Erkenntnisse zu Automatisierungspotenzialen und Produktivitätseffekten. Beratungsstudien (graue Literatur) großer Institute liefern ergänzend aktuelle, breit angelegte empirische Daten zu Skill-Wandel oder Adoptionsraten, die wissenschaftlich oft noch nicht verfügbar sind. Fachpresse und Praxisbeiträge runden das Bild punktuell ab, indem sie die praktische Rezeption der Entwicklungen in Unternehmen abbilden. Da geeignete Fachpressebeiträge im Zuge der Recherche nur vereinzelt identifiziert werden konnten, stützt sich die Analyse in diesem Bereich überwiegend auf Beratungsstudien, die eine vergleichbare Funktion erfüllen.

Zur Sicherung der Quellenqualität werden spezifische Auswahlkriterien angelegt. Neben einer strikten Aktualität (Fokus auf 2023–2026) wird bei Beratungsstudien die Transparenz der Methodik (Stichprobengröße, Erhebungszeitraum) geprüft. Um eine einseitige Darstellung zu vermeiden, wird auf Ausgewogenheit geachtet, indem auch kritische Gegenpositionen zum KI-Einsatz in Unternehmen einbezogen werden. Reine Meinungsbeiträge ohne empirische Grundlage werden ausgeschlossen.

Diese einbezogenen Beratungsquellen stellen keine peer-reviewte Literatur im engeren Sinne dar und sind entsprechend kritisch zu würdigen. Insbesondere bei Studien von Unternehmensberatungen ist ein potenzieller Interessenkonflikt zu berücksichtigen, da diese Institute selbst kommerzielle KI-Transformationsleistungen anbieten. Dieser methodischen Einschränkung wird dadurch begegnet, dass Beratungsquellen stets in Verbindung mit wissenschaftlichen Quellen herangezogen werden und ihre empirischen Befunde nur dort als eigenständige Belege gelten, wo vergleichbare wissenschaftliche Daten aufgrund der Aktualität des Forschungsfelds noch nicht verfügbar sind.

3.3 Experteninterviews

Als eine der zentralen Methoden qualitativer Forschung findet das Experteninterview in unterschiedlichen Forschungsfeldern Anwendung und kann dabei sowohl als eigenständiges Instrument als auch in Kombination mit weiteren Forschungsmethoden eingesetzt werden (vgl. (Burger, 2011, S. 127)). Im Mittelpunkt steht die gezielte Erschließung des Fachwissens ausgewählter Experten, um auf dieser Basis wissenschaftlich fundierte Erkenntnisse zu gewinnen (vgl. (Bogner, Littig und Menz, 2014, S. 17)).

Das Interview stellt in seiner grundlegenden Form eine mündliche Befragung dar (vgl. (Renner und Jacob, 2020, S. 1)). Befragungen lassen sich dabei generell in quantitative und qualitative Verfahren unterteilen (vgl. (Fantapié Altobelli, 2017, S. 55, 357)). Leitfadengestützte Experteninterviews zählen zu den qualitativen Methoden der Datenerhebung. Da die gewonnenen Daten im Anschluss unmittelbar weiterverarbeitet werden, ist bei der Durchführung besondere Sorgfalt geboten (vgl. (Baur und Blasius, 2022, S. 875)).

Qualitative Befragungen unterscheiden sich von quantitativen Verfahren insbesondere durch ihren kleineren Umfang. Anstelle standardisierter Fragen stehen individualisierte Fragen im Vordergrund, die auf Informationen abzielen, die für Außenstehende nicht ohne Weiteres zugänglich sind (vgl. (Fantapié Altobelli, 2017, S. 357)). Ein Leitfadeninterview eignet sich insbesondere dann, wenn der Interviewer mit dem Thema vertraut ist oder es gezielt eingrenzen kann. In beiden Fällen ermöglichen vorab formulierte Fragen eine strukturierte Gesprächsführung (vgl. (Porst, 2015, S. 95)). Das Experteninterview stellt eine besondere Form des Leitfadeninterviews dar, bei der der Fokus auf dem Fachwissen und der Praxiserfahrung der

befragten Person liegt. Dies erlaubt es, zielgerichtete und komplexere Fragestellungen zu adressieren, die ausschließlich durch den Sachverstand eines Experten beantwortet werden können (vgl. (Baur und Blasius, 2022, S. 888–889)).

Nach Renner und Jacob lassen sich Interviews grundsätzlich in hoch standardisierte, unstandardisierte sowie teilstandardisierte bzw. halbstrukturierte Formen unterteilen, wobei letztere die Vorteile beider Extremformen vereint, indem sie sich an einem Leitfaden orientiert, gleichzeitig aber Raum für ergänzende Fragen lässt (vgl. (Renner und Jacob, 2020, S. 13–17)).

Der Leitfaden strukturiert den Ablauf aller Gespräche und ermöglicht so eine einheitliche Gesprächsführung. Er kann Erzählaufforderungen, vorformulierte Fragen sowie Stichpunkte enthalten und bei Bedarf auch Stimuli wie Bilder oder Geschichten einbeziehen. Dabei wird stets eine Balance zwischen Offenheit und Strukturiertheit angestrebt. Bei der Erstellung empfiehlt sich ein dreistufiges Vorgehen, bei dem zunächst möglichst offene Fragen gestellt werden, die dem Befragten freie Antworten ermöglichen und so alle relevanten Informationen erschließen. Anschließend können gezielte Nachfragen zu Themen gestellt werden, die bisher unbeantwortet oder unzureichend behandelt wurden. Abschließend werden vorformulierte Fragen in einer logischen Reihenfolge an den Interviewten gerichtet (vgl. (Baur und Blasius, 2022, S. 881–883)).

Als Experten können Personen herangezogen werden, die über ein überdurchschnittliches, umfangreiches Wissen oder eine besondere fachliche Tiefe in einem bestimmten Bereich verfügen. Dies umfasst sowohl Insiderwissen, das für Außenstehende nur schwer zugänglich ist, als auch einen allgemein vertieften Wissensstand im jeweiligen Fachgebiet. Expertenwissen beschränkt sich dabei nicht auf die Berufswelt, sodass auch Personen, die sich ein spezifisches Thema eigenständig erschlossen oder darin besondere Fähigkeiten entwickelt haben, in diesen Bereichen als Experten gelten können. Im Mittelpunkt der Interviews steht die fachliche Expertise der Befragten und nicht ihre persönliche Lebenssituation. Den Interviewpartnern wird dabei verdeutlicht, welche bedeutsame Rolle ihr Wissen für die Beantwortung der Forschungsfrage einnimmt (vgl. (Baur und Blasius, 2022, S. 887–888)).

In der vorliegenden Arbeit wurden vier Wissensarbeitende bei SAP als Experten befragt, die Large Language Models aktiv und regelmäßig in ihren beruflichen Alltag integriert haben. Drei der Befragten sind in der PCG-Einheit tätig und decken beratungs- sowie projektnahe Tätigkeitsfelder ab, während die vierte Person als Senior Developer im Bereich S/4HANA Cloud eine technische Entwicklungsperspektive einbringt. Ihre Expertise ergibt sich damit nicht aus einer formalen Zertifizierung, sondern aus dem praktisch aufgebauten Erfahrungswissen im konkreten Einsatz von KI-Tools im Unternehmenskontext. Die Durchführung und Auswertung der Interviews werden in Kapitel 5 dargestellt.

4 Auswirkungen von KI-Textgenerierung auf die Wissensarbeit (Ergebnisse der Literaturanalyse)

Das folgende Kapitel stellt die Ergebnisse der durchgeführten Literaturanalyse dar und untersucht, wie KI-Textgenerierung die Wissensarbeit verändert. Dabei gliedert sich die Analyse in die drei Themenbereiche, die im Rahmen der Literaturanalyse in Kapitel 3 identifiziert wurden. Abschnitt 4.1 beleuchtet zunächst, inwiefern sich bestehende Arbeitsprozesse durch den Einsatz von KI verschieben. Darauf aufbauend analysiert Abschnitt 4.2, welche veränderten Anforderungen sich daraus für die Kompetenzprofile von Wissensarbeitenden ergeben. Abschließend zeigt Abschnitt 4.3, welche Chancen und Risiken sich aus diesen Veränderungen ergeben. Die drei Abschnitte bauen dabei aufeinander auf und ermöglichen so einen umfassenden Blick auf die Auswirkungen von KI-Textgenerierung auf die Wissensarbeit.

4.1 Veränderungen von Arbeitsprozessen

Die Literaturanalyse zeigt, dass KI-Textgenerierung die Arbeitsprozesse von Wissensarbeitenden auf mehreren Ebenen verändert. Im Folgenden werden vier zentrale Verschiebungen beschrieben, nämlich die Verlagerung von ausführenden hin zu assistierenden Tätigkeiten, die wachsende Bedeutung der Steuerung und Überwachung von KI-Prozessen, die funktionale Arbeitsteilung zwischen Mensch und Maschine sowie die veränderte Bewertungsgrundlage von Arbeit.

Verschiebung von Ausführung zu Assistenz

Die Literaturanalyse legt nahe, dass KI-Textgenerierung die Arbeitsprozesse von Wissensarbeitenden weniger durch eine vollständige Ablösung von Arbeitsplätzen verändert, sondern vielmehr bestehende Tätigkeiten und Aufgaben innerhalb von Rollen verschiebt. Dieses Bild zeigt sich sowohl in wissenschaftlichen Studien als auch in Praxis- und Beratungsberichten (vgl. (Carbonero, Ernst und Weber, 2023, S. 707-708); vgl. (Agrawal, Gans und Goldfarb, 2024, S. 327); vgl. (Brynjolfsson, Li und Raymond, 2025, S. 891, 901, 934-935); vgl. (Emerson *u. a.*, 2026, S. 1-2, 9-13); vgl. (Deloitte, 2026, S. 3-5, 8, 11-12, 32); vgl. (PwC Deutschland, 2026, S. 3-19)). Insbesondere routineorientierte Tätigkeiten wie Informationsrecherche, Texterstellung und Dokumentation werden den Quellen zufolge zunehmend durch KI unterstützt, woraus sich interpretieren lässt, dass sich der Arbeitsschwerpunkt stärker auf die Überprüfung, Bewertung und Integration von Ergebnissen verlagert (vgl. (Noy und Zhang, 2023, Abstract, S. 1, 3, 7); vgl. (Brynjolfsson, Li und Raymond, 2025, S. 890, 891); vgl. (Lee *u. a.*, 2025, S. 1-2); vgl. (Dell'Acqua *u. a.*, 2026, S. 403, 406, 419-420)). Bereits vor dem Aufkommen generativer KI zeigte sich, dass Wissensarbeitende einen erheblichen Teil ihrer Arbeitszeit für Routineaufgaben aufwenden, wodurch weniger Kapazität für Innovationen und Problemlösungen verbleibt

(vgl. (Haufe Online Redaktion, 2017)). Darüber hinaus deutet die Literatur darauf hin, dass KI überwiegend nicht als Ersatz, sondern als Assistenzsystem verstanden wird, das menschliche Arbeit ergänzt und erweitert. Daraus lässt sich schließen, dass zunehmend hybride Arbeitsformen entstehen, in denen menschliche und technologische Fähigkeiten gemeinsam eingesetzt werden (vgl. (Brynjolfsson, Li und Raymond, 2025, S. 891, 901, 934-935); vgl. (Dell'Acqua u. a., 2026, S. 403-404); vgl. (Lei und Kim, 2024, S. 252, 259); vgl. (Emerson u. a., 2026, S. 1-2, 9-13); vgl. (Deloitte, 2026, S. 3-5, 8, 11-12, 32); vgl. (PwC Deutschland, 2026, S. 3-19)).

Steuerung und Überwachung von KI-Prozessen

Diese Verlagerung hin zur Assistenzfunktion von KI geht mit einer grundlegenden Veränderung der Rolle von Wissensarbeitenden einher. Laut einer Befragung von BCG gab fast die Hälfte der Teilnehmenden an, dass sich ihre Rolle zunehmend dahin verschoben habe, KI zu steuern und anzuleiten, anstatt die eigentliche Arbeit selbst auszuführen (vgl. (Beauchene u. a., 2026, S. 3)). Laut McKinsey werden in diesem Zuge neue Rollen erforderlich sein, unter anderem für LLM Selection and Management sowie für das Training und Management von GenAI-Agenten (vgl. (Hussin u. a., 2024, S. 5)).

Diese Entwicklung zeigt sich auch in spezifischen Berufsfeldern. So verschiebt generative KI nach BCG die Tätigkeit von Softwareentwicklern weg von repetitiven Codieraufgaben hin zu System-Level Thinking, Orchestrierung sowie Produkt- und Designaufgaben, wobei menschliches Urteilsvermögen und Verantwortung weiterhin erforderlich bleiben (vgl. (Emerson u. a., 2026, S. 8)).

Neben der Steuerung gewinnt dabei auch die Überwachung von KI-Prozessen an Bedeutung. McKinsey argumentiert, dass die Automatisierung einfacher Tätigkeiten Beschäftigten ermöglicht, sich komplexeren Aufgaben zuzuwenden, die menschliches Urteilsvermögen, Aufsicht und den Umgang mit Mehrdeutigkeit erfordern. Zugleich verweist McKinsey auf eine Studie mit 1.488 US-Beschäftigten, nach der eine intensive Überwachung von KI-Systemen zu kognitiver Ermüdung beitragen kann (vgl. (Metakis u. a., 2026)). BCG erwartet in diesem Zusammenhang, dass durch KI neugestaltete Rollen höhere Anforderungen an Fachwissen, Aufsicht und Verantwortlichkeit stellen werden, wobei insbesondere Aufgaben bestehen bleiben, die kontextbezogenes Urteilsvermögen, Koordination und Oversight-Fähigkeiten erfordern (vgl. (Emerson u. a., 2026, S. 11-12, 15)). McKinsey betont ergänzend, dass mit der Einführung generativer KI neue Rollen und Verantwortlichkeiten entstehen, darunter sogenannte „LLMOps“-Fähigkeiten zur langfristigen Überwachung der Modellleistung sowie eine stärkere Führungsaufsicht darüber, wie sich Rollen und Arbeitsweisen anpassen müssen (vgl. (Hussin u. a., 2024, S. 5)). PwC hebt schließlich hervor, dass Organisationen nicht nur KI-Kompetenzen innerhalb der Belegschaft aufbauen, sondern auch ihre Integrations-, Governance- und Vendor-Management-Fähigkeiten stärken müssen, um KI-Lösungen gezielt steuern zu können (vgl. (PwC Deutschland, 2026, S. 17, 19)).

Routine für KI, Ausnahmen für Menschen

Mit der Verlagerung hin zu steuernden Tätigkeiten verändert sich auch das konkrete Verhältnis zwischen menschlicher und maschineller Aufgabenbearbeitung. Dabei zeigt sich, dass LLMs häufig strikt an vorgegebene Richtlinien gebunden bleiben, selbst wenn deren Anwendung im konkreten Kontext unpraktisch oder kontraproduktiv ist. Diese Inflexibilität wird auf eine mechanistische Interpretation von Regeln zurückgeführt, während menschliche Entscheidungen häufiger kontextabhängige Anpassungen berücksichtigen. Der Umgang mit Ausnahmen stellt daher eine Form adaptiver Entscheidungsfindung dar, die nuanciertes Urteilsvermögen erfordert (vgl. (DiSorbo, Ju und Aral, 2025, S. 1,3,14)).

Daraus ergibt sich eine funktionale Arbeitsteilung zwischen Mensch und Maschine. Rollen mit offenen Problemlösungen und häufigen Ausnahmen werden laut der Analyse eher durch KI ergänzt als ersetzt, da sie weiterhin menschliches Urteilsvermögen erfordern. Am Beispiel von Call-Centern zeigt sich eine mögliche Aufgabenteilung, bei der KI standardisierte Erstinteraktionen übernimmt, während Menschen Eskalationen und Ausnahmefälle bearbeiten. Gleichzeitig könnten Einstiegsrollen neu gestaltet werden und früher als bisher Aufgaben wie die Überwachung von KI-Systemen, das Management von Ausnahmen und komplexere Problemlösungen umfassen (vgl. (Emerson *u. a.*, 2026, S. 3-7, 15)). In der Praxis bedeutet dies, dass durch den Einsatz von KI Mitarbeitende zwar von einfachen, wiederkehrenden Anfragen entlastet werden, ihre Tätigkeit sich jedoch stärker hin zu komplexen und eskalierten Fällen verschiebt. Während KI das Grundrauschen einfacher Aufgaben übernimmt, verbleiben bei Menschen die anspruchsvolleren Fälle, wodurch die kognitive Intensität der Arbeit steigen kann (vgl. (Brassey *u. a.*, 2026)).

Qualität statt Geschwindigkeit

Die veränderte Aufgabenteilung zwischen Mensch und KI hat nicht nur Auswirkungen auf die Art der Tätigkeiten, sondern auch auf den Maßstab, nach dem Arbeit bewertet wird. Da KI-Systeme zunehmend in die Erstellung von Arbeitsergebnissen eingebunden sind, gewinnt die Frage nach deren Qualität an Bedeutung. Hintergrund hierfür ist, dass Machine-Learning-Code im Gegensatz zu klassischem Softwarecode nicht auf deterministischen Wenn-Dann-Regeln basiert, sondern auf statistischen Verfahren. Aufgrund seines nicht-deterministischen Charakters kann dieselbe Eingabe zu unterschiedlichen Ausgaben führen, was ML-Systeme grundlegend von deterministischen Programmen unterscheidet (vgl. (Cooper, Frankle und Sa, 2022, S. 2-3, 7-8)). Ergänzend dazu werden KI-Halluzinationen als ein inhärentes technisches Merkmal der probabilistischen Generierungsmechanismen großer Sprachmodelle eingeordnet (vgl. (Cheng *u. a.*, 2026, S. 1)).

Dieser nicht-deterministische Charakter schlägt sich in einem Spannungsverhältnis zwischen Effizienz und Verantwortlichkeit nieder. Nutzer bevorzugen in praktischen Anwendungssitua-

tionen häufig direkte und schnell umsetzbare Antworten gegenüber einem tieferen Verständnis der zugrunde liegenden Entscheidungsprozesse. Eine starke Effizienzorientierung kann jedoch das Risiko einer übermäßigen Abhängigkeit von KI-Systemen erhöhen, wodurch die kritische Bewertung von KI-generierten Ergebnissen beeinträchtigt werden kann (vgl. (Spatola, 2024, S. 1-2, 5)). Ebenso zeigt sich, dass eine Steigerung der Bearbeitungsgeschwindigkeit nicht zwangsläufig zu einer Verbesserung der Qualität der Ergebnisse führt (vgl. (Spivack u. a., 2024, S. 5)).

Folgerichtig verändert der Einsatz von KI die Rolle von Wissensarbeitenden in Richtung einer stärkeren Qualitätssicherung. Im Bereich der Softwareentwicklung beispielsweise müssen Entwickler zunehmend als Reviewer agieren und KI-generierten Code hinsichtlich Fehlern, Kompatibilität und Wartbarkeit bewerten, was erweiterte Fähigkeiten zur Analyse und Qualitätssicherung erfordert (vgl. (Hussin u. a., 2024, S. 3-4)). Dabei steigen auch die allgemeinen Erwartungen an Arbeitsergebnisse. Befragte geben an, dass die Anforderungen an das, was als ausreichend gilt, gestiegen sind, und 52 % berichten, dass sie mehr Zeit für die Überprüfung und Korrektur von KI-generierten Ergebnissen aufwenden (vgl. (Beauchene u. a., 2026, S. 17)). In sicherheitskritischen Bereichen können KI-Halluzinationen darüber hinaus erhebliche Auswirkungen haben, etwa wenn fehlerhafte diagnostische Vorschläge im Gesundheitswesen klinische Risiken erhöhen oder in anderen Bereichen durch notwendige Überprüfungen zusätzliche Aufwände entstehen (vgl. (Cheng u. a., 2026, S. 4)). Schließlich zeigt sich, dass für die Ausrichtung von LLMs an menschlichem Urteilsvermögen nicht nur entscheidend ist, welche Entscheidungen getroffen werden, sondern auch, wie diese zustande kommen, wobei insbesondere das Training mit menschlichen Erklärungen eine wichtige Rolle spielt (vgl. (DiSorbo, Ju und Aral, 2025, S. 1-2)).

Zusammenfassend lässt sich ableiten, dass KI-Textgenerierung die Wissensarbeit nicht durch Stellenabbau verändert, sondern durch eine mehrstufige Verlagerung von Tätigkeitsschwerpunkten. Routineaufgaben werden zunehmend durch KI übernommen, während Wissensarbeitende stärker in steuernde und bewertende Rollen wechseln. Eine funktionale Arbeitsteilung entsteht, in der KI standardisierbare Prozesse abwickelt und der Mensch Ausnahmen sowie kontextabhängige Entscheidungen verantwortet. Da KI-Systeme nicht deterministisch arbeiten und zu Halluzinationen neigen, verschiebt sich der Bewertungsmaßstab von Effizienz hin zur Ergebnisqualität.

4.2 Veränderungen der Kompetenzprofile

Die in Abschnitt 4.1 beschriebenen Verschiebungen in den Arbeitsprozessen ziehen veränderte Anforderungen an die Kompetenzprofile von Wissensarbeitenden nach sich. Die Literaturanalyse identifiziert dabei sechs zentrale Themenbereiche, nämlich die steigende Bedeutung von KI-Kompetenz und kritischem Denken, den wachsenden Wert impliziten Erfahrungswissens,

die Relevanz von Fachkompetenz und kontextuellem Urteilsvermögen, die Notwendigkeit kontinuierlichen Lernens und der Requalifizierung, den Aufbau von Datenschutz- und Sicherheitskompetenz sowie die zunehmende Bedeutung ethischer Urteilsfähigkeit.

KI-Kompetenz und kritisches Denken

Die Analyse der Literatur zeigt, dass sich durch KI-Textgenerierung nicht nur Arbeitsprozesse verändern, sondern auch die Anforderungen an die Kompetenzprofile von Wissensarbeitenden. Über nahezu alle Quellen hinweg lässt sich erkennen, dass technologische Kompetenzen zunehmend durch menschliche Fähigkeiten ergänzt werden müssen und künftig nicht mehr allein fachliches Wissen über den beruflichen Erfolg entscheidet (vgl. (Lee *u. a.*, 2025, S. 1); vgl. (Gerlich, 2025, S. 1-2, 14)). Besonders häufig zeigt sich dabei die steigende Bedeutung von KI-Kompetenz. Den Quellen zufolge müssen Wissensarbeitende lernen, KI-Systeme effektiv einzusetzen, ihre Ergebnisse zu interpretieren sowie deren Grenzen und Risiken zu verstehen (vgl. (Rafi *u. a.*, 2024, S. 1-2, 7); vgl. (Emerson *u. a.*, 2026, S. 15, 18-19); vgl. (Deloitte, 2026, S. 3-5, 8, 11-12, 32)). Da KI-generierte Inhalte Fehler, Verzerrungen oder Halluzinationen enthalten können, lässt sich daraus schließen, dass kritisches Denken und menschliche Urteilkraft nicht an Bedeutung verlieren, sondern im Gegenteil unverzichtbar bleiben (vgl. (Lee *u. a.*, 2025, S. 12, 15-16); (Brynjolfsson, Li und Raymond, 2025, S. 897); vgl. (Dell'Acqua *u. a.*, 2026, S. 3); vgl. (Woodruff *u. a.*, 2024, S. 7 und 23)).

Erfahrungswissen als Wettbewerbsvorteil

Neben explizit vermittelbaren Kompetenzen wie KI-Literacy rückt mit dem Aufkommen von KI auch eine weniger greifbare Wissensform in den Fokus, nämlich das implizite Erfahrungswissen. Explizites Wissen bezeichnet Wissen, das leicht dokumentiert, formalisiert und kommuniziert werden kann, beispielsweise in Form von Anleitungen oder Rezepten. Implizites Wissen basiert dagegen auf persönlicher Erfahrung, Intuition und situativem Verständnis und lässt sich nur schwer verbalisieren oder vollständig kodifizieren, wie etwa die Fähigkeit, beim Fahrradfahren das Gleichgewicht zu halten (vgl. (Atakishiyev *u. a.*, 2025, S. 14); (Lu, 2025, S. 9)). Dabei handelt es sich häufig um Wissen, dessen Besitz oder Erwerb den Handelnden nicht vollständig bewusst ist (vgl. (Atakishiyev *u. a.*, 2025, S. 14); (Lu, 2025, S. 1, 7)). Implizites Wissen umfasst dabei drei Formen. Erstens gibt es Wissen, das zwar theoretisch kodifizierbar wäre, dessen Überführung in explizite Information jedoch zu kostspielig ist. Zweitens zählt dazu Wissen über sprachliche Nuancen und Subtexte. Drittens gehört verkörpertes Wissen dazu, das durch sensorische Erfahrungen erworben wird (vgl. (Lu, 2025, S. 1-2)).

Genau an diesem Punkt stoßen LLMs an ihre Grenzen. Sie basieren auf Repräsentationsmodellen, die Muster aus großen Mengen textueller Daten lernen und diese für Sprachgenerierung und Verständnis nutzen. Da ein Teil des impliziten Wissens subjektiv, erfahrungsbasiert und kaum textualisiert ist, stellt dessen Erfassung durch LLMs eine besondere Herausforderung

dar (vgl. (Atakishiyev *u. a.*, 2025, S. 14); (Lu, 2025, S. 2)). Besonders deutlich wird dieser Unterschied im Bereich des verkörperten Wissens, denn während LLMs sprachliche Muster und Zusammenhänge aus Trainingsdaten lernen können, verfügen sie nicht über physische Erfahrungen oder sensorische Interaktionen mit der Welt und können daher beispielsweise Kälte beschreiben, ohne jemals körperlich zu frieren (vgl. (Lu, 2025, S. 2, 10, 17)). Kritiker argumentieren darüber hinaus, dass LLMs lediglich statistische Zusammenhänge in Textdaten erfassen und keine menschliche Form von semantischem Verständnis besitzen (vgl. (Lu, 2025, S. 6-7)).

Daraus ergibt sich, dass implizites Erfahrungswissen durch die Verbreitung von KI nicht an Wert verliert, sondern im Gegenteil an Bedeutung gewinnt. KI kann bestehendes Wissen erweitern und Aufgaben beschleunigen, ersetzt jedoch nicht vollständig menschliches Urteilsvermögen, Mustererkennung und implizites Wissen, die durch wiederholte praktische Erfahrung in realen Situationen entstehen (vgl. (Brassey *u. a.*, 2026)). Menschen können zudem bei bestimmten Aufgaben weiterhin einen komparativen Vorteil besitzen, insbesondere wenn für das Training von KI-Modellen nicht ausreichend aufgezeichnete Daten verfügbar sind oder deren Erhebung wirtschaftlich nicht sinnvoll wäre (vgl. (Lu, 2025, S. 16)).

Fachkompetenz und kontextuelles Urteilsvermögen

Eng verbunden mit dem Wert impliziten Wissens ist die Frage, welche Fachkompetenzen künftig besonders gefragt sind. Während stark strukturierte und wiederholbare Tätigkeiten eher für eine Automatisierung geeignet sind, bleiben Rollen mit offenen Problemlösungen und häufigen Ausnahmen stärker auf menschliches Urteilsvermögen angewiesen und werden daher eher durch KI augmentiert als ersetzt. Mitarbeitende können dabei als Eskalationsschicht fungieren, wenn KI-Agenten komplexe Fälle oder Ausnahmesituationen nicht bewältigen können (vgl. (Emerson *u. a.*, 2026, S.4, 16)). McKinsey zeigt in diesem Zusammenhang, dass stark KI-exponierte Rollen Aufgaben mit menschlich geprägten Fähigkeiten wie Empathie, Urteilsvermögen und Kreativität 2,5-mal schneller aufnehmen als weniger KI-exponierte Rollen (vgl. (Brassey *u. a.*, 2026)).

Besondere Bedeutung kommt dabei dem kontextuellen Urteilsvermögen zu. KI kann zwar strukturierte Aufgaben übernehmen und Prozesse beschleunigen, ersetzt jedoch nicht vollständig das menschliche Urteilsvermögen, das für die Interpretation emotionaler und sozialer Hinweise sowie für kontextabhängige Entscheidungen notwendig ist. Besonders Rollen mit hohen Anforderungen an Interaktion, Vertrauen und kontextuelles Urteil werden daher eher durch KI ergänzt als ersetzt (vgl. (Emerson *u. a.*, 2026, S. 7-8, 11-12)). Da bestimmte Fähigkeiten wie Problemlösung, Urteilsvermögen und der Umgang mit organisationsspezifischem Wissen schwer formal zu vermitteln sind, gewinnen zudem Lehrlingsmodelle und Mentoring an Bedeutung, bei denen erfahrene Experten durch praktische Zusammenarbeit und Vorbildfunk-

tion institutionelles Wissen sowie schwer vermittelbare Kompetenzen an jüngere Mitarbeitende weitergeben (vgl. (Hussin *u. a.*, 2024, S. 8)).

Kontinuierliches Lernen und Requalifizierung

Angesichts der beschriebenen Verschiebungen in Arbeitsprozessen und Kompetenzprofilen stellt sich schließlich die Frage, wie Wissensarbeitende und Organisationen auf diese Veränderungen reagieren können. Schätzungen zufolge werden in den nächsten zwei bis drei Jahren etwa 50 % bis 55 % der Arbeitsplätze in den USA durch KI verändert. Für viele Beschäftigte bedeutet dies keine vollständige Ersetzung ihrer bisherigen Tätigkeit, sondern eine Veränderung der Arbeitsanforderungen und Aufgabenprofile. Unternehmen stehen daher vor der Herausforderung, strategische Maßnahmen zur Weiterbildung und Umschulung ihrer Mitarbeitenden zu entwickeln (vgl. (Emerson *u. a.*, 2026, S.1,13)).

Der Bedarf an Weiterbildung wird von vielen Beschäftigten als zunehmend relevant wahrgenommen. So geben 88 % der in der BCG-Studie befragten Personen an, dass sie in den nächsten fünf Jahren eine umfassende Weiterqualifizierung benötigen, während sich gleichzeitig nur 36 % der Befragten für den KI-Einsatz bereits als ausreichend geschult einschätzen (vgl. (Beauchene *u. a.*, 2026, S. 11–13)). Aufgrund der kontinuierlichen Weiterentwicklung von KI-Technologien wird Weiterbildung dabei nicht als einmalige Maßnahme ausreichen, sondern Beschäftigte werden voraussichtlich häufiger Weiterqualifizierungen benötigen, um ihre Fähigkeiten an veränderte Anforderungen anzupassen (vgl. (Emerson *u. a.*, 2026, S.18)). Die Einführung von KI-Systemen erfordert darüber hinaus nicht nur die Weiterentwicklung technischer Kompetenzen, sondern auch den Erhalt der kognitiven Leistungsfähigkeit der Beschäftigten. Das Konzept des Brain Capital betrachtet Gehirngesundheit und geistige Fähigkeiten als strategische Ressource. Ohne entsprechende Maßnahmen besteht das Risiko kognitiver Überlastung, insbesondere wenn Weiterbildungs- und Transformationsprozesse zusätzliche Anforderungen schaffen, ohne ausreichende Kapazitäten und Erholungsphasen zu berücksichtigen (vgl. (Brassey *u. a.*, 2026)).

Datenschutz- und Sicherheitskompetenz

Das TrustLLM-Framework definiert Datenschutz (Privacy) als eines von acht grundlegenden Prinzipien für vertrauenswürdige, menschenzentrierte Large Language Models. Zu den weiteren Prinzipien zählen Sicherheit, Wahrhaftigkeit, Fairness, Robustheit, Transparenz, Rechenschaftspflicht und Machine Ethics (vgl. (Atakishiyev *u. a.*, 2025, S.22)).

Auch für Wissensarbeitende ergibt sich daraus die Anforderung, grundlegende Kompetenzen im Umgang mit KI-Risiken aufzubauen. Am Beispiel von Softwarefachkräften wird deutlich, dass dazu insbesondere das Verständnis verschiedener Risikoarten und der Einsatz geeigneter Schutzmaßnahmen gehören (vgl. (Hussin *u. a.*, 2024, S.6)). Darüber hinaus sollten Wissensarbeitende, die KI-Lösungen von Drittanbietern einsetzen, über grundlegende Kennt-

nisse in den Bereichen Governance und Vendor Management verfügen, um externe Modelle wirksam steuern zu können (vgl. (PwC Deutschland, 2026, S.17)). Im Zuge der zunehmenden KI-Nutzung entstehen zudem neue spezialisierte Rollen, die sich auf KI-Sicherheit und Datenverantwortung konzentrieren (vgl. (Hussin u. a., 2024, S.5)). Erschwerend kommt hinzu, dass in vielen Unternehmen klare Governance-Strukturen für die Zusammenarbeit von Menschen und KI-Systemen noch fehlen, sodass Mitarbeitende und Führungskräfte de facto eine erhöhte Eigenverantwortung tragen (vgl. (Beauchene u. a., 2026, S.27)).

Ethische Urteilsfähigkeit

Neben technischen Kompetenzen umfasst die Zusammenarbeit mit KI-Systemen auch eine ethische Dimension. Menschliche kognitive Flexibilität schließt dabei Fähigkeiten wie innovatives Denken, die Anpassung an komplexe Kontexte sowie ethische Beurteilung ein. Diese menschlichen Fähigkeiten ergänzen die technologischen Stärken von KI-Systemen und tragen dazu bei, die jeweiligen Grenzen von Mensch und KI in der Zusammenarbeit zu überwinden (vgl. (Cheng u. a., 2026, S.3)). Dass Ethik dabei nicht nur eine abstrakte Anforderung darstellt, zeigt sich daran, dass das Weltwirtschaftsforum Ethik als relevante Kompetenz im Rahmen der Global Skills Taxonomy aufführt, die von Arbeitgebern als Kernkompetenz für die Belegschaft bewertet wird (vgl. (World Economic Forum, 2025, S.35)).

Wie im Abschnitt zu Datenschutz- und Sicherheitskompetenz bereits dargelegt, definiert das TrustLLM-Framework acht grundlegende Prinzipien vertrauenswürdiger LLMs. Neben technischen Dimensionen wie Datenschutz und Robustheit zählen dazu auch normative Prinzipien wie Fairness, Transparenz, Rechenschaftspflicht und Machine Ethics (vgl. (Atakishiyev u. a., 2025, S.22)). Für Wissensarbeitende bedeutet dies, dass ein verantwortungsvoller KI-Einsatz nicht allein technisches Verständnis erfordert, sondern auch die Fähigkeit, diese ethischen Dimensionen im Arbeitsalltag zu erkennen und zu berücksichtigen.

Eng damit verbunden ist die Frage des angemessenen Vertrauens in KI-Systeme. Eine bewusste Vertrauenskalibrierung („Trust Calibration,“) ist im Umgang mit KI-Systemen erforderlich. Das Vertrauen in ein System sollte an dessen tatsächliche Fähigkeiten angepasst werden, um eine übermäßige bzw. blinde Abhängigkeit trotz möglicher Fehler zu vermeiden (vgl. (Romeo und Conti, 2025, S.260)). Dies schließt an die in Abschnitt 4.1 beschriebene Nicht-Determinismus-Problematik an, denn da KI-Systeme fehleranfällig sind und zu Halluzinationen neigen, ist ein unkritisches Vertrauen in ihre Ausgaben nicht nur qualitativ riskant, sondern auch ethisch problematisch.

Darüber hinaus wird bei KI-gestützten Entscheidungen empfohlen, dass Menschen die primären Entscheidungen treffen und KI lediglich als Zweitmeinung nutzen. Dadurch soll eine übermäßige Abhängigkeit von KI vermieden und die menschliche Entscheidungsautonomie erhalten werden (vgl. (Romeo und Conti, 2025, S.272-273)). Daraus folgt, dass die ethische

Verantwortung für Entscheidungen mit Konsequenzen für andere Personen nicht an ein KI-System übertragen werden kann, sondern beim Menschen verbleibt.

Zusammenfassend verdeutlicht die Literaturanalyse, dass sich die Kompetenzanforderungen an Wissensarbeitende in mehrere Richtungen gleichzeitig verschieben. KI-Kompetenz und kritisches Denken werden zur Grundvoraussetzung, da KI-generierte Inhalte stets bewertet werden müssen. Gleichzeitig gewinnt implizites Erfahrungswissen an Wert, weil LLMs situatives Urteilen und kontextabhängige Entscheidungen nicht replizieren können. Hinzu kommen Datenschutz- und Sicherheitskompetenz sowie ethische Urteilsfähigkeit als neue Querschnittsanforderungen. Da sich all diese Anforderungen kontinuierlich weiterentwickeln, wird die Fähigkeit zur dauerhaften Requalifizierung zum entscheidenden Merkmal zukunftsfähiger Wissensarbeit.

4.3 Chancen und Risiken

Aus den in Abschnitt 4.1 und 4.2 beschriebenen Veränderungen ergeben sich sowohl Chancen als auch Risiken für Wissensarbeitende.

Chancen

Eine zentrale Chance ergibt sich aus der in Abschnitt 4.1 beschriebenen Entlastung von Routinetätigkeiten. Da KI standardisierbare Aufgaben zunehmend übernimmt, gewinnen Wissensarbeitende zeitliche Kapazitäten für komplexere und wertschöpfende Tätigkeiten, sodass mehr Raum für strategisches Denken, Ideenentwicklung und kreative Problemlösung entsteht.

Eine weitere Chance liegt in der Stärkung menschlicher Kernkompetenzen. Wie in Abschnitt 4.2 gezeigt, können LLMs implizites Erfahrungswissen, kontextuelles Urteilsvermögen und situatives Entscheiden nicht replizieren. Der Mensch bleibt in komplexen Ausnahmesituationen daher unverzichtbar, und genau diese Kompetenzen gewinnen durch den KI-Einsatz an Sichtbarkeit und Wert.

Darüber hinaus eröffnet die in Abschnitt 4.1 beschriebene Mensch-KI-Kollaboration neue Möglichkeiten der Aufgabenverteilung. Organisationen können Prozesse flexibler gestalten, indem KI standardisierte Erstinteraktionen übernimmt und Menschen sich auf Eskalationen, Ausnahmen und Entscheidungen mit hohem Kontextbedarf konzentrieren.

Risiken

Den Chancen stehen jedoch erhebliche Risiken gegenüber. Ein zentrales Risiko besteht in Fehlentscheidungen durch unkritische KI-Nutzung. Wie in Abschnitt 4.1 dargelegt, arbeiten KI-Systeme nicht deterministisch und neigen zu Halluzinationen. Wer KI-generierte Ergebnisse ungeprüft übernimmt, riskiert inhaltlich falsche Ausgaben als Grundlage für Entscheidungen zu verwenden. Da die Verantwortung für Ergebnisqualität beim Menschen verbleibt, stellt

die fehlende kritische Prüfung ein strukturelles Risiko dar, das mit zunehmendem KI-Einsatz an Gewicht gewinnt. Daraus lässt sich ableiten, dass eine bewusste Vertrauenskalibrierung notwendig ist. Wissensarbeitende müssen das Vertrauen in KI-Ausgaben an die tatsächlichen Fähigkeiten des jeweiligen Systems anpassen und die eigene Entscheidungsautonomie aktiv erhalten, anstatt KI unkritisch als primäre Entscheidungsinstanz zu behandeln.

Ein weiteres Risiko betrifft den Kompetenzaufbau bei Berufsanfängern. Wie in Abschnitt 4.1 beschrieben, übernimmt KI zunehmend standardisierbare Einstiegsaufgaben. Genau diese Aufgaben sind es jedoch, über die Berufsanfänger traditionell praktische Erfahrung und implizites Wissen aufbauen. Wie in Abschnitt 4.2 beschrieben, lässt sich implizites Erfahrungswissen nur durch wiederholte Praxis in realen Situationen entwickeln. Werden diese Aufgaben durch KI automatisiert, entfällt dieser Lernpfad, sodass der kurzfristige Leistungsgewinn langfristig auf Kosten des Kompetenzaufbaus gehen kann.

Schließlich besteht das Risiko einer wachsenden Qualifikationslücke. Der in Abschnitt 4.2 beschriebene Bedarf an kontinuierlicher Requalifizierung trifft nicht alle Beschäftigten gleichermaßen. Wer KI-Kompetenz, kritisches Denken und die Bereitschaft zur dauerhaften Weiterentwicklung nicht aufbaut, läuft Gefahr, mit den veränderten Anforderungen nicht Schritt halten zu können. Zugleich besteht das Risiko kognitiver Überlastung, wenn Weiterbildungs- und Transformationsprozesse zusätzliche Anforderungen schaffen, ohne ausreichende Kapazitäten zu berücksichtigen.

Ein weiteres Risiko ergibt sich aus der in Abschnitt 4.2 beschriebenen Datenschutz- und Sicherheitskompetenz. Da in vielen Unternehmen Governance-Strukturen für den KI-Einsatz noch fehlen, sind Wissensarbeitende zunehmend selbst dafür verantwortlich, den sicheren Umgang mit vertraulichen Daten sicherzustellen. Wer diese Kompetenz nicht aufbaut, riskiert unbewusst vertrauliche Informationen an externe Modelle weiterzugeben oder Compliance-Vorgaben zu verletzen, ohne sich dessen bewusst zu sein.

Zusammenfassend zeigt sich, dass die durch KI ausgelösten Veränderungen in Arbeitsprozessen und Kompetenzprofilen weder ausschließlich positiv noch ausschließlich negativ zu bewerten sind. Die Chancen liegen vor allem in der Entlastung von Routinetätigkeiten, der Aufwertung menschlicher Kernkompetenzen und flexibleren Formen der Zusammenarbeit. Dem gegenüber stehen Risiken durch unkritische KI-Nutzung, den Wegfall klassischer Lernpfade für Berufsanfänger und eine wachsende Qualifikationslücke. Entscheidend wird sein, ob Wissensarbeitende und Organisationen die notwendigen Kompetenzen und Strukturen aufbauen, um KI verantwortungsvoll einzusetzen und die menschliche Urteilskraft dauerhaft zu erhalten.

5 Experteninterviews, Diskussion und Handlungsempfehlungen

Das folgende Kapitel ergänzt die Literaturanalyse aus Kapitel 4 um eine empirische Perspektive und verfolgt dabei drei aufeinander aufbauende Ziele. Abschnitt 5.1 stellt zunächst die Durchführung der Experteninterviews dar und wertet die Aussagen der vier befragten Wissensarbeitenden bei SAP thematisch aus. Darauf aufbauend gleicht Abschnitt 5.2 die Interviewergebnisse mit den theoretischen Befunden aus Kapitel 4 ab, um zu prüfen, inwiefern die Literatur durch die Praxisperspektiven bestätigt, ergänzt oder herausgefordert wird. Abschnitt 5.3 benennt anschließend die methodischen Limitationen der Untersuchung, bevor Abschnitt 5.4 auf Basis der gewonnenen Erkenntnisse konkrete Handlungsempfehlungen für SAP ableitet.

5.1 Durchführung und Auswertung der Interviews

Zur Beantwortung der Forschungsfrage wurden ergänzend zur Literaturanalyse leitfadengestützte Experteninterviews durchgeführt. Als Grundlage für die Gespräche diente ein Interviewleitfaden, der im Rahmen der Vorbereitung entwickelt wurde und im Anhang in Abbildung 1 eingesehen werden kann. Parallel dazu wurden geeignete Interviewpartner aus dem Unternehmensumfeld von SAP identifiziert, kontaktiert und die Gesprächstermine koordiniert.

Durchführung der Experteninterviews

Im Vorfeld jedes Interviews wurden die Teilnehmenden über die Zielsetzung und den Kontext der Arbeit informiert, um einen gemeinsamen Ausgangspunkt zu schaffen. Die Interviews fanden jeweils unabhängig voneinander in Form von Videokonferenzen statt und dauerten durchschnittlich ca. 30 Minuten. Um einen natürlichen Gesprächsfluss zu ermöglichen, wurde die Reihenfolge der Fragen flexibel gehandhabt. Mit ausdrücklicher Zustimmung der Teilnehmenden wurden die Gespräche aufgezeichnet, sodass eine sorgfältige Auswertung im Nachgang möglich war. Darüber hinaus wurden die Teilnehmenden zu Beginn des Gesprächs darauf hingewiesen, dass ihre Aussagen sowie ihre Person vollständig anonymisiert behandelt werden.

Auswertung der Experteninterviews

Im Folgenden werden die Aussagen der vier Interviewpartner thematisch verglichen, um Gemeinsamkeiten und Unterschiede systematisch herauszuarbeiten.

Person A ist seit ca. vier bis fünf Jahren bei PCG tätig und arbeitet als Projektmanagerin in einem internen Transformationsprojekt, das die Neugestaltung zweier Support-Einheiten umfasst. Person B ist seit ca. 15 Jahren bei PCG in verschiedenen Rollen aktiv und beschäftigt

sich aktuell mit Entitlement Checks für Partnerprodukte, Customer Support Profiles sowie internen KI-Projekten. Person C ist ebenfalls bei PCG tätig, seit 20 Jahren bei SAP und aktuell in einem internen Transformationsprojekt tätig, das Kundenkommunikation auf Kanal-, Technologie- und Geschäftsprozessebene neu gestaltet. Person D kommt demgegenüber aus einem anderen Tätigkeitsfeld und ist Senior Developer in einer Entwicklungsabteilung bei SAP und seit 2019 nach Abschluss des DHBW-Studiums in der Abteilung tätig. Sein Schwerpunkt liegt auf der Softwareentwicklung sowie der Betreuung von Studierenden, insbesondere im Bereich Performance-KPIs für Apps. Damit repräsentieren Personen A, B und C eher beratungs- und projektnahe Wissensarbeit, während Person D die Perspektive technischer Entwicklungsarbeit einbringt.

Alle vier Interviewpartner nutzen KI-Tools regelmäßig in ihrem Arbeitsalltag. So gibt Person D an, die Tools täglich zu verwenden, nachdem die Nutzung durch einen internen Aufruf angestoßen wurde. Auch Personen A, B und C berichten von einer regelmäßigen, teils täglichen Nutzung. Hinsichtlich der Einsatzfelder unterscheiden sich die Antworten entsprechend der jeweiligen Tätigkeitsschwerpunkte. Person A verwendet primär EKX für Präsentationen sowie MS Copilot für E-Mail-Formulierungen und Texte und nutzt darüber hinaus Teams Premium für automatische Meeting-Summaries. Person B setzt KI demgegenüber vor allem für PM-Aufgaben wie das Aufsetzen von Projekten und Work-Breakdown-Structures, als Sparring-Partner bei Präsentationen sowie als Lern-Tutor bei neuen Themen ein. Person C nutzt Claude und EKX wiederum vor allem zur Analyse größerer Datenmengen und Dokumente sowie zur Zusammenfassung umfangreicher Compliance-Texte. Person D schließlich konzentriert sich auf Code-Generierung und Dokumentation, einschließlich der Erstellung technischer und nutzerorientierter Anleitungen.

Bei der Frage nach Hemmfaktoren zeigen sich sowohl Gemeinsamkeiten als auch Unterschiede. Personen A und C berichten, dass sie persönlich kaum durch externe Faktoren gehemmt werden. Für Kolleginnen und Kollegen identifizieren jedoch alle Befragten ähnliche Muster, nämlich initiale Skepsis gegenüber neuen Technologien, fehlendes Vertrauen in die Zuverlässigkeit der Tools sowie mangelnde Kenntnis über sinnvolle Anwendungsfälle. Person D beschreibt dieses Muster als typisches Gewohnheitsverhalten, da Kolleginnen und Kollegen auf disruptive Technologien wie KI zunächst skeptisch reagierten. Ergänzend dazu weist Person B darauf hin, dass für fortgeschrittene Anwendungen wie den Aufbau von Agenten noch geeignete Schulungsangebote fehlten.

Alle vier Personen beschreiben eine Veränderung ihrer Arbeitspraxis durch KI, die in ihrer Ausprägung jedoch variiert. Person A berichtet, dass sie administrative PM-Aufgaben zunehmend an KI delegiert und dadurch mehr Zeit für strategisch-inhaltliche Themen gewinnt. Person B hebt ergänzend hervor, dass die gleichzeitige Betreuung mehrerer Projekte einfacher geworden sei, weist allerdings auch auf den Prüfaufwand für KI-generierte Ergebnisse hin, der

die Zeitersparnis teilweise kompensiere. Person C schätzt die persönliche Geschwindigkeitssteigerung im aktuellen Strategie-Projekt auf ca. 10 %, verweist jedoch auf deutlich höhere Potenziale in Projekten mit Massendaten. Person D beschreibt demgegenüber eine strukturelle Veränderung, da das Team angehalten sei, bei jeder Problemstellung aktiv zu prüfen, ob KI-Einsatz sinnvoll sei. Zudem werde Dokumentation heute standardmäßig KI-unterstützt erstellt, was auch die Umstellung von Word-Dateien auf das Markdown-Format erfordere.

Bei der Einschätzung, welche Aufgaben für KI geeignet sind, zeigen sich sowohl übereinstimmende als auch spezifische Kriterien. Personen A und B stimmen darin überein, dass Formulierungsaufgaben, Texterstellung und Zusammenfassungen besonders gut geeignet sind, wobei Person A davon explizit Aufgaben mit empathischer oder teamdynamischer Komponente abgrenzt, etwa individuelle Workshop-Agenden. Person C stellt hingegen den Datenschutz als primären Eignungsfilter heraus, da vor jeder inhaltlichen Abwägung geprüft werden müsse, ob personenbezogene oder vertrauliche Daten betroffen seien. Person D beschreibt Code-Analyse als besonders geeigneten Anwendungsfall, benennt jedoch gleichzeitig auch eine klare Grenze, denn sobald viele voneinander abhängige Klassen und Objekte im Spiel seien, verliere die KI den Kontextüberblick.

Alle Befragten haben konkrete Erfahrungen mit fehlerhaften KI-Ausgaben gemacht und beschreiben einen ähnlichen Umgang damit, nämlich kritisches Hinterfragen und eigenständige Verifikation. Person A schildert dabei einen Fall, in dem Copilot durch einen Transkriptionsfehler wiederholt ein nicht existierendes Projekt erfand und sie das gesamte 90-minütige Meeting abhören musste, um die Fehlerquelle zu finden. In ähnlicher Weise berichtet Person D von einem Kollegen, dem die KI zu einer ABAP-Syntax-Frage eine klare, aber faktisch falsche Antwort gab, die der offiziellen Dokumentation widersprach. Demgegenüber beschreiben Personen B und C strukturierte Gegenstrategien. So hat Person B einen Kontext-Prompt entwickelt, der die KI zu Rückfragen und Selbstkorrektur anhält, während Person C empfiehlt, bei numerischen Auswertungen explizit nachrechnen zu lassen, da in fast der Hälfte der Fälle leichte Abweichungen in der zweiten Antwort auftreten.

Im Bereich Datenschutz zeigen alle vier Personen ein ausgeprägtes Bewusstsein, das sich in konkreten Verhaltensregeln niederschlägt. Übereinstimmend berichten alle, dass keine personenbezogenen Daten an KI-Tools weitergegeben werden. Personen B und C betonen darüber hinaus die Bedeutung von Vertraulichkeitsstufen und des Need-to-Know-Prinzips. Person C kritisiert dabei, dass klare Vorgaben oft nur in Wiki-Artikeln hinterlegt seien und nicht direkt am Eingabefeld der Tools erscheinen. Person D hebt ergänzend hervor, dass bei jedem KI-unterstützten Entwicklungsschritt eine menschliche Prüfinstanz im Sinne eines Human in the Loop obligatorisch sei.

Bei der Frage nach veränderten Kompetenzen und dem Risiko des Verlernens zeigen sich deutliche Unterschiede. Während Personen B und D das Verlernrisiko klar benennen, berichten

Personen A und C kaum davon betroffen zu sein. Person D gibt dabei offen zu, nicht mehr zu wissen, wann er zuletzt eigenständig ABAP-Code entwickelt habe, da der gedankliche Entwicklungsprozess zunehmend durch die KI übernommen werde. Person B beschreibt demgegenüber, dass die Gefahr des Verlernens durch aktive Evaluation von KI-Ergebnissen teilweise kompensiert werden könne. Person A berichtet hingegen, dass KI-Nutzung bei ihr sogar den Lerneffekt bei unbekannten Themen fördere, während Person C das Risiko für ihre aktuelle Arbeitspraxis ebenfalls verneint. Als neue Schlüsselkompetenz nennen Personen A und B übereinstimmend die Fähigkeit zum gezielten Prompting sowie zur kritischen Evaluation von KI-Outputs.

Hinsichtlich der Vorteile stimmen alle Befragten darin überein, dass Zeitersparnis und Qualitätssteigerung bei analytischen und dokumentarischen Aufgaben zentrale Stärken von KI-Tools sind. Person B ergänzt dabei aus organisationaler Perspektive, dass KI auch aus Kostensicht relevant sei, da sie unter Umständen Personal ersetzen könne. Sowohl Person B als auch Person D weisen zudem auf eine wachsende Spreizung zwischen KI-affinen und KI-ablehnenden Mitarbeitenden hin, die zu Spannungen in Teams führen könne. Bei den Empfehlungen für SAP zeigen sich mehrere Überschneidungen. So fordern Personen A und C eine bessere Sichtbarkeit von Datenschutzregeln, insbesondere direkt am Eingabefeld der Tools. Person B empfiehlt darüber hinaus, Mitarbeitende gezielt in der strukturierten Evaluation von KI-Ergebnissen zu schulen und die dafür notwendigen Kapazitäten einzuplanen. Person D betont abschließend, dass Token-Limits und KI-Budgets sinnvoll gestaltet werden müssten und die menschliche Kontrollinstanz in KI-getriebenen Prozessen dauerhaft verankert werden solle.

5.2 Diskussion der Ergebnisse im Abgleich mit der Literatur

Die Ergebnisse der Experteninterviews werden im Folgenden den Befunden der Literaturanalyse aus Kapitel 4 gegenübergestellt. Ziel ist es, zu prüfen, inwiefern die in der Literatur beschriebenen Veränderungen in Arbeitsprozessen, Kompetenzprofilen sowie Chancen und Risiken durch die Praxiserfahrungen der befragten Wissensarbeitenden bei SAP bestätigt, ergänzt oder herausgefordert werden.

Veränderungen von Arbeitsprozessen

Die Literaturanalyse zeigt, dass KI-Textgenerierung Arbeitsprozesse vor allem durch eine Verlagerung von ausführenden hin zu steuernden und überwachenden Tätigkeiten verändert, ohne dabei Arbeitsplätze vollständig zu ersetzen. Dieses Bild spiegelt sich in den Interviews deutlich wider. Alle vier befragten Personen beschreiben, dass KI-Tools routineorientierte Aufgaben wie Texterstellung, Dokumentation oder Codeanalyse übernehmen, während sie selbst zunehmend in prüfende, bewertende oder steuernde Rollen wechseln. Person A berichtet, dass sie administrative Aufgaben an KI delegiert und dadurch mehr Kapazität für strategisch-inhaltli-

che Tätigkeiten gewinnt, was die in der Literatur beschriebene Entlastung von Routineaufgaben unmittelbar bestätigt. In ähnlicher Weise beschreibt Person D, dass das Team angehalten sei, bei jeder Problemstellung aktiv zu prüfen, ob KI-Einsatz sinnvoll sei, was die von McKinsey und BCG beschriebene Steuerungsrolle des Menschen in KI-gestützten Prozessen in der Praxis abbildet.

Auch die in der Literatur beschriebene Verschiebung des Qualitätsmaßstabs von Effizienz hin zur Ergebnisqualität findet in den Interviews eine klare Entsprechung. Alle Befragten betonen, dass KI-Ausgaben stets kritisch geprüft werden müssen und nicht unesehen übernommen werden können. Person D schildert dabei exemplarisch, dass unkritisch übernommener KI-Code langfristig kaum wartbar wäre, was den in der Literatur beschriebenen nicht-deterministischen Charakter von ML-Systemen als praktisches Risiko bestätigt. Person B ergänzt, dass der Prüfaufwand für KI-generierte Ergebnisse die Zeitersparnis teilweise kompensiere, was das von der BCG-Studie beschriebene Spannungsverhältnis zwischen Effizienz und Verantwortlichkeit in der Praxis widerspiegelt.

Veränderungen der Kompetenzprofile

Die Literatur identifiziert KI-Kompetenz und kritisches Denken als zentrale neue Anforderungen an Wissensarbeitende. Dieser Befund wird durch alle vier Interviews gestützt. Personen A und B benennen gezieltes Prompting sowie die kritische Evaluation von KI-Outputs als die wichtigsten neu entstandenen Fähigkeiten in ihrer Arbeitspraxis. Darüber hinaus bestätigen die Interviews die von der Literatur beschriebene Notwendigkeit kontinuierlichen Lernens. Person B berichtet, dass die Fähigkeit zur strukturierten Evaluation von KI-Ergebnissen im Team noch aktiv entwickelt werden müsse, während Person D die Umstellung von Word-Dateien auf Markdown als konkrete neue technische Anforderung beschreibt, die zunächst eine Lernhürde darstellte.

Besonders deutlich zeigt sich in den Interviews die Relevanz von Datenschutz- und Sicherheitskompetenz, die die Literatur als wachsende Querschnittsanforderung beschreibt. Person C hebt hervor, dass Datenschutz bei ihr als primärer Filter vor jeder inhaltlichen Eignung von KI-Aufgaben steht, und kritisiert, dass klare Vorgaben in vielen Tools nicht direkt am Eingabefeld erscheinen, sondern nur in internen Wiki-Artikeln hinterlegt sind. Damit bestätigt sie nicht nur den in der Literatur beschriebenen Kompetenzaufbau als Notwendigkeit, sondern weist auch auf eine strukturelle Lücke hin, die in der Literatur so nicht explizit thematisiert wird.

Das in der Literatur beschriebene Risiko des Cognitive Offloading, also der Schwächung kognitiver Fähigkeiten durch zunehmende Delegation an KI, findet in den Interviews eine differenzierte Bestätigung. Person D beschreibt offen, dass der gedankliche Entwicklungsprozess beim eigenständigen Coden zunehmend durch die KI übernommen werde und das Verlernrisiko real sei. Person B bestätigt das grundsätzliche Risiko, sieht in der aktiven

Auseinandersetzung mit KI-Ergebnissen jedoch einen möglichen Ausgleich. Personen A und C hingegen berichten nicht von einem Verlerneffekt, was darauf hindeutet, dass das Risiko stark von der Art der Tätigkeit und dem Grad der KI-Nutzung abhängt.

Dieser Befund führt zu einer eigenständigen Schlussfolgerung, die so in der gesichteten Literatur nicht explizit formuliert wird. Das Verlernrisiko durch KI-Nutzung ist demnach nicht generell vorhanden oder abwesend, sondern ausgeprägt tätigkeitsabhängig. Es tritt besonders dann auf, wenn Wissensarbeitende KI für strukturierte, wiederholbare kognitive Kernprozesse ihrer Rolle einsetzen, wie etwa das eigenständige Entwickeln von Code. In projektnaher oder beratender Wissensarbeit hingegen, wo Tätigkeiten ohnehin stärker durch Kontexturteil, Kommunikation und situative Entscheidungen geprägt sind, scheint das Risiko deutlich geringer ausgeprägt zu sein. Für Organisationen wie SAP folgt daraus, dass Maßnahmen gegen das Verlernrisiko nicht pauschal für alle Mitarbeitenden gelten sollten, sondern gezielt auf jene Rollen ausgerichtet werden müssen, in denen KI strukturierte Kernkompetenzen ersetzt statt ergänzt.

Chancen und Risiken

Die in der Literatur beschriebene zentrale Chance der Entlastung von Routineaufgaben wird durch alle vier Interviews bestätigt. Besonders prägnant zeigt sich dies bei Person C, die bei der Analyse umfangreicher Compliance-Dokumente deutliche Zeitersparnisse berichtet, sowie bei Person D, dem die KI bei der Zusammenfassung langer Dokumente erhebliche Kapazitäten freisetzt. Ergänzend dazu beschreibt Person B, dass sich die gleichzeitige Betreuung mehrerer Projekte durch KI-Unterstützung deutlich vereinfacht habe, was die in der Literatur beschriebene Aufwertung strategischer Tätigkeiten durch KI in der Praxis belegt.

Das in der Literatur als zentrales Risiko beschriebene Fehlentscheidungen durch unkritische KI-Nutzung wird durch alle Interviewpartner aus eigener Erfahrung bekräftigt. So schildert Person A, wie Copilot durch eine Fehlerquelle im Transkript ein nicht existierendes Projekt erfand und den gesamten Prüfaufwand erhöhte, während Person D beschreibt, wie die KI zu einer ABAP-Syntax-Frage eine klare, aber faktisch falsche Antwort gab. Beide Fälle veranschaulichen, dass die in der Literatur beschriebene kontinuierliche menschliche Validierung nicht nur theoretisch notwendig, sondern in der Praxis unerlässlich ist.

Das Risiko einer wachsenden Qualifikationslücke, das die Literatur vor allem im Hinblick auf unterschiedliche Adoptionsgeschwindigkeiten beschreibt, tritt in den Interviews in Form eines konkreten Teamphänomens zutage. Sowohl Person B als auch Person D berichten von einer zunehmenden Spreizung zwischen KI-affinen und KI-ablehnenden Kolleginnen und Kollegen, die zu Ungleichgewichten in Teams führen könne. Darüber hinaus ergänzen die Interviews einen Aspekt, der in der Literatur weniger prominent behandelt wird, nämlich die Frage der Token-Kosten und KI-Budgets. Person D sowie Person B weisen darauf hin, dass ungleiche

Nutzungslimits zwischen Rollen eine neue Form der Chancenungleichheit schaffen können, die Organisationen aktiv adressieren müssen.

Insgesamt zeigt der Abgleich, dass die in der Literatur beschriebenen Veränderungen in Arbeitsprozessen, Kompetenzanforderungen sowie Chancen und Risiken durch die Interviewergebnisse in weiten Teilen bestätigt werden. Gleichzeitig ergänzen die Praxisperspektiven die theoretischen Befunde an mehreren Stellen, insbesondere hinsichtlich der strukturellen Datenschutzlücken in Tool-Oberflächen, der rollenabhängigen Ausprägung des Verlernrisikos sowie der bisher wenig diskutierten Frage der KI-Budgetverteilung als organisationale Gerechtigkeitsfrage.

Aus dem Abgleich lassen sich dabei drei eigenständige Erkenntnisse ableiten, die so in der gesichteten Literatur nicht explizit formuliert werden. Erstens ist das Verlernrisiko durch KI-Nutzung nicht pauschal vorhanden oder abwesend, sondern abhängig davon, ob KI strukturierte kognitive Kernprozesse einer Rolle ersetzt oder lediglich ergänzt. Zweitens besteht eine strukturelle Datenschutzlücke nicht nur auf der Kompetenzebene der Mitarbeitenden, sondern auf der Gestaltungsebene der Tool-Oberflächen selbst, da Datenschutzhinweise dort häufig nicht sichtbar verankert sind. Drittens eröffnet die ungleiche Verteilung von KI-Nutzungsbudgets zwischen Rollen eine neue Dimension organisationaler Chancenungleichheit, die in der bisherigen Forschung zu KI und Wissensarbeit kaum thematisiert wird. Diese drei Erkenntnisse stellen den empirischen Eigenbeitrag der vorliegenden Arbeit dar und können als Ausgangspunkt für weiterführende Untersuchungen dienen.

5.3 Limitationen der Untersuchung

Die vorliegende Arbeit weist eine Reihe von Einschränkungen auf, die bei der Interpretation der Ergebnisse berücksichtigt werden müssen.

Eine erste Limitation ergibt sich aus dem gewählten Forschungsdesign als Einzelfallstudie nach Yin. Wie in Kapitel 3 dargelegt, wurde SAP als Revelatory Case ausgewählt, da der Forscher als internes Mitglied der Organisation einen Feldzugang besitzt, der externen Forschern weitgehend verschlossen ist. Gleichzeitig schränkt diese Entscheidung die Übertragbarkeit der Ergebnisse auf andere Unternehmen und Branchen erheblich ein. Da SAP im Vergleich zu vielen anderen Unternehmen eine fortgeschrittene LLM-Adoption aufweist, lassen sich Aussagen über die Veränderung von Wissensarbeit durch KI in Unternehmen mit geringerer Adoptionsreife, anderen Organisationsstrukturen oder anderen regulatorischen Rahmenbedingungen aus den Ergebnissen nicht ohne Weiteres ableiten.

Darüber hinaus beschränkt sich die Untersuchungseinheit auf Wissensarbeitende bei SAP, die aktiv Large Language Models einsetzen. Dabei stammen drei der vier befragten Personen aus der PCG-Einheit, während lediglich Person D die Perspektive technischer Entwick-

lungsarbeit repräsentiert. Die vier Interviewpartner decken zwar verschiedene Rollen und Tätigkeitsschwerpunkte ab, stellen jedoch keine repräsentative Stichprobe der gesamten SAP-Belegschaft dar. Insbesondere Rollen, die weniger oder gar keinen Kontakt zu KI-Tools haben, sind in der Auswertung nicht vertreten, weshalb die Ergebnisse eher die Perspektive bereits KI-affiner Wissensarbeitender widerspiegeln.

Eine weitere Einschränkung betrifft die Datenerhebung selbst. Da alle Interviews von einem einzelnen Autor durchgeführt wurden, der als internes Mitglied der SAP-Organisation bekannt ist, lässt sich ein Interviewereffekt nicht vollständig ausschließen. Befragte könnten dazu neigen, KI-Nutzung positiver darzustellen als tatsächlich erlebt, um sozial erwünschte Antworten zu geben oder die eigene Kompetenz herauszustellen. Dieser Effekt kann durch die durchgeführte Anonymisierung zwar abgemildert, aber nicht eliminiert werden.

Ergänzend dazu handelt es sich bei der Literaturanalyse um die Arbeit eines einzelnen Autors. Wie in Kapitel 3 im Rahmen der Snyder-Methodik bereits eingeräumt, empfiehlt das methodische Vorgehen idealerweise den Einsatz von zwei Reviewern, um die Reliabilität der Quellenauswahl zu sichern. Da dies im Rahmen einer Einzelarbeit nicht realisierbar war, besteht trotz der dokumentierten Ein- und Ausschlusskriterien ein gewisses Risiko selektiver Quellenauswahl.

Hinzu kommt die kritische Einordnung der herangezogenen grauen Literatur. Wie in Kapitel 3 ausgeführt, stammen mehrere der verwendeten Quellen von Unternehmensberatungen wie BCG, McKinsey, Deloitte und PwC, die selbst kommerzielle KI-Transformationsleistungen anbieten. Ein potenzieller Interessenkonflikt bei der Darstellung von KI-Potenzialen kann trotz der in der Arbeit vorgenommenen kritischen Würdigung und der Kombination mit wissenschaftlichen Quellen nicht vollständig ausgeschlossen werden.

Schließlich ist die Aktualität der verwendeten Literatur als Limitation zu berücksichtigen. Das Forschungsfeld der generativen KI entwickelt sich außergewöhnlich schnell, sodass Studien, die zum Zeitpunkt der Recherche aktuell waren, bereits bei der Fertigstellung der Arbeit durch neuere Erkenntnisse oder veränderte Rahmenbedingungen überholt sein können. Die in dieser Arbeit beschriebenen Veränderungen in Arbeitsprozessen und Kompetenzprofilen sind daher als Momentaufnahme eines sich dynamisch entwickelnden Feldes zu verstehen und nicht als stabile Befundlage.

5.4 Handlungsempfehlungen

Auf Basis der Literaturanalyse sowie der Ergebnisse der Experteninterviews lassen sich im Folgenden konkrete Handlungsempfehlungen für SAP als Organisation sowie für Wissensarbeitende ableiten. Die Empfehlungen orientieren sich an den drei Themenbereichen der Arbeit und adressieren sowohl strukturelle als auch individuelle Handlungsbedarfe.

Verankerung des Human in the Loop als organisationales Prinzip

Eine zentrale Erkenntnis aus Literatur und Interviews ist, dass KI-Systeme nicht deterministisch arbeiten und zu Halluzinationen neigen, weshalb die menschliche Prüfinstanz in keinem KI-gestützten Prozess wegfallen darf. SAP sollte das Prinzip des Human in the Loop daher nicht als individuelle Verhaltensempfehlung belassen, sondern als verbindlichen Bestandteil von Prozessdesign und Qualitätssicherung verankern. Konkret bedeutet dies, dass bei der Einführung neuer KI-gestützter Workflows von Beginn an festgelegt werden sollte, welche Ausgaben von wem geprüft werden und welche Eskalationswege bei fehlerhaften Ergebnissen bestehen. Gerade im Bereich der Softwareentwicklung, den Person D exemplarisch beschreibt, sollte KI-generierter Code grundsätzlich einem menschlichen Review unterzogen werden, bevor er produktiv eingesetzt wird.

Aufbau strukturierter KI-Kompetenz statt individuellem Ausprobieren

Die Interviews zeigen, dass KI-Nutzung bei SAP bislang stark von der persönlichen Initiative und Affinität der einzelnen Mitarbeitenden abhängt. Während einige Befragte bereits strukturierte Strategien wie Kontext-Prompts oder explizite Nachrechenaufträge entwickelt haben, tasteten sich andere anfangs ohne Orientierung an die Tools heran. SAP sollte daher gezielte Schulungsangebote entwickeln, die über die bloße Tool-Einführung hinausgehen und konkret die Fähigkeit zur kritischen Evaluation von KI-Ausgaben vermitteln. Dabei sollte Prompting als eigenständige Kompetenz behandelt werden, da die Qualität der KI-Ausgabe maßgeblich von der Qualität der Eingabe abhängt. Ergänzend empfiehlt sich der Aufbau eines teamübergreifenden Best-Practice-Katalogs, in dem bewährte Anwendungsfälle, geeignete Tools und Erfahrungen mit typischen Fehlern geteilt werden, um das vorhandene implizite Wissen einzelner Personen für die gesamte Organisation nutzbar zu machen.

Datenschutz sichtbar machen statt dokumentieren

Aus den Interviews geht hervor, dass Datenschutzvorgaben zwar existieren, aber häufig nur in internen Wiki-Artikeln hinterlegt sind und von Mitarbeitenden nicht aktiv wahrgenommen werden. Person C kritisiert, dass klare Hinweise fehlen, welche Daten in welches Tool eingegeben werden dürfen, und dass insbesondere das Need-to-Know-Prinzip sowie die Unterscheidung zwischen intern betriebenen und extern gehosteten Modellen vielen Kolleginnen und Kollegen nicht bewusst ist. SAP sollte daher Datenschutzhinweise direkt in den Tool-Oberflächen verankern, etwa durch Hinweistexte am Eingabefeld oder durch automatisierte Warnmeldungen bei erkennbar vertraulichen Inhalten. Darüber hinaus sollte eine zentrale und aktuell gehaltene Übersichtsseite bereitgestellt werden, die klar kommuniziert, welches Tool für welche Zwecke und Vertraulichkeitsstufen freigegeben ist.

Verlernrisiko aktiv adressieren

Die Interviews belegen, dass das Risiko des Verlernens besonders in technischen Tätigkeitsfeldern real ist. Person D beschreibt, dass der gedankliche Prozess des eigenständigen Entwickelns zunehmend durch die KI übernommen wird. Gleichzeitig zeigt Person B, dass aktive Auseinandersetzung mit KI-Ergebnissen diesen Effekt teilweise abmildern kann. SAP sollte daher Weiterbildungsmaßnahmen so gestalten, dass sie nicht nur neue KI-Kompetenzen aufbauen, sondern auch bestehende fachliche Fähigkeiten bewusst erhalten. Dies kann etwa durch regelmäßige Aufgaben geschehen, die bewusst ohne KI-Unterstützung bearbeitet werden, oder durch Mentoring-Formate, in denen erfahrene Mitarbeitende ihr implizites Erfahrungswissen an jüngere Kolleginnen und Kollegen weitergeben, bevor es durch KI-Nutzung an Sichtbarkeit verliert. Da das Verlernrisiko, wie in Abschnitt 5.2 dargelegt, besonders in strukturierten Entwicklungsrollen auftritt, sollten entsprechende Maßnahmen gezielt für Mitarbeitende in technischen Entwicklungsrollen konzipiert werden, wie sie in dieser Untersuchung durch Person D repräsentiert werden, anstatt sie pauschal für alle Mitarbeitenden auszurollen.

KI-Budgets fair und zweckgebunden gestalten

Sowohl Person B als auch Person D weisen auf ein bisher wenig diskutiertes strukturelles Risiko hin, nämlich dass ungleiche Token-Limits und KI-Budgets zwischen verschiedenen Rollen und Einheiten dazu beitragen könnten, dass bestehende Leistungsunterschiede weiter zunehmen. Wer mehr KI-Kapazität zur Verfügung hat, kann produktiver arbeiten und neue Kompetenzen schneller aufbauen. Da bei SAP mehrere Tools wie EKX, MS Copilot und Claude parallel im Einsatz sind und unterschiedliche Nutzungslimits gelten, ist diese Frage besonders relevant. SAP sollte daher bei der Vergabe von KI-Nutzungsbudgets nicht allein technische oder kostenbezogene Kriterien anlegen, sondern auch den konkreten Arbeitsbedarf der jeweiligen Rolle berücksichtigen. Gleichzeitig sollten Mitarbeitende darin geschult werden, Prompts effizient zu formulieren und den tatsächlichen Nutzwert jedes KI-Einsatzes zu hinterfragen, um Ressourcen gezielt einzusetzen.

Wissensarbeitende für veränderte Rollenanforderungen vorbereiten

Schließlich zeigen sowohl die Literatur als auch die Interviews übereinstimmend, dass sich die Rolle von Wissensarbeitenden grundlegend verändert. Routinetätigkeiten werden zunehmend durch KI übernommen, während gleichzeitig die Anforderungen an kontextuelles Urteilsvermögen, kritisches Denken und die Fähigkeit zur Qualitätssicherung steigen. SAP sollte diese Verschiebung aktiv kommunizieren und in die interne Karriere- und Rollenentwicklung einbeziehen. Mitarbeitende sollten verstehen, dass KI keine Bedrohung für ihre Tätigkeit darstellt, sondern eine Erweiterung, die jedoch neue Kompetenzen erfordert. Gleichzeitig sollten Führungskräfte sensibilisiert werden, die wachsende Spreizung zwischen KI-affinen und KI-ablehnenden Mitarbeitenden frühzeitig zu erkennen und durch gezielte Unterstützungsangebote zu adressieren, bevor daraus dauerhafte Kompetenzlücken oder Teamkonflikte entstehen.

6 Fazit und Ausblick

Die vorliegende Arbeit hat untersucht, wie KI-Textgenerierung die Wissensarbeit bei SAP verändert und welche Chancen und Risiken sich daraus ergeben. Ausgehend von einer systematischen Literaturanalyse in Kapitel 4 wurden theoretische Befunde zu Veränderungen in Arbeitsprozessen, Kompetenzprofilen sowie Chancen und Risiken erarbeitet. In Kapitel 5 wurden diese Befunde anhand leitfadengestützter Experteninterviews mit vier Wissensarbeitenden bei SAP empirisch überprüft, diskutiert und durch Handlungsempfehlungen für die Organisation ergänzt. Das abschließende Kapitel fasst die zentralen Ergebnisse der Arbeit zusammen und gibt einen Ausblick auf offene Fragen und mögliche Anknüpfungspunkte für weiterführende Forschung.

6.1 Zusammenfassung der Ergebnisse

Die Arbeit zeigt, dass KI-Textgenerierung die Wissensarbeit nicht durch eine vollständige Ablösung menschlicher Tätigkeiten verändert, sondern durch eine mehrstufige Verschiebung von Aufgabenschwerpunkten. Routineorientierte Tätigkeiten wie Texterstellung, Dokumentation und Informationsrecherche werden zunehmend durch Large Language Models unterstützt oder übernommen, während Wissensarbeitende stärker in steuernde, überwachende und qualitätssichernde Rollen wechseln. Dieser Befund aus der Literatur wird durch alle vier befragten Interviewpartner bestätigt, die übereinstimmend berichten, dass KI für sie als Assistenzsystem fungiert, das ihre Arbeit erweitert, aber nicht ersetzt.

Gleichzeitig bringt dieser Wandel veränderte Kompetenzanforderungen mit sich. KI-Kompetenz und kritisches Denken werden zur neuen Grundvoraussetzung, da generierte Inhalte stets bewertet und hinterfragt werden müssen. Implizites Erfahrungswissen gewinnt an Wert, weil Large Language Models auf explizitem Textwissen basieren und situatives Urteilsvermögen sowie kontextabhängige Entscheidungen nicht replizieren können. Darüber hinaus erweist sich Datenschutz- und Sicherheitskompetenz als wachsende Querschnittsanforderung, die in den Interviews besonders deutlich als drängend beschrieben wird. Die Interviews ergänzen die Literatur dabei an mehreren Stellen, die bislang weniger prominent diskutiert werden. Dazu zählen die strukturelle Sichtbarkeitslücke bei Datenschutzvorgaben in Tool-Oberflächen sowie die Frage, inwiefern ungleiche KI-Nutzungsbudgets bestehende Leistungsunterschiede zwischen Mitarbeitenden verstärken könnten. Darüber hinaus führt der Vergleich zu einer eigenständigen Schlussfolgerung zum Verlernrisiko, wonach dieses nicht generell vorhanden oder abwesend ist, sondern ausgeprägt tätigkeitsabhängig auftritt und sich besonders in strukturierten Entwicklungsrollen zeigt, in denen KI kognitive Kernprozesse ersetzt statt ergänzt, während es in projektnaher oder beratender Wissensarbeit deutlich geringer ausgeprägt ist.

Die Chancen des KI-Einsatzes liegen vor allem in der Entlastung von Routinetätigkeiten, der Aufwertung strategisch-inhaltlicher Arbeit und der Beschleunigung analytischer Prozesse. Dem gegenüber stehen Risiken durch unkritische KI-Nutzung, den Wegfall klassischer Lernpfade für weniger erfahrene Mitarbeitende, eine wachsende Qualifikationslücke zwischen KI-affinen und KI-ablehnenden Beschäftigten sowie eine bislang wenig beachtete Frage der Chancengerechtigkeit durch ungleiche KI-Nutzungsbudgets. Die abgeleiteten Handlungsempfehlungen adressieren diese Herausforderungen auf organisationaler Ebene und betonen, dass SAP den strukturellen Rahmen für einen verantwortungsvollen KI-Einsatz aktiv gestalten muss, anstatt ihn der individuellen Initiative der Mitarbeitenden zu überlassen.

Zusammenfassend lässt sich festhalten, dass die Forschungsfrage, wie KI-Textgenerierung Arbeitsprozesse und Kompetenzprofile in der Wissensarbeit bei SAP verändert sowie welche Chancen und Risiken sich daraus ergeben, durch die Kombination aus Literaturanalyse und Experteninterviews differenziert beantwortet werden konnte. Die Ergebnisse sind dabei nicht als abgeschlossener Befund zu verstehen, sondern als Momentaufnahme eines sich dynamisch entwickelnden Feldes.

6.2 Ausblick

Die vorliegende Arbeit öffnet mehrere Anknüpfungspunkte für weiterführende Forschung. Erstens beschränkt sich die Untersuchung auf einen einzelnen Unternehmensfall mit vier Interviewpartnerinnen und Interviewpartnern, von denen drei aus derselben Organisationseinheit stammen. Eine Mehrfallstudie, die verschiedene Unternehmen, Branchen oder Unternehmensgrößen einbezieht, könnte prüfen, ob die identifizierten Muster übertragbar sind oder ob SAP als Technologieunternehmen mit fortgeschrittener KI-Adoption einen Sonderfall darstellt.

Zweitens wäre eine Studie aufschlussreich, die dieselben oder vergleichbare Wissensarbeitende über einen längeren Zeitraum begleitet. Die Frage, ob das beschriebene Verlernrisiko tatsächlich eintritt und in welchem Umfang sich Kompetenzprofile langfristig verschieben, lässt sich auf Basis einer einmaligen Erhebung nicht abschließend beantworten.

Drittens wurde in der Arbeit bewusst auf die Perspektive von Berufsanfängerinnen und Berufsanfängern verzichtet, da die Untersuchungseinheit auf aktive LLM-Nutzende fokussiert war. Gerade für diese Gruppe ist jedoch die Frage besonders relevant, ob der Wegfall klassischer Lernpfade durch KI-gestützte Routineübernahme langfristig den Aufbau impliziten Erfahrungswissens beeinträchtigt. Hier besteht erheblicher Forschungsbedarf, der über die vorliegende Arbeit hinausgeht.

Schließlich entwickelt sich das Forschungsfeld der generativen KI außergewöhnlich schnell weiter. Neue Modellgenerationen, agentenbasierte Systeme und eine zunehmende Integration in Unternehmensprozesse werden die in dieser Arbeit beschriebenen Veränderungen voraus-

sichtlich weiter verstärken und neue Fragen aufwerfen, die zum Zeitpunkt der Untersuchung noch nicht absehbar waren. Eine kontinuierliche wissenschaftliche Begleitung dieser Entwicklung bleibt daher notwendig.

Anhang

A1: Übersicht eingesetzter KI-Werkzeuge

Werkzeug	Beschreibung der Nutzung
ChatGPT	• Sprachliche Überarbeitung und Umformulierung von Textpassagen zur Verbesserung der Ausdrucksweise (gesamt) • Erstellung von BibTeX-Einträgen für das Literaturverzeichnis auf Basis bibliografischer Angaben (gesamt)
Claude (Anthropic)	• Vorschläge zu wissenschaftlicher Fachliteratur und relevanten Quellen im Themenfeld KI und Wissensarbeit (gesamt) • Übersetzung von Textpassagen und Fachbegriffen vom Deutschen ins Englische (gesamt) • Inhaltliche Rückfragen zu Konzepten und Begriffsdefinitionen zur eigenen Einschätzung (gesamt) • Zusammenfassung der Experteninterviews und Aufbereitung der Interviewinhalte für die Auswertung (Kapitel 5)
NotebookLM (Google)	• Erstellung einer strukturierten Übersicht über die verwendeten Quellen und deren Kerninhalte (gesamt) • Abgleich von Textaussagen mit den zugehörigen Quellenbelegen zur Konsistenz- und Zitatprüfung (gesamt) • Zusammenfassung und Erschließung längerer wissenschaftlicher Dokumente (gesamt)
Elicit	• Systematische Literaturrecherche zu wissenschaftlichen Studien und Forschungsergebnissen im Themenfeld KI-gestützte Textgenerierung und Wissensarbeit (Kapitel 2 und 3) • Identifikation thematisch relevanter Publikationen anhand von Forschungsfragen (Kapitel 2 und 3)

Tabelle 1: Übersicht über die Nutzung von KI-basierten Werkzeugen

Interviewleitfaden: LLMs in der Wissensarbeit bei SAP

Interviewleitfaden: KI Tools in der Wissensarbeit bei SAP

Datum und Uhrzeit: xx.xx.xxxx um xx:xx Uhr	Ort: Microsoft Teams Besprechung
Befragter: xxx	Interviewer: Anton Nguyen

Alle Daten werden anonymisiert behandelt und nicht weitergegeben. Die Arbeit ist nur meinem wissenschaftlichen Betreuer an der DHBW Ravensburg sowie ausgewählten Kollegen intern bei SAP zugänglich.

	Inhaltliche Aspekte	Nachfragen mit obligatorischer Formulierung
Erzählauf-forderung	Würdest du dich zu Beginn kurz vorstellen und etwas über deinen beruflichen Hintergrund und deine aktuellen Aufgaben erzählen?	
Erzählauf-forderung	Wie häufig nutzt du interne KI Tools wie den MS Copilot Unternehmenschat, GenAI XL, Claude oder EKX in deinem Arbeitsalltag, regelmäßig, gelegentlich oder eher selten oder gar nicht?	<i>Falls regelmäßig: Wofür genau setzt du sie ein, und gibt es Aufgaben, bei denen du sie besonders häufig nutzt? Falls selten oder gar nicht: Was sind die Gründe dafür?</i>
Erzählauf-forderung	Was hält dich, oder Kolleg:innen in deinem Bereich, davon ab, diese Tools stärker zu nutzen?	<i>Liegt das eher an fehlendem Vertrauen, fehlender Schulung, ungeeigneten Aufgaben, technischen Hürden oder anderen Gründen?</i>
Erzählauf-forderung	Was hat sich bei deiner Arbeit konkret verändert, seit du diese Tools nutzt, beziehungsweise was müsste sich ändern, damit du sie stärker einsetzt?	<i>Was hat sich dadurch für dein Team oder deine Abteilung verändert?</i>
Erzählauf-forderung	Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist oder ob du sie lieber selbst übernimmst?	<i>Fällt dir ein konkretes Beispiel aus deinem Bereich dazu ein?</i>
Erzählauf-forderung	KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	<i>Hattest du selbst schon einmal so eine Situation? Was ist passiert, und wie bist du damit umgegangen?</i>
Erzählauf-forderung	Worauf achtest du beim Thema Datenschutz und Vertraulichkeit, wenn du diese Tools bei SAP nutzt?	<i>Gibt es dazu klare Vorgaben oder Regeln in deinem Bereich?</i>
Erzählauf-forderung	Prüfst und überarbeitest du inzwischen mehr KI generierte Inhalte, statt Dinge komplett selbst von null zu erstellen?	<i>Was musstest du dafür neu lernen, oder welche Fähigkeiten sind dadurch wichtiger geworden?</i>
Erzählauf-forderung	Hast du manchmal das Gefühl, dass du dich zu sehr auf die Tools verlässt und dadurch etwas verlernst?	
Erzählauf-forderung	Wo bringt dir KI am meisten Zeitvorteile oder Qualitätsvorteile, und wo stößt sie an ihre Grenzen?	<i>Fallen dir weitere Vorteile oder Nachteile ein, die wir noch nicht angesprochen haben?</i>
Erzählauf-forderung	Was sollte SAP als Unternehmen tun, damit die Vorteile genutzt werden, ohne dass die Risiken überhandnehmen?	<i>Was würdest du speziell für deinen eigenen Bereich empfehlen?</i>
Ab-schluss-frage:	Gibt es sonst noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist und das wir noch nicht besprochen haben?	

Abbildung 1: Interviewleitfaden: KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person A

Gesprächsprotokoll	Interview Person A 30.07.2026, 11:00-11:30 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	• 4-5 Jahre bei PCG; Hintergrund in Recruiting (Daimler/Mercedes-Benz, Amazon, Deutsche Bahn) und PM bei SAP (HANA Data & Analytics) • Aktuell PM in einem internen Transformationsprojekt - Neugestaltung von zwei Support-Einheiten • Bringt PCG-Konzepte zu Rollen-Snapshots, Zusammenführungen und Retrospektiven ein
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	• Regelmäßig, täglich • EKX -> hauptsächlich für PowerPoint-Präsentationen • MS Copilot -> E-Mail-Formulierungen, Texte polieren • Teams Premium -> automatische Meeting-Summaries -> Weitergabe an Copilot zur Analyse (z.B. unbekannte Fachbegriffe wie „Omnichannel Routing“ erklären lassen)
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	• Person A selbst hält nichts davon ab • Kolleg:innen: Wissenslücken über Tool-Funktionsweise; fehlende Einsicht in den Nutzen • Zeitargument: Nachkontrolle kostet Zeit; Unsicherheit bzgl. Datenschutz • Fehlende Prompting-Kompetenz -> schlechte Ergebnisse
Was hat sich konkret verändert, bzw. was müsste sich ändern?	• Delegiert administrative PM-Aufgaben an KI -> mehr Zeit für strategisch-inhaltliche Themen • Wunsch: PII-Daten auch in EKX erlaubt; bessere Tool-Integration (Teams Summary -> Copilot -> Auto-Action-Items + E-Mail) • Einschränkung: Halluzinationsgefahr macht umfangreiche Aufgaben weiterhin zeitaufwendig
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	• Geeignet: E-Mails, Texte, Präsentationen • Nicht geeignet: langer E-Mail-Vorkontext, Prioritätenabhängigkeiten, Empathie/Teamdynamik, finanzielle/zeitliche Impacts • Bsp.: Workshop-Agenden mit individuellen Teilnehmenden-Hintergründen - dafür ist KI nicht gemacht
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	• Irischer Kollege mit starkem Akzent falsch transkribiert -> Copilot erfand wiederholt „Paris-Projekt“ • Person A musste 90-Min.-Meeting vollständig abhören, um Fehlerquelle zu finden • Umgang: Suchfunktion, Video zurückspringen, kritisch gegenlesen - „Du kannst dem Tool nicht blind vertrauen“
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	• Grünes SAP-internes Symbol bei Copilot beachten; kein PII in EKX eingeben • Richtlinien nicht auf einer zentralen Seite konsolidiert; Wissenstand ggf. veraltet • Wunsch: zentrale Übersichtsseite oder KI-Tool, das Datenschutzfragen beantwortet
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	• Wichtigste neue Fähigkeit: Prompting - Scope definieren, Ergebnis challengen • Kritisches Prüfen des Outputs; gezielte Tool-Auswahl • Nutzt Claude bewusst nicht - Oberfläche zu technisch; bevorzugt Copilot • „Es gibt nicht das eine richtige Tool - jeder muss seinen Weg finden“
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	• Bei Person A nicht - lernt bei unbekannten Themen (z.B. Go-Live-Testing) durch KI dazu • Kolleginnen aus Assistenzbereichen berichten jedoch, E-Mails nach intensiver KI-Nutzung nicht mehr alleine schreiben zu können
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	• Vorteile: Administrative Aufgaben beschleunigt, strategisch relevanter arbeiten, weniger Routinearbeit • Grenzen: Halluzinationen, fehlende Tool-übergreifende Kommunikation, kein Kontextverständnis, keine Empathie
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	• Zentrale Übersichtsseite: welches Tool wofür, was darf eingegeben werden • Automatischer PII-Guard; regelmäßige interne Kommunikation über neue Möglichkeiten • PCG-spezifisch: KI-Best-Practice-Katalog team- und bereichsübergreifend teilen
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	• KI-Nutzung stark isoliert je Team - Wunsch: PCG-weiter Überblick, welche Teams welche Tools wie einsetzen • Kontrast: Bei SAP KI fast erwartet; in anderen Unternehmen wurden ChatGPT-Übersetzungen als Abmahnungsgrund behandelt

Tabelle 2: Gesprächsprotokoll: Interview mit Person A — KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person B

Gesprächsprotokoll	Interview Person B 30.07.2026, 13:15-13:45 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	• Projekte im Bereich Support und Support Operations bei PCG; ca. 15 Jahre in der Gruppe • Hintergrund: externer Consultant in 4 Firmen (Bankbereich, technische Seite), dann SAP Systems Integration, Global Process Office, CEO Area Internal Consulting • Aktuell: Entitlement Checks für Partnerprodukte, Customer Support Profiles (Nachbarprojekt zu Support Rewired) sowie interne Projekte zu KI-Tools
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	• Sehr regelmäßig • PM-Aufgaben: Projekte aufsetzen, Work-Breakdown-Structures entwickeln, Planung starten • Brainstormen und kritische Durchsicht von Präsentationsfolien - KI als Sparring-Partner • Gelegentlich als Lern-Tutor bei neuen Themen; Prozessmodellierung mit KI-Tools in Signavio
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	• Person B selbst kaum durch Schulung gehemmt; in Expertenbereichen (Datenmodellierung, Datenanalyse) sind aber bessere KI-Kenntnisse nötig • Stärkere Nutzung kommt mit stärkeren Tool-Fähigkeiten und der Möglichkeit, Agenten aufzubauen • Für Agentic AI fehlen noch Kurse (z.B. Joule Studio)
Was hat sich konkret verändert, bzw. was müsste sich ändern?	• Zeit wird frei -> mehrere Projekte gleichzeitig einfacher zu betreuen; Qualität steigt • Gegenpol: KI-Ergebnisse müssen immer geprüft werden, was Zeit kostet (teilweise Kompensation) • Im Team: große Unterschiede in KI-Affinität; Person B wird häufig von Kollegen um Rat gefragt
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	• Formulierungsaufgaben: sehr geeignet, spart schnell Zeit • Komplexe Zusammenhänge: Einzelaspekte eingeben, KI verknüpft und reichert mit Wissen an • Projektplanung: Infos von Stakeholdern zusammenfassen lassen - funktioniert sehr gut • Recherche und Einarbeitung in neue Themen als Tutor - hilft, „5 Minuten Vorsprung vor dem Kunden“ zu erreichen
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	• Früher: KI rechnete falsch oder schrieb Zahlen ohne Berechnung hin; Bildgenerierung mit vielen Fehlern • Heute deutlich besser; Person B hat einen Kontext-Prompt auf die eigene Rolle zugeschnitten • Prompt enthält Anweisung zu Rückfragen und Interaktion, sodass KI Halluzinationen selbst erkennt • Auch Compliance-, Branding- und Sprachvorgaben im Prompt verpackt -> kaum noch Probleme
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	• Klare Vorgaben vorhanden; empfiehlt Disclaimer der Tools zu lesen • Datenschutz ist Topthema für SAP - konsequente Einhaltung wichtig, auch wenn umständlich • Kontext-Prompt enthält Anweisung: keine persönlichen Daten verwenden • Richtet sich nach SAP-Empfehlungen; beachtet Vertraulichkeitsstufen: Public, Confidential, Strictly Confidential
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	• Ja - KI-Inhalte überarbeiten statt selbst von Grund auf erstellen überwiegt absolut • Fähigkeit zur strukturierten Evaluation von KI-Ergebnissen noch nicht ausgebildet - braucht Kurse • Hält das für eine zentrale Aufgabe, die das Team noch lernen muss
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	• Ja, Gefahr besteht - je mehr man sich stützt, desto schneller verlernt man Dinge • Durch aktive Evaluation von KI-Ergebnissen kann man den Effekt teilweise kompensieren • Man empfindet das Ergebnis dann wieder als eigenes -> Ausgleich zwischen Nutzung und Verlernrisiko
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	• Vorteile: Projekt-Setup, Kommunikationsaufgaben, Produktivität und Qualität eindeutig • Kostenvorteil aus Firmensicht: KI kann Personal ersetzen, wenn günstiger als Personalkosten • Nachteil: Großer Spread zwischen KI-affinen und nicht-affinen Kollegen -> mögliche Konflikte in Teamstrukturen • Überforderung als Risiko: hohe Erwartungshaltung von Arbeitgeber und Gesellschaft kann psychische Probleme verursachen
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	• Mitarbeiter befähigen, KI-Ergebnisse strukturiert zu evaluieren - auch aktiv einfordern • Kapazität für Evaluation einplanen, nicht nur Netto-Produktivitätsvorteile messen • Automatisierte Überprüfung bei automatisierten KI-Antworten einbauen • Überforderungsthematik im Auge behalten; Verlernrisiko adressieren
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	• Token-Kosten und faire Verteilung von KI-Nutzungsbudgets - einige Rollen können grenzenlos nutzen, andere sehr begrenzt -> Chancenungleichheit • Rollenveränderungen durch KI werden in 2-3 Jahren enorm stark sein; Risiko für Einzelne, Chance für KI-affine Kollegen und den Arbeitgeber

Tabelle 3: Gesprächsprotokoll: Interview mit Person B — KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person C

Gesprächsprotokoll	Interview Person C 06.08.2026, 11:00-11:30 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	- Wirtschaftsinformatik studiert; 2003 Berufseinstieg bei kleiner Hardwarefirma in Hamburg 2006 SAP-Einstieg (Technologieberatung, Traineeprogramm); 2026 20-jähriges Jubiläum bei SAP - Ca. 7 Jahre Consulting, ca. 7 Jahre MaxAttention-Kundenbetreuung, Mitentwicklung des Readiness-Checks (ERP -> S/4HANA-Migration) - Seit ca. 6 Jahren bei PCG; aktuelles Projekt: internes Transformationsprojekt zur Neugestaltung von Kundenkommunikation auf Kanal-, Technologie- und Geschäftsprozessebene
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	- Regelmäßig - Teams Premium: Meeting-Transcript-Summaries - Claude und EKX: größere Datenmengen aus Excels/Dokumenten zusammenfassen, Inhalte gezielt finden - Bsp.: 500-seitige Compliance- und Rechtsdokumente (z.B. sap.com) analysieren, ohne PII einzugeben - statt manuelles Durchlesen
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	- Person C selbst hält nichts davon ab - PCG ist keine Entwicklungseinheit -> geringerer Anreiz für Code-Generierung; nicht alle Projekte arbeiten mit Massendaten - Bei Strategie-Projekten (Meetings, Dokumente, konzeptionelles Arbeiten) keine weiteren Anwendungsfälle als aktuell genutzt - Bei Kolleg:innen: Unterschied zwischen KI-Affinen (nutzen privat ChatGPT, Gemini, Claude Code, DeepSeek) und KI-Ablehnenden -> Letztere weniger intrinsisch motiviert
Was hat sich konkret verändert, bzw. was müsste sich ändern?	- Persönlich schneller geworden; im aktuellen Strategie-Projekt ca. 10 % Speed-Steigerung (kein Massendaten-Projekt) - Vergleich mit Entwickler-Freund: 90 % Zeitersparnis bei Prototypen-Erstellung - Bei PCG-Projekten mit Massendaten (z.B. Ticketanalysen): höhere Ersparnis möglich, aber nicht bezifferbar - Im Team: Kolleg:innen beschäftigen sich mehr mit dem Thema, Lernaufwand kostet zunächst Zeit; noch in Anfangsphase (manche Tools erst seit wenigen Monaten freigegeben)
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	- Primärfilter: Datenschutz- und Vertraulichkeitsprüfung vor inhaltlicher Eignung - Primäre Hürde: personenbezogene Daten und Confidentiality; aufpassen, was man eingibt - Need-to-Know-Prinzip: auch Kundendaten ohne PII sind vertraulich; KI kann Daten aggregieren, die nur einem engeren Kreis zugänglich sein sollten - Viele Kolleg:innen nicht ausreichend für diesen Sachverhalt sensibilisiert
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	- Bei Zusammenfassungen: Plausibilitätschecks durchführen; bei eigenem Meeting direkt erkennbar - Bei Datenauswertungen: Ergebnis hinterfragen lassen („Rechne bitte nochmal nach,“) -> fast in der Hälfte der Fälle leichte Abweichungen in zweiter Antwort - Umgang: Bei Trendaussagen mit leichten Abweichungen wird das Ergebnis trotzdem genutzt; bei genauen Zahlen ist manuelle Prüfung notwendig
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	- Need-to-Know-Prinzip beachten; kein PII und keine vertraulichen Daten eingeben - Klare Vorgaben fehlen oft: im offiziellen Playground lange keine deutlichen Hinweise (kein Popup, keine rote Schrift) - Regeln nur in Wiki-Artikeln/Dokumenten hinterlegt - Großer Nachholbedarf: Datenschutzhinweise müssen direkt am Prompt-Eingabefeld erscheinen, nicht nur auf Übersichtsseiten
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	Nein - erstellt Inhalte überwiegend selbst
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	Bis jetzt noch nicht
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	- Vorteile im aktuellen Projekt: Meeting Summaries, Dokument Summaries, PowerPoint-Gerüst als Ausgangsbasis (dann manuell nacharbeiten) - Für Entwickler massiver Vorteil (bis 90 % Zeitersparnis bei Prototypen); für Operations ebenfalls (Daten aus ERP/Ariba ohne vordefinierten Report abrufen, Stichwort Autonomous Enterprise) - Risiko: KI-Outputs nicht immer reproduzierbar -> erschwert Support für KI-generierte Ergebnisse; fraglich, ob SAP genug Zeit/Geld in diesen Aspekt investiert
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	- Klares Bewusstsein schaffen, welche Datenquellen an Assistenten angebunden werden und was die jeweilige Zielgruppe sehen darf (Need-to-Know) - Mitarbeitende verinnerlichen lassen, ob genutzte Tools intern (hinter SAP-Firewall) oder extern (OpenAI, Google) betrieben werden - Offenheit für KI-Nutzung fördern, wenn Datenbewusstsein vorhanden -> hohes Potenzial; andernfalls persönliches Compliance-Risiko
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	Nein, alle relevanten Aspekte wurden besprochen

Tabelle 4: Gesprächsprotokoll: Interview mit Person C — KI Tools in der Wissensarbeit bei SAP

Interview-Auswertung: Person D

Gesprächsprotokoll	Interview Person D 10.08.2026, 10:30-11:00 Uhr Thema: KI Tools in der Wissensarbeit bei SAP Interviewer: Anton Nguyen
Würdest du dich kurz vorstellen und etwas über deinen beruflichen Hintergrund erzählen?	• Senior Developer in einer SAP-Entwicklungsabteilung • DHBW-Student seit 2016, Studienabschluss 2019, danach direkt in die Abteilung übernommen • Aufgaben: Softwareentwicklung sowie Betreuung von Studierenden • Schwerpunkt im Alltag: Performance-KPIs für Apps (Geschwindigkeit, Ressourcenverbrauch)
Wie häufig nutzt du interne KI Tools in deinem Arbeitsalltag?	• Täglich • Einstieg über internen Aufruf, ein KI-Coding-Tool zu installieren; seitdem kontinuierlich gewachsen • Hauptanwendungsfälle: Code-Generierung und Dokumentation (technische Doku sowie User-Anleitungen)
Was hält dich oder Kolleg:innen davon ab, diese Tools stärker zu nutzen?	• Anfangs: fehlendes Vertrauen, weil die Tools neu waren • Kolleg:innen sind Gewohnheitstiere; disruptive Technologien erzeugen zunächst Skepsis • Mittlerweile größtenteils überwunden; Team hat sich mit den Grenzen und Stärken der Tools vertraut gemacht
Was hat sich konkret verändert, bzw. was müsste sich ändern?	• Team angehalten, bei jeder Problemstellung aktiv zu fragen: „Macht KI-Einsatz hier Sinn? Warum (nicht)?“ • Code-Generierung mit KI ist Standard, aber immer mit anschließendem menschlichem Review • Dokumentation: Word-Dateien werden in Markdown-Files überführt, damit KI damit arbeiten kann • Neue Dokumente entstehen heute überwiegend KI-unterstützt
Woran machst du fest, ob eine Aufgabe gut für KI geeignet ist?	• Gut geeignet: Code-Analyse (ABAP-Klassen, UI5-Controller, ganze App-Projekte) - KI liefert detaillierte Beschreibungen • Grenzen: viele voneinander abhängige Klassen und Objekte - KI verliert den Kontext-überblick • Sowohl JavaScript/UI5 als auch ABAP werden analysiert; Nutzung nimmt bei ABAP zu
KI Tools erfinden manchmal Dinge, die plausibel klingen, aber falsch sind. Wie gehst du damit um?	• Man entwickelt ein Gefühl dafür, ob Aussagen stimmen; trotzdem immer kritisch hinterfragen • Konkretes Beispiel: Kollege fragte, ob das ABAP-Statement „Wait“, intern einen Commit auslöst; KI verneinte dies klar - obwohl die offizielle Dokumentation das Gegenteil belegt • Risiko: unkritisch übernommener KI-Code wird in Monaten oder Jahren schwer wartbar und unkontrollierbar
Worauf achtest du beim Thema Datenschutz und Vertraulichkeit?	• Keine personenbezogenen Daten an KI-Tools weitergeben - wird im Team konsequent beachtet • „Human in the Loop“: bei jedem KI-unterstützten Entwicklungsschritt ist menschliche Prüfung Pflicht • Auch bei Reviews gilt: KI-Output immer durch menschliches Urteil absichern
Prüfst du mehr KI-generierte Inhalte? Welche Fähigkeiten sind wichtiger geworden?	• Ja - neue Dokumente entstehen heute fast ausschließlich KI-unterstützt statt von Grund auf selbst erstellt • Neue Anforderung: Word-Dateien in Markdown konvertieren, damit KI damit arbeiten kann - anfangs Hürde, nach einmaliger Einarbeitung routiniert • Kritische Prüfung und Review von KI-Outputs ist zur zentralen Arbeitspraxis geworden
Hast du das Gefühl, dich zu sehr auf die Tools zu verlassen?	• Ja, das Risiko ist real - weiß nicht mehr, wann zuletzt eigenständig ABAP-Code entwickelt wurde • Der gedankliche Entwicklungsprozess wird von der KI übernommen und fehlt dadurch • Fähigkeit noch nicht vollständig verlernt, aber das Risiko ist vorhanden
Wo bringt KI am meisten Vorteile, und wo stößt sie an ihre Grenzen?	• Vorteile: Zeitersparnis bei Dokumentenanalyse (z.B. 80-seitige Dokumente schnell zusammenfassen und gezielt befragen) • Analytische Aufgaben wie Code-Review und Dokumentation beschleunigt • Grenzen: komplexe Abhängigkeiten zwischen vielen Objekten - KI verliert Kontext; Ergebnisse müssen immer validiert werden
Was sollte SAP tun, damit Vorteile genutzt werden, ohne dass Risiken überhandnehmen?	• Token-Limits sind bereits ein präsent Thema; Budgets für Entwicklung sollten ausreichend sein • Mitarbeitende sollten lernen, Prompts effizienter zu formulieren und jeden Prompt auf seinen Nutzen zu prüfen • Balance finden zwischen produktivem KI-Einsatz und Kostenbewusstsein - KI nicht aus Bequemlichkeit verwenden
Gibt es noch etwas zum Thema KI und Arbeiten bei SAP, das dir wichtig ist?	• Menschliche Kontrolle in KI-getriebenen Prozessen ist essenziell - immer jemanden einplanen, der einschreiten kann • Egal ob Code, Reviews oder Dokumentation: KI sollte Assistent bleiben, nicht unkontrollierter Entscheider

Tabelle 5: Gesprächsprotokoll: Interview mit Person D — KI Tools in der Wissensarbeit bei SAP

Literaturverzeichnis

Agrawal, A., Gans, J.S. und Goldfarb, A. (2024) „Artificial intelligence adoption and system-wide change“, *Journal of Economics & Management Strategy*, 33(2), S. 327–337. Verfügbar unter: <https://doi.org/10.1111/jems.12521>.

Arlinghaus, A. (2017) *Wissensarbeit: Aktuelle arbeitswissenschaftliche Erkenntnisse*. MBF-Report 35. Verfügbar unter: https://www.imu-boeckler.de/fpdf/HBS-006601/p_mbf_report_2017_35.pdf.

Atakishiyev, R. u. a. (2025) „Explainability of Large Language Models: Opportunities and Challenges Toward Generating Trustworthy Explanations“, *arXiv preprint arXiv:2510.17256* [Preprint]. Verfügbar unter: <https://arxiv.org/pdf/2510.17256>.

Balzert, H. (2009) *Lehrbuch der Softwaretechnik: Basiskonzepte und Requirements Engineering*. 3. Aufl. Heidelberg: Spektrum Akademischer Verlag. Verfügbar unter: <https://doi.org/10.1007/978-3-8274-2247-7>.

Baur, N. und Blasius, J. (Hrsg.) (2022) *Handbuch Methoden der empirischen Sozialforschung*. 3. Aufl. Wiesbaden: Springer VS. Verfügbar unter: <https://doi.org/10.1007/978-3-658-37985-8>.

Beauchene, V. u. a. (2026) *AI at Work: Strategy Matters More Than Tools*. Verfügbar unter: <https://web-assets.bcg.com/eb/92/4b39b729403fb6fcae4ff974b234/ai-at-work-slideshow-jun-2026-1.pdf>.

Bogner, A., Littig, B. und Menz, W. (2014) *Interviews mit Experten: Eine praxisorientierte Einführung*. Wiesbaden: Springer VS (Qualitative Sozialforschung). Verfügbar unter: <https://doi.org/10.1007/978-3-531-19416-5>.

Brassey, J. u. a. (2026) „Five Principles for Designing Brain-Powered Organizations“, *McKinsey People & Organizational Performance Blog* [Preprint]. Verfügbar unter: <https://www.mckinsey.com/capabilities/people-and-organizational-performance/our-insights/the-organization-blog/five-principles-for-designing-brain-powered-organizations>.

Brynjolfsson, E., Li, D. und Raymond, L.R. (2025) „Generative AI at Work“, *The Quarterly Journal of Economics*, 140(2), S. 889–942. Verfügbar unter: <https://doi.org/10.1093/qje/qjae044>.

Bubeck, S. u. a. (2023) *Sparks of Artificial General Intelligence: Early Experiments with GPT-4*. arXiv. Verfügbar unter: <https://doi.org/10.48550/arXiv.2303.12712>.

Burger, D. (2011) *Computergestützter organisationaler Wissenstransfer und Wissensgenerierung: Ein Experteninterview basierter Forschungsansatz*. Wiesbaden: VS Verlag für Sozialwissenschaften (SpringerLink Bücher). Verfügbar unter: <https://doi.org/10.1007/978-3-531-93047-3>.

Carbonero, F., Ernst, E. und Weber, E. (2023) „The Impact of Artificial Intelligence on Labor Markets in Developing Countries: A New Method with an Illustration for Lao PDR and Urban Viet Nam“, *Journal of Evolutionary Economics*, 33, S. 707–736. Verfügbar unter: <https://doi.org/10.1007/s00191-023-00809-7>.

Chen, Q. u. a. (2025) „Large language models at work in China's labor market“, *China Economic Review*, 92, S. 102413. Verfügbar unter: <https://doi.org/10.1016/j.chieco.2025.102413>.

Cheng, Q. u. a. (2026) „The trust crisis in artificial intelligence: AI hallucinations and human-AI collaboration“, *Technology in Society*, 86, S. 103286. Verfügbar unter: <https://doi.org/10.1016/j.techsoc.2026.103286>.

Cooper, A.F., Frankle, J. und Sa, C.D. (2022) „Non-Determinism and the Lawlessness of Machine Learning Code“, in *Proceedings of the 2022 Symposium on Computer Science and Law (CSLAW '22)*. ACM, S. 1–9. Verfügbar unter: <https://doi.org/10.1145/3511265.3550446>.

Dell'Acqua, F. u. a. (2026) „Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality“, *Organization Science*, S. 1–21. Verfügbar unter: <https://doi.org/10.1287/orsc.2025.21838>.

Deloitte (2026) *2026 Global Human Capital Trends: From Tensions to Tipping Points – Choosing the Human Advantage*. technical report.

DiSorbo, M.D., Ju, H. und Aral, S. (2025) „Teaching AI to Handle Exceptions: Supervised Fine-Tuning with Human-Aligned Judgment“, *arXiv preprint arXiv:2503.02976* [Preprint]. Verfügbar unter: <https://doi.org/10.48550/arXiv.2503.02976>.

Drucker, P.F. (1994) „The Age of Social Transformation“, *The Atlantic Monthly*, 274(5), S. 53–80. Verfügbar unter: <https://www.theatlantic.com/past/politics/ecbig/soctrans.htm> (Zugegriffen: 22 Juli 2026).

Drucker, P.F. (1999) „Knowledge-Worker Productivity: The Biggest Challenge“, *California Management Review*, 41(2), S. 79–94.

Eisenhardt, K.M. und Graebner, M.E. (2007) „Theory Building from Cases: Opportunities and Challenges“, *Academy of Management Journal*, 50(1), S. 25–32. Verfügbar unter: <https://doi.org/10.5465/AMJ.2007.24160888>.

Eloundou, T. u. a. (2023) *GPTs are GPTs: An Early Look at the Labor Market Impact Potential of Large Language Models*. arXiv. Verfügbar unter: <https://doi.org/10.48550/arXiv.2303.10130>.

Emerson, G. u. a. (2026) „AI Will Reshape More Jobs Than It Replaces“, *Boston Consulting Group* [Preprint]. Verfügbar unter: <https://www.bcg.com/publications/2026/ai-will-reshape-more-jobs-than-it-replaces> (Zugegriffen: 28 Juli 2026).

Fantapié Altobelli, C. (2017) *Marktforschung: Methoden, Anwendungen, Praxisbeispiele*. 3. Aufl. Konstanz und München: UVK Verlagsgesellschaft mbH. Verfügbar unter: <https://doi.org/10.36198/9783838587219>.

Felten, E., Raj, M. und Seamans, R. (2023) „Occupational Heterogeneity in Exposure to Generative AI“, *SSRN Electronic Journal* [Preprint], (4414065). Verfügbar unter: <https://doi.org/10.2139/ssrn.4414065>.

Gerlich, M. (2025) „AI Tools in Society: Impacts on Cognitive Offloading and the Future of Critical Thinking“, *Societies*, 15(1), S. 6. Verfügbar unter: <https://doi.org/10.3390/soc15010006>.

Haufe Online Redaktion (2017) *Status quo Wissensarbeit: Viel Routine, wenig Innovation*. Verfügbar unter: https://www.haufe.de/personal/hr-management/status-quo-wissensarbeit-viel-routine-wenig-innovation_80_428408.html (Zugegriffen: 27 Juli 2026).

Hussin, A. u. a. (2024) „The Gen AI Skills Revolution: Rethinking Your Talent Strategy“, *McKinsey Insights* [Preprint]. Verfügbar unter: <https://www.mckinsey.com/~media/mckinsey/business%20functions/mckinsey%20digital/our%20insights/the%20gen%20ai%20skills%20revolution%20rethinking%20your%20talent%20strategy/the-gen-ai-skills-revolution-rethinking-your-talent-strategy-v3.pdf?shouldIndex=false>.

Jiao, J. u. a. (2025) *Generative AI and LLMs in Industry: A Text-Mining Analysis and Critical Evaluation of Guidelines and Policy Statements Across Fourteen Industrial Sectors*. Verfügbar unter: <https://arxiv.org/abs/2501.00957>.

Kusterer, S. (2008) *Qualitätssicherung im Wissensmanagement: Eine Fallstudienanalyse*. Wiesbaden: Gabler Edition Wissenschaft.

Lee, H.-P. u. a. (2025) „The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Stewardship“, in *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '25)*. ACM. Verfügbar unter: <https://doi.org/10.1145/3706598.3713778>.

Lei, Y.-W. und Kim, R. (2024) „Automation and Augmentation: Artificial Intelligence, Robots, and Work“, *Annual Review of Sociology*, 50, S. 251–272. Verfügbar unter: <https://doi.org/10.1146/annurev-soc-090523-050708>.

Lu, J. (2025) „Tacit Knowledge in Large Language Models“, *The Review of Austrian Economics* [Preprint]. Verfügbar unter: <https://doi.org/10.1007/s11138-025-00710-5>.

Metakis, M. u. a. (2026) „You Can't Lead AI from the Sidelines“, *McKinsey People & Organizational Performance Blog* [Preprint]. Verfügbar unter: <https://www.mckinsey.com/capabilities/people-and-organizational-performance/our-insights/the-organization-blog/you-cant-lead-ai-from-the-sidelines>.

- Noy, S. und Zhang, W. (2023) „Experimental Evidence on the Productivity Effects of Generative Artificial Intelligence“, *SSRN Electronic Journal* [Preprint]. Verfügbar unter: <https://doi.org/10.2139/ssrn.4375283>.
- Porst, R. (2015) „Arten von Befragungen und Befragungstechniken“, *Gesellschaft, Wirtschaft, Politik (GWP)*, 64(1), S. 93–103. Verfügbar unter: <https://www.budrich-journals.de/>.
- PwC Deutschland (2026) *2026 AI Jobs Barometer: KI kommt an, doch Skills folgen kaum*. Studie. Verfügbar unter: <https://www.pwc.de/de/workforce-transformation/ai-jobs-barometer.html> (Zugegriffen: 28 Juli 2026).
- Rafi, M. u. a. (2024) „Analyzing The Impact of Generative AI on IT Employee Performance“, in *2024 3rd International Conference on Creative Communication and Innovative Technology (ICCIT)*. IEEE. Verfügbar unter: <https://doi.org/10.1109/ICCIT62134.2024.10701171>.
- Renner, K.-H. und Jacob, N.-C. (2020) *Das Interview: Grundlagen und Anwendung in Psychologie und Sozialwissenschaften*. Berlin and Heidelberg: Springer (Basiswissen Psychologie). Verfügbar unter: <https://doi.org/10.1007/978-3-662-60441-0>.
- Romeo, G. und Conti, D. (2025) „Exploring automation bias in human–AI collaboration: a review and implications for explainable AI“, *AI and Society*, 41, S. 259–278. Verfügbar unter: <https://doi.org/10.1007/s00146-025-02422-7>.
- Snyder, H. (2019) „Literature review as a research methodology: An overview and guidelines“, *Journal of Business Research*, 104, S. 333–339. Verfügbar unter: <https://doi.org/10.1016/j.jbusres.2019.07.039>.
- Spatola, N. (2024) „The efficiency-accountability tradeoff in AI integration: Effects on human performance and over-reliance“, *Computers in Human Behavior: Artificial Humans*, 2(2), S. 100059. Verfügbar unter: <https://doi.org/10.1016/j.chbah.2024.100059>.
- Spivack, N. u. a. (2024) „Cognition is All You Need—The Next Layer of AI Above Large Language Models“, *arXiv preprint arXiv:2403.02164* [Preprint]. Verfügbar unter: <https://doi.org/10.48550/arXiv.2403.02164>.
- Trenerry, B. u. a. (2021) „Preparing Workplaces for Digital Transformation: An Integrative Review and Framework of Multi-Level Factors“, *Frontiers in Psychology*, 12, S. 620766. Verfügbar unter: <https://doi.org/10.3389/fpsyg.2021.620766>.
- Woodruff, A. u. a. (2024) „How Knowledge Workers Think Generative AI Will (Not) Transform Their Industries“, in *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '24)*. ACM. Verfügbar unter: <https://doi.org/10.1145/3613904.3642700>.
- World Economic Forum (2025) *The Future of Jobs Report 2025*. Verfügbar unter: https://reports.weforum.org/docs/WEF_Future_of_Jobs_Report_2025.pdf.

Yin, R.K. (2014) *Case Study Research: Design and Methods*. Thousand Oaks, California: SAGE Publications.

Selbständigkeitserklärung

Ich versichere hiermit, dass ich die vorliegende Projektarbeit mit dem Thema

Wissensarbeit im Zeitalter generativer Künstlicher Intelligenz bei SAP

Eine systematische Analyse der Auswirkungen von Large Language Models auf Arbeitsprozesse und Kompetenzprofile

selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe und diese Arbeit bei keiner anderen Prüfung mit gleichem oder vergleichbarem Inhalt vorgelegt habe und diese bislang nicht veröffentlicht wurde. Des Weiteren versichere ich, dass die eingereichte elektronische Fassung mit der gedruckten Ausfertigung übereinstimmt.

Ort, Datum

Unterschrift

Erklärung und Nutzungsdokumentation zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten als Prüfungsleistungen

Zur Verwendung KI-gestützter Werkzeuge erkläre ich in Kenntnis des Hinweisblatts „Hinweise zum Einsatz von KI-basierten Werkzeugen bei der Anfertigung von wissenschaftlichen Arbeiten als Prüfungsleistungen im prüfungsrechtlichen Kontext“ Folgendes:

- Ich habe mich aktiv über die Leistungsfähigkeit und Beschränkungen der in meiner Arbeit eingesetzten KI-Werkzeuge informiert.
- Bei der Anfertigung der Arbeit habe ich durchgehend eigenständig und beim Einsatz KI-gestützter Werkzeuge maßgeblich steuernd gearbeitet.
- Insbesondere habe ich die Inhalte entweder aus wissenschaftlicher oder anderen zugelassenen Quellen entnommen und diese gekennzeichnet oder diese unter Anwendung wissenschaftlicher Methoden selbst entwickelt.
- Mir ist bewusst, dass ich als Verfasser:in der Arbeit die volle Verantwortung für die in ihr gemachten Angaben und Aussagen trage.
- Soweit ich KI-gestützte Werkzeuge zur Erstellung der Arbeit eingesetzt habe, sind diese zu den Produktnamen, den formulierten Eingaben (Prompts), den Einsatzzwecken und der entsprechenden Seiten-/Bereichsreferenzierung auf die Arbeit im KI-Verzeichnis am Ende der Arbeit vollständig ausgewiesen und im Text belegt (z.B. als Fußnote).

Ort, Datum

Unterschrift